

Análisis Multivariado ID 033521

Semana 4: Inferencial para el media

Profesora: Diana Marcela Martínez Ruiz

20 de agosto de 2026

- 1 Inferencia sobre el vector de medias
- 2 T^2 de Hotelling y Test de razón de verosimilitud
- 3 Regiones de Confianza en el Caso Multivariado

Caso univariado

Hipótesis sobre la media de una población normal

$$H_0 : \mu = \mu_0 \text{ y } H_1 : \mu \neq \mu_0$$

Caso univariado

Hipótesis sobre la media de una población normal

$$H_0 : \mu = \mu_0 \text{ y } H_1 : \mu \neq \mu_0$$

Si $X_1, \dots, X_n$ denota una muestra aleatoria de una población normal, el test estadístico para contrastar las hipótesis es

$$t = \frac{\bar{X} - \mu_0}{s/\sqrt{n}} \sim t_{n-1}(\alpha)$$

donde $\bar{X} = \frac{1}{n} \sum_{j=1}^n X_j$, $s^2 = \frac{1}{n-1} \sum_{j=1}^n (X_j - \bar{X})^2$ y t_{n-1} denota el percentil $100(\alpha)$ de la distribución T-Student con n grados de libertad.

Caso univariado

Hipótesis sobre la media de una población normal

$$H_0 : \mu = \mu_0 \text{ y } H_1 : \mu \neq \mu_0$$

Si $X_1, \dots, X_n$ denota una muestra aleatoria de una población normal, el test estadístico para contrastar las hipótesis es

$$t = \frac{\bar{X} - \mu_0}{s/\sqrt{n}} \sim t_{n-1}(\alpha)$$

donde $\bar{X} = \frac{1}{n} \sum_{j=1}^n X_j$, $s^2 = \frac{1}{n-1} \sum_{j=1}^n (X_j - \bar{X})^2$ y t_{n-1} denota el percentil $100(\alpha)$ de la distribución T-Student con n grados de libertad.

Regla de decisión

Se rechaza H_0 si $|t| > t_{n-1}(\alpha)$

Si escribimos

$$t^2 = \frac{(\bar{X} - \mu_0)^2}{s^2/n} = n(\bar{X} - \mu_0)(s^2)^{-1}(\bar{X} - \mu_0)$$

donde t^2 es el cuadrado de la distancia de la media muestral al valor de prueba μ_0 .

Si escribimos

$$t^2 = \frac{(\bar{X} - \mu_0)^2}{s^2/n} = n(\bar{X} - \mu_0)(s^2)^{-1}(\bar{X} - \mu_0)$$

donde t^2 es el cuadrado de la distancia de la media muestral al valor de prueba μ_0 . **Regla de decisión**

Se rechazar H_0 a un nivel de significancia $\alpha/2$, si

$$t^2 > t_{n-1}^2(\alpha/2)$$

También se puede tomar una decisión con base en el intervalo de confianza:

$$\bar{x} - t_{n-1}(\alpha/2) \frac{s}{\sqrt{n}} \leq \mu_0 \leq \bar{x} + t_{n-1}(\alpha/2) \frac{s}{\sqrt{n}}$$

Inferencia sobre el vector de medias

Caso Multivariado: inferencia para el vector de medias

Sea $\boldsymbol{\mu}_{p \times 1}$ el vector de medias poblacionales del vector aleatorio $\mathbf{X}_{p \times 1}$

$$H_0 : \boldsymbol{\mu}_{p \times 1} = \boldsymbol{\mu}_{p \times 1}^0 \text{ y } H_1 : \boldsymbol{\mu}_{p \times 1} \neq \boldsymbol{\mu}_{p \times 1}^0$$

Caso Multivariado: inferencia para el vector de medias

Sea $\boldsymbol{\mu}_{p \times 1}$ el vector de medias poblacionales del vector aleatorio $\mathbf{X}_{p \times 1}$

$$H_0 : \boldsymbol{\mu}_{p \times 1} = \boldsymbol{\mu}_{p \times 1}^0 \text{ y } H_1 : \boldsymbol{\mu}_{p \times 1} \neq \boldsymbol{\mu}_{p \times 1}^0$$

Una generalización natural de la distancia t^2 del caso univariado es:

$$T^2 = (\bar{\mathbf{X}} - \boldsymbol{\mu}_0)' \left(\frac{1}{n} \mathbf{S} \right)^{-1} (\bar{\mathbf{X}} - \boldsymbol{\mu}_0)$$

Caso Multivariado: inferencia para el vector de medias

Sea $\boldsymbol{\mu}_{p \times 1}$ el vector de medias poblacionales del vector aleatorio $\mathbf{X}_{p \times 1}$

$$H_0 : \boldsymbol{\mu}_{p \times 1} = \boldsymbol{\mu}_{p \times 1}^0 \text{ y } H_1 : \boldsymbol{\mu}_{p \times 1} \neq \boldsymbol{\mu}_{p \times 1}^0$$

Una generalización natural de la distancia t^2 del caso univariado es:

$$T^2 = (\bar{\mathbf{X}} - \boldsymbol{\mu}_0)' \left(\frac{1}{n} \mathbf{S} \right)^{-1} (\bar{\mathbf{X}} - \boldsymbol{\mu}_0)$$

donde $\bar{\mathbf{X}}_{p \times 1} = \frac{1}{n} \sum_{j=1}^n \mathbf{X}_j$, $\mathbf{S}_{p \times p} = \frac{1}{n-1} \sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}})(\mathbf{X}_j - \bar{\mathbf{X}})$, y $\boldsymbol{\mu}_0 = \begin{bmatrix} \mu_{10} \\ \mu_{20} \\ \vdots \\ \mu_{p0} \end{bmatrix}$.

Aquí $(1/n)\mathbf{S}$ es la matriz de covarianza estimada de $\bar{\mathbf{X}}$.

Caso Multivariado: inferencia para el vector de medias

Sea $\boldsymbol{\mu}_{p \times 1}$ el vector de medias poblacionales del vector aleatorio $\mathbf{X}_{p \times 1}$

$$H_0 : \boldsymbol{\mu}_{p \times 1} = \boldsymbol{\mu}_{p \times 1}^0 \text{ y } H_1 : \boldsymbol{\mu}_{p \times 1} \neq \boldsymbol{\mu}_{p \times 1}^0$$

Una generalización natural de la distancia t^2 del caso univariado es:

$$T^2 = (\bar{\mathbf{X}} - \boldsymbol{\mu}_0)' \left(\frac{1}{n} \mathbf{S} \right)^{-1} (\bar{\mathbf{X}} - \boldsymbol{\mu}_0)$$

donde $\bar{\mathbf{X}}_{p \times 1} = \frac{1}{n} \sum_{j=1}^n \mathbf{X}_j$, $\mathbf{S}_{p \times p} = \frac{1}{n-1} \sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}})(\mathbf{X}_j - \bar{\mathbf{X}})$, y $\boldsymbol{\mu}_0 = \begin{bmatrix} \mu_{10} \\ \mu_{20} \\ \vdots \\ \mu_{p0} \end{bmatrix}$.

Aquí $(1/n)\mathbf{S}$ es la matriz de covarianza estimada de $\bar{\mathbf{X}}$.



El estadístico T^2 es llamado T^2 de Hotelling

Si el estadístico T^2 es grande, significa que el vector muestral $\bar{\mathbf{x}}$ está muy alejado del vector hipotético $\boldsymbol{\mu}_0$. Por lo tanto, se rechazaría H_0 .

Si el estadístico T^2 es grande, significa que el vector muestral $\bar{x}$ está muy alejado del vector hipotético μ_0 . Por lo tanto, se rechazaría H_0 .

El estadístico T^2 se distribuye

$$\frac{(n-1)p}{n-p} F_{p, n-p}$$

donde $F_{p, n-p}$ denota una v.a con una distribución F con p y $n-p$ grados de libertad.

Si el estadístico T^2 es grande, significa que el vector muestral $\bar{\mathbf{x}}$ está muy alejado del vector hipotético $\boldsymbol{\mu}_0$. Por lo tanto, se rechazaría H_0 .

El estadístico T^2 se distribuye

$$\frac{(n-1)p}{n-p} F_{p, n-p}$$

donde $F_{p, n-p}$ denota una v.a con una distribución F con p y $n-p$ grados de libertad.

Teorema

Sea $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ una muestra aleatoria de una población $N_{p(\boldsymbol{\mu}, \boldsymbol{\Sigma})}$. Entonces con $\bar{\mathbf{X}}_{p \times 1} = \frac{1}{n} \sum_{j=1}^n \mathbf{X}_j$, $\mathbf{S}_{p \times p} = \frac{1}{n-1} \sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}})(\mathbf{X}_j - \bar{\mathbf{X}})$.

A un nivel de significancia α , la hipótesis H_0 se rechaza si:

$$T^2 = n(\bar{\mathbf{x}} - \boldsymbol{\mu}_0)' \mathbf{S}^{-1} (\bar{\mathbf{x}} - \boldsymbol{\mu}_0) > \frac{(n-1)p}{n-p} F_{p, n-p}$$

Ejemplo (Prueba de un vector de medias con T^2)

Se analizó la transpiración de 20 mujeres sanas. Se midieron tres componentes: X_1 (tasa de sudoración), X_2 (sodio) y X_3 (potasio).

Pruebe $H_0 : \boldsymbol{\mu}' = [4, 50, 10]$ contra $H_1 : \boldsymbol{\mu}' \neq [4, 50, 10]$ con $\alpha = 0,10$.

Los cálculos proporcionan:

$$\bar{\mathbf{x}} = \begin{bmatrix} 4,640 \\ 45,400 \\ 9,965 \end{bmatrix}, \quad \mathbf{S}^{-1} = \begin{bmatrix} ,586 & -,022 & ,258 \\ -,022 & ,006 & -,002 \\ ,258 & -,002 & ,402 \end{bmatrix}$$

$$T^2 = 20[0,640, -4,600, -0,035] \begin{bmatrix} 0,467 \\ -0,042 \\ 0,160 \end{bmatrix} = 9,74$$

Example 5.2 de Johnson and Wichern (2013), Applied Multivariate Statistical Analysis, pp. 214

Comparando el valor observado $T^2 = 9,74$ con el valor critico

$$\frac{(n-1)p}{n-p} F_{p,n-p}(0,10) = \frac{19 * 3}{17} F_{3,17}(0,10) = 8,18$$

se observa que $T^2 = 9,74 > 8,18$, consecuentemente se rechaza H_0 a un nivel de significancia del 10 %.

```
library(ICSNP)
mu_0=c(4,50,10)# Vector de medias de la H_0
HotellingsT2(sweat_data[, -1], mu=mu_0, test="f")
```

Hotelling's one sample T2-test

```
data:  sweat_data[, -1]
T.2 = 2.9045, df1 = 3, df2 = 17, p-value = 0.06493
alternative hypothesis: true location is not equal to c(4,50,10)
```

```
library(ICSNP)
mu_0=c(4,50,10)# Vector de medias de la H_0
HotellingsT2(sweat_data[, -1], mu=mu_0, test="f")
```

Hotelling's one sample T2-test

```
data:  sweat_data[, -1]
T.2 = 2.9045, df1 = 3, df2 = 17, p-value = 0.06493
alternative hypothesis: true location is not equal to c(4,50,10)
```

- **Nota sobre el estadístico:** La diferencia entre el valor $T^2 = 9,74$ y la salida de R ($T,2 = 2,90$) radica en que R reporta el estadístico ya transformado a la distribución F para realizar la prueba. La relación utilizada es:

$$F = \frac{n - p}{p(n - 1)} T^2$$

donde $n = 20$ y $p = 3$. Ambos valores son matemáticamente consistentes para la misma inferencia.



Comparando con los resultados de las Pruebas univariadas individuales

En el caso **univariado**:

$$H_{01} : \mu_1 = 4$$

$$H_{02}$$

$$: \mu_2 = 50$$

$$H_{03} : \mu_3 = 10$$

$$H_{11} : \mu_1 \neq 4$$

$$H_{12}$$

$$: \mu_2 \neq 50$$

$$H_{13} : \mu_3 \neq 10$$

tenemos:

$$p\text{-valor}_1 = 0,108, \quad p\text{-valor}_2 = 0,1619, \quad p\text{-valor}_3 = 0,9354$$

Comparando con los resultados de las Pruebas univariadas individuales

En el caso **univariado**:

$$H_{01} : \mu_1 = 4$$

$$H_{02} : \mu_2 = 50$$

$$H_{03} : \mu_3 = 10$$

$$H_{11} : \mu_1 \neq 4$$

$$H_{12} : \mu_2 \neq 50$$

$$H_{13} : \mu_3 \neq 10$$

tenemos:

$$p\text{-valor}_1 = 0,108, \quad p\text{-valor}_2 = 0,1619, \quad p\text{-valor}_3 = 0,9354$$

Observe que **en todos los casos** $p\text{-valor} > \alpha$, así que para un nivel de significancia del 10 % **se concluye que los valores 4, 50, 10 son plausibles** para μ_1, μ_2 y μ_3 , respectivamente.

El problema es que **pueden existir otros valores de μ** que también pueden ser consistentes con los datos.



Observaciones

- Con las pruebas univariadas los valores dados fueron plausibles (no se rechazó H_0), mientras que en la multivariada no lo fueron (se rechazó H_0).

Observaciones

- Con las pruebas univariadas los valores dados fueron plausibles (no se rechazó H_0), mientras que en la multivariada no lo fueron (se rechazó H_0).
- H_0 será rechazada si una o más de las componentes difiere mucho de los valores hipotéticos 0. En este punto no se tiene idea de cuales de estos valores hipotéticos no son soportados por los datos.

Observaciones

- Con las pruebas univariadas los valores dados fueron plausibles (no se rechazó H_0), mientras que en la multivariada no lo fueron (se rechazó H_0).
- H_0 será rechazada si una o más de las componentes difiere mucho de los valores hipotéticos 0. En este punto no se tiene idea de cuales de estos valores hipotéticos no son soportados por los datos.
- Para que la prueba sea válida es necesario que los datos provengan de una distribución normal multivariada.

T^2 de Hotelling y Test de razón de verosimilitud

Estimadores máximo verosímiles (MLE) de $\boldsymbol{\mu}$ y $\boldsymbol{\Sigma}$

Sea $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ una muestra aleatoria proveniente de una población $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Entonces:

$$\hat{\boldsymbol{\mu}} = \overline{\mathbf{X}} \quad \text{y} \quad \hat{\boldsymbol{\Sigma}} = \frac{1}{n} \sum_{j=1}^n (\mathbf{X}_j - \overline{\mathbf{X}})(\mathbf{X}_j - \overline{\mathbf{X}})' = \frac{(n-1)}{n} \mathbf{S}$$

Estimadores máximo verosímiles (MLE) de μ y Σ

Sea $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ una muestra aleatoria proveniente de una población $N_p(\mu, \Sigma)$. Entonces:

$$\hat{\mu} = \bar{\mathbf{X}} \quad \text{y} \quad \hat{\Sigma} = \frac{1}{n} \sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}})(\mathbf{X}_j - \bar{\mathbf{X}})' = \frac{(n-1)}{n} \mathbf{S}$$

son los estimadores de máxima verosimilitud de μ y Σ , respectivamente. Sus valores observados, $\bar{\mathbf{x}}$ y $\frac{1}{n} \sum_{j=1}^n (\mathbf{x}_j - \bar{\mathbf{x}})(\mathbf{x}_j - \bar{\mathbf{x}})'$, son llamados las estimaciones de máxima verosimilitud de μ y Σ .

Máxima Verosimilitud (ML)

El MLE $\bar{\mathbf{X}}$ es un vector aleatorio y el MLE $\hat{\Sigma}$ es una matriz aleatoria. **Las estimaciones de máxima verosimilitud son sus valores particulares para el conjunto de datos dado.**

Además, el máximo de la verosimilitud es:

$$L(\hat{\mu}, \hat{\Sigma}) = \frac{1}{(2\pi)^{np/2}} e^{-np/2} \frac{1}{|\hat{\Sigma}|^{n/2}} \quad (1)$$

Máxima Verosimilitud (ML)

El MLE $\bar{\mathbf{X}}$ es un vector aleatorio y el MLE $\hat{\Sigma}$ es una matriz aleatoria. **Las estimaciones de máxima verosimilitud son sus valores particulares para el conjunto de datos dado.**

Además, el máximo de la verosimilitud es:

$$L(\hat{\boldsymbol{\mu}}, \hat{\boldsymbol{\Sigma}}) = \frac{1}{(2\pi)^{np/2}} e^{-np/2} \frac{1}{|\hat{\boldsymbol{\Sigma}}|^{n/2}} \quad (1)$$

De aquí se tienen que la ML de la normal multivariada está dada por:

$$\max_{\boldsymbol{\mu}, \boldsymbol{\Sigma}} L(\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{np/2} |\hat{\boldsymbol{\Sigma}}|^{n/2}} e^{-np/2}$$

Bajo $H_0 : \boldsymbol{\mu} = \boldsymbol{\mu}_0$, se tiene que

$$\max_{\boldsymbol{\Sigma}} L(\boldsymbol{\mu}_0, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{np/2} |\hat{\boldsymbol{\Sigma}}_0|^{n/2}} e^{-np/2}$$

donde $\hat{\boldsymbol{\Sigma}}_0 = \frac{1}{n} \sum_{j=1}^n (\mathbf{x}_j - \boldsymbol{\mu}_0)(\mathbf{x}_j - \boldsymbol{\mu}_0)(\mathbf{X}_j)'$

Para contrastar las hipótesis $H_0 : \boldsymbol{\mu} = \boldsymbol{\mu}_0$ y $H_1 : \boldsymbol{\mu} \neq \boldsymbol{\mu}_0$

Es decir, para determinar si $\boldsymbol{\mu}_0$ es un valor plausible de $\boldsymbol{\mu}$, se deben comparar $\max_{\boldsymbol{\Sigma}} L(\boldsymbol{\mu}_0, \boldsymbol{\Sigma})$ y $\max_{\boldsymbol{\mu}, \boldsymbol{\Sigma}} L(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Esta comparación es llamada *estadístico de razón de verosimilitud*, el cual está dado por

$$\Lambda = \frac{\max_{\boldsymbol{\Sigma}} L(\boldsymbol{\mu}_0, \boldsymbol{\Sigma})}{\max_{\boldsymbol{\mu}, \boldsymbol{\Sigma}} L(\boldsymbol{\mu}, \boldsymbol{\Sigma})} = \left(\frac{|\hat{\boldsymbol{\Sigma}}_0|}{|\hat{\boldsymbol{\Sigma}}|} \right)^{n/2}$$

Estadístico Razón de verosimilitud

Para contrastar las hipótesis $H_0 : \boldsymbol{\mu} = \boldsymbol{\mu}_0$ y $H_1 : \boldsymbol{\mu} \neq \boldsymbol{\mu}_0$

Es decir, para determinar si $\boldsymbol{\mu}_0$ es un valor plausible de $\boldsymbol{\mu}$, se deben comparar $\max_{\boldsymbol{\Sigma}} L(\boldsymbol{\mu}_0, \boldsymbol{\Sigma})$ y $\max_{\boldsymbol{\mu}, \boldsymbol{\Sigma}} L(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Esta comparación es llamada *estadístico de razón de verosimilitud*, el cual está dado por

$$\Lambda = \frac{\max_{\boldsymbol{\Sigma}} L(\boldsymbol{\mu}_0, \boldsymbol{\Sigma})}{\max_{\boldsymbol{\mu}, \boldsymbol{\Sigma}} L(\boldsymbol{\mu}, \boldsymbol{\Sigma})} = \left(\frac{|\hat{\boldsymbol{\Sigma}}_0|}{|\hat{\boldsymbol{\Sigma}}|} \right)^{n/2}$$

El estadístico equivalente es $\Lambda^{2/n} = \frac{|\hat{\boldsymbol{\Sigma}}_0|}{|\hat{\boldsymbol{\Sigma}}|}$ es llamado *Lambda de Wilks*. También puede expresarse como

$$\Lambda^{2/n} = \left(1 + \frac{T^2}{n-1} \right)^{-1}$$

Estadístico Razón de verosimilitud

Para contrastar las hipótesis $H_0 : \boldsymbol{\mu} = \boldsymbol{\mu}_0$ y $H_1 : \boldsymbol{\mu} \neq \boldsymbol{\mu}_0$

Es decir, para determinar si $\boldsymbol{\mu}_0$ es un valor plausible de $\boldsymbol{\mu}$, se deben comparar $\max_{\boldsymbol{\Sigma}} L(\boldsymbol{\mu}_0, \boldsymbol{\Sigma})$ y $\max_{\boldsymbol{\mu}, \boldsymbol{\Sigma}} L(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Esta comparación es llamada *estadístico de razón de verosimilitud*, el cual está dado por

$$\Lambda = \frac{\max_{\boldsymbol{\Sigma}} L(\boldsymbol{\mu}_0, \boldsymbol{\Sigma})}{\max_{\boldsymbol{\mu}, \boldsymbol{\Sigma}} L(\boldsymbol{\mu}, \boldsymbol{\Sigma})} = \left(\frac{|\hat{\boldsymbol{\Sigma}}_0|}{|\hat{\boldsymbol{\Sigma}}|} \right)^{n/2}$$

El estadístico equivalente es $\Lambda^{2/n} = \frac{|\hat{\boldsymbol{\Sigma}}_0|}{|\hat{\boldsymbol{\Sigma}}|}$ es llamado *Lambda de Wilks*. También puede expresarse como

$$\Lambda^{2/n} = \left(1 + \frac{T^2}{n-1} \right)^{-1}$$

Entonces, se rechaza H_0 para valores pequeños de $\Lambda^{2/n}$ o para valores de T^2 grandes.



Método general de razón de verosimilitud

Sea $\theta' = (\mu_1, \dots, \mu_p, \sigma_{11}, \dots, \sigma_{1p}, \dots, \sigma_{p-1,1}, \dots, \sigma_{pp})$ el vector de parámetros poblacionales desconocidos, y sea $L(\theta)$ la función de verosimilitud obtenida al evaluar la densidad conjunta de $X_1, \dots, X_n$ en sus valores muestrales $x_1, \dots, x_n$.

Método general de razón de verosimilitud

Sea $\theta' = (\mu_1, \dots, \mu_p, \sigma_{11}, \dots, \sigma_{1p}, \dots, \sigma_{p-1,1}, \dots, \sigma_{pp})$ el vector de parámetros poblacionales desconocidos, y sea $L(\theta)$ la función de verosimilitud obtenida al evaluar la densidad conjunta de $X_1, \dots, X_n$ en sus valores muestrales $x_1, \dots, x_n$.

El vector θ toma sus valores en el conjunto paramétrico Θ , cuya dimensión es $\nu = p + (p + 1)/2$. Entonces bajo $H_0 : \theta = \theta_0$ esta restricción cae en el subconjunto Θ_0 de Θ .

Método general de razón de verosimilitud

Sea $\theta' = (\mu_1, \dots, \mu_p, \sigma_{11}, \dots, \sigma_{1p}, \dots, \sigma_{p-1,1}, \dots, \sigma_{pp})$ el vector de parámetros poblacionales desconocidos, y sea $L(\theta)$ la función de verosimilitud obtenida al evaluar la densidad conjunta de $X_1, \dots, X_n$ en sus valores muestrales $x_1, \dots, x_n$.

El vector θ toma sus valores en el conjunto paramétrico Θ , cuya dimensión es $\nu = p + (p + 1)/2$. Entonces bajo $H_0 : \theta = \theta_0$ esta restricción cae en el subconjunto Θ_0 de Θ .

Cuando el tamaño de muestra n es grande, bajo H_0

$$-2 \ln \Lambda = -2 \ln \left(\frac{\max_{\theta \in \Theta_0} L(\theta)}{\max_{\theta \in \Theta} L(\theta)} \right)$$

es aproximadamente $\chi^2_{\nu - \nu_0}$. Donde $\nu - \nu_0 = (\text{Dimensión de } \Theta) - (\text{Dimensión de } \Theta_0)$

Para el caso particular de la normal multivariada, se tiene que

$$H_0 : \boldsymbol{\mu} = \boldsymbol{\mu}_0 \text{ y } H_1 : \boldsymbol{\mu} \neq \boldsymbol{\mu}_0$$

Para el caso particular de la normal multivariada, se tiene que

$$H_0 : \boldsymbol{\mu} = \boldsymbol{\mu}_0 \text{ y } H_1 : \boldsymbol{\mu} \neq \boldsymbol{\mu}_0$$

$\Theta_0 = (\mu_1 = \mu_{10}, \dots, \mu_p = \mu_{p0}, \sigma_{11}, \dots, \sigma_{1p}, \dots, \sigma_{p-1,1}, \dots, \sigma_{pp})$ tiene dimensión $\nu_0 = p(p+1)/2$.

Para el caso particular de la normal multivariada, se tiene que

$$H_0 : \boldsymbol{\mu} = \boldsymbol{\mu}_0 \text{ y } H_1 : \boldsymbol{\mu} \neq \boldsymbol{\mu}_0$$

$\Theta_0 = (\mu_1 = \mu_{10}, \dots, \mu_p = \mu_{p0}, \sigma_{11}, \dots, \sigma_{1p}, \dots, \sigma_{p-1,1}, \dots, \sigma_{pp})$ tiene dimensión $\nu_0 = p(p+1)/2$. **Recuerde que** ν son los parámetros que no tiene restricción, en este caso son los $\frac{p+1}{2}$ elementos de la $\boldsymbol{\Sigma}$, como $\boldsymbol{\mu} = \boldsymbol{\mu}_0$ se asumen fijos, no aportan a la dimensión de Θ_0 .

Para el caso particular de la normal multivariada, se tiene que

$$H_0 : \boldsymbol{\mu} = \boldsymbol{\mu}_0 \text{ y } H_1 : \boldsymbol{\mu} \neq \boldsymbol{\mu}_0$$

$\Theta_0 = (\mu_1 = \mu_{10}, \dots, \mu_p = \mu_{p0}, \sigma_{11}, \dots, \sigma_{1p}, \dots, \sigma_{p-1,1}, \dots, \sigma_{pp})$ tiene dimensión $\nu_0 = p(p+1)/2$. **Recuerde que** ν son los parámetros que no tiene restricción, en este caso son los $\frac{p+1}{2}$ elementos de la $\boldsymbol{\Sigma}$, como $\boldsymbol{\mu} = \boldsymbol{\mu}_0$ se asumen fijos, no aportan a la dimensión de Θ_0 . Por lo tanto:

$$-2 \ln \Lambda \sim \chi_p^2$$

Las pruebas son evaluadas con base en la función potencia:

$$\begin{aligned}\beta(\boldsymbol{\theta}) &= P_{\boldsymbol{\theta}}[\mathbf{X} \in \mathcal{R}] \\ &= \begin{cases} \text{Prob. Error. Tipo I} & , \text{ si } \boldsymbol{\theta} \in \Theta_0 \\ 1 - \text{Prob. Error. Tipo II} & , \text{ si } \boldsymbol{\theta} \in \Theta_0^c \end{cases} \\ &= \begin{cases} \alpha & , \text{ si } \boldsymbol{\theta} \in \Theta_0 \\ 1 - \beta & , \text{ si } \boldsymbol{\theta} \in \Theta_0^c \end{cases}\end{aligned}$$

donde $\mathcal{R}$ es la región de **rechazo** de H_0 .




Figura 1: Región de rechazo

Lo ideal es que

$$P_{\boldsymbol{\theta}}[\mathbf{X} \in \mathcal{R}] = \begin{cases} 0 & , \text{ si } \boldsymbol{\theta} \in \Theta_0 \\ 1 & , \text{ si } \boldsymbol{\theta} \in \Theta_0^c \end{cases}$$

Lo ideal es que

$$P_{\theta}[\mathbf{X} \in \mathcal{R}] = \begin{cases} 0 & , \text{ si } \theta \in \Theta_0 \\ 1 & , \text{ si } \theta \in \Theta_0^c \end{cases}$$

esto es:

- niveles de significancia

$$\begin{aligned} \alpha &= P[\text{Prob. Error. Tipo I}] \\ &= P[\text{Rechazar } H_0 \text{ cuando } H_0 \text{ verdadera}] \end{aligned}$$

pequeños (cercanos a 0).

- **altas potencias** (cercanas a 1)

$$\begin{aligned} 1 - \beta &= 1 - P[\text{Prob. Error. Tipo II}] \\ &= P[\text{Rechazar } H_0 \text{ cuando } H_0 \text{ falsa}] \end{aligned}$$

- **altas potencias** (cercanas a 1)

$$\begin{aligned}1 - \beta &= 1 - P[\text{Prob. Error. Tipo II}] \\ &= P[\text{Rechazar } H_0 \text{ cuando } H_0 \text{ falsa}]\end{aligned}$$

En general,

- en el caso **uniparamétrico**, la **LRT** es la **más potente** entre todas aquellas que tienen el mismo nivel de significancia.
- en el caso **multivariado**, la prueba **LRT** tiene **mayor potencia** (promedio) posible cuando el tamaño muestral es grande.

Regiones de Confianza en el Caso Multivariado

En la situación **multivariado**, **generally no es suficiente** con probar la hipótesis

$$H_0 : \mu = \mu_0$$

donde todas las componentes del vector de medias son especificadas bajo la hipótesis nula. Con frecuencia **es preferible encontrar regiones de μ con valores que son plausibles a la luz de los datos observados**. Estas regiones son llamadas **regiones de confianza**.

Definición de Región de Confianza

Una región de confianza para un vector de parámetro θ , es un **conjunto que contiene los posibles valores** de θ y está determinada por los datos.

Región de Confianza

Se dice que $R(\mathbf{X})$ es una región con $(1 - \alpha)100\%$ de confianza para θ , **antes de obtener la muestra**

$$P[R(\mathbf{X}) \text{ contenga al verdadero } \theta] = 1 - \alpha$$

Construcción de la Región de Confianza para μ

Para **construir una región de confianza** para μ recuerde que: Si $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ es una muestra aleatoria de una población $N_p(\mu, \Sigma)$

$$T^2 = n(\bar{\mathbf{X}} - \mu)^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \mu) \sim \frac{(n-1)p}{n-p} F_{p, n-p}$$

Entonces, **antes de obtener la muestra**

$$P \left[n(\bar{\mathbf{X}} - \mu)^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \mu) \leq \frac{(n-1)p}{n-p} F_{p, n-p}(\alpha) \right] = 1 - \alpha$$

Región de Confianza para una Muestra Dada

Luego, para una muestra dada, el conjunto de valores de μ que satisfacen

$$n(\bar{\mathbf{x}} - \boldsymbol{\mu})^\top \mathbf{S}^{-1}(\bar{\mathbf{x}} - \boldsymbol{\mu}) \leq \frac{(n-1)p}{n-p} F_{p, n-p}(\alpha)$$

definen una región para μ con $(1 - \alpha)100\%$ de confianza.

Región de Confianza para una Muestra Dada

Luego, para una muestra dada, el conjunto de valores de μ que satisfacen

$$n(\bar{\mathbf{x}} - \boldsymbol{\mu})^\top \mathbf{S}^{-1}(\bar{\mathbf{x}} - \boldsymbol{\mu}) \leq \frac{(n-1)p}{n-p} F_{p, n-p}(\alpha)$$

definen una **región** para μ con $(1 - \alpha)100\%$ de **confianza**. **Observación:**

- Geométricamente la **región** es una **elipsoide** centrada en $\bar{\mathbf{x}}$.
- La **región** $(1 - \alpha)100\%$ de confianza para μ contiene todos los posibles valores μ_0 para los cuales la prueba T^2 no rechaza $H_0 : \mu = \mu_0$ a un nivel de significancia α .




Figura 2: Elipse del 95 % de confianza para μ . Tomada de: Johnson and Wichern (2013), *Applied Multivariate Statistical Analysis*, pp. 223

Verificación de Valores Plausibles

Entonces, si **queremos determinar si un vector μ_0 cualquiera cae dentro de la región de confianza**, esto es, si queremos verificar si μ_0 es un valor plausible para μ , comparamos la distancia generalizada

$$n(\bar{\mathbf{x}} - \boldsymbol{\mu}_0)^\top \mathbf{S}^{-1}(\bar{\mathbf{x}} - \boldsymbol{\mu}_0)$$

con el cuantil

$$\frac{(n-1)p}{n-p} F_{p, n-p}(\alpha)$$

Verificación de Valores Plausibles

Entonces, si **queremos determinar si un vector μ_0 cualquiera cae dentro de la región de confianza**, esto es, si queremos verificar si μ_0 es un valor plausible para μ , comparamos la distancia generalizada

$$n(\bar{\mathbf{x}} - \boldsymbol{\mu}_0)^\top \mathbf{S}^{-1}(\bar{\mathbf{x}} - \boldsymbol{\mu}_0)$$

con el cuantil

$$\frac{(n-1)p}{n-p} F_{p, n-p}(\alpha)$$

Si

$$n(\bar{\mathbf{x}} - \boldsymbol{\mu}_0)^\top \mathbf{S}^{-1}(\bar{\mathbf{x}} - \boldsymbol{\mu}_0) \leq \frac{(n-1)p}{n-p} F_{p, n-p}(\alpha)$$

μ_0 CAE en la región de confianza.

Ejemplo Práctico: Datos de Sudoración

Para los datos de `sweat.xlsx` tenemos que

$$\bar{\mathbf{x}} = \begin{bmatrix} 4,64 \\ 45,40 \\ 9,96 \end{bmatrix}, \quad \mathbf{S} = \begin{bmatrix} 2,879 & 10,010 & -1,809 \\ 10,010 & 199,788 & -5,640 \\ -1,809 & -5,640 & 3,628 \end{bmatrix}$$

$$\mathbf{S}^{-1} = \begin{bmatrix} 0,586 & -0,022 & 0,258 \\ -0,022 & 0,006 & -0,002 \\ 0,258 & -0,002 & 0,402 \end{bmatrix}$$

luego, la **elipse del 90 % de confianza** para

$$\boldsymbol{\mu} = [\mu_1, \mu_2, \mu_3]^T$$

contiene todos los valores μ_1, μ_2, μ_3 que satisfacen

$$20[4,64 - \mu_1, 45,40 - \mu_2, 9,96 - \mu_3] \begin{bmatrix} 0,586 & -0,022 & 0,258 \\ -0,022 & 0,006 & -0,002 \\ 0,258 & -0,002 & 0,402 \end{bmatrix} \begin{bmatrix} 4,64 - \mu_1 \\ 45,40 - \mu_2 \\ 9,96 - \mu_3 \end{bmatrix} \leq \frac{19 \times 3}{17}(2,44) = 8,174$$

$$20[4,64 - \mu_1, 45,40 - \mu_2, 9,96 - \mu_3] \begin{bmatrix} 0,586 & -0,022 & 0,258 \\ -0,022 & 0,006 & -0,002 \\ 0,258 & -0,002 & 0,402 \end{bmatrix} \begin{bmatrix} 4,64 - \mu_1 \\ 45,40 - \mu_2 \\ 9,96 - \mu_3 \end{bmatrix} \leq \frac{19 \times 3}{17}(2,44) = 8,174$$

¿Cae $\mu_0 = [4, 50, 10]^\top$ dentro de la elipse del 90 % de confianza?

$$20[4,64 - \mu_1, 45,40 - \mu_2, 9,96 - \mu_3] \begin{bmatrix} 0,586 & -0,022 & 0,258 \\ -0,022 & 0,006 & -0,002 \\ 0,258 & -0,002 & 0,402 \end{bmatrix} \begin{bmatrix} 4,64 - \mu_1 \\ 45,40 - \mu_2 \\ 9,96 - \mu_3 \end{bmatrix} \leq \frac{19 \times 3}{17}(2,44) = 8,174$$

¿Cae $\mu_0 = [4, 50, 10]^T$ dentro de la elipse del 90 % de confianza? Para saber, simplemente, reemplazamos $\mu_1 = 4$, $\mu_2 = 50$, $\mu_3 = 10$ en la **elipse anterior** y obtenemos 9,6644. Evidentemente,

$$9,6644 \not\leq 8,174$$

Evaluación del Vector Hipotético

$$20[4,64 - \mu_1, 45,40 - \mu_2, 9,96 - \mu_3] \begin{bmatrix} 0,586 & -0,022 & 0,258 \\ -0,022 & 0,006 & -0,002 \\ 0,258 & -0,002 & 0,402 \end{bmatrix} \begin{bmatrix} 4,64 - \mu_1 \\ 45,40 - \mu_2 \\ 9,96 - \mu_3 \end{bmatrix} \leq \frac{19 \times 3}{17}(2,44) = 8,174$$

¿Cae $\mu_0 = [4, 50, 10]^T$ dentro de la elipse del 90 % de confianza? Para saber, simplemente, reemplazamos $\mu_1 = 4$, $\mu_2 = 50$, $\mu_3 = 10$ en la elipse anterior y obtenemos 9,6644. Evidentemente,

$$9,6644 \not\leq 8,174$$

es decir, el vector $\mu_0 = [4, 50, 10]^T$ NO cae dentro de la región y por lo tanto se rechaza H_0 . En consecuencia, $\mu_0 = [4, 50, 10]^T$ NO es un valor plausible para μ .

Intervalos de Confianza Simultáneos

- Las regiones de confianza proporcionan un conocimiento conjunto sobre los valores plausibles para μ .
- Generalmente, las **conclusiones en los estudios también suelen incluir afirmaciones sobre las componentes individuales** del vector de medias.
- En ese caso, necesitamos **construir intervalos individuales** para cada componente del vector de media de forma tal que **simultáneamente** cada uno de ellos contenga a su media bajo una probabilidad especificada.

Esta clase de intervalos son llamados **intervalos de confianza simultáneos**.