

Análisis Multivariado

Introducción: ¿Cómo describir datos multivariados?

Profesora: Diana Marcela Martínez Ruiz

30 de julio de 2026

- 1 Panorama de los métodos multivariados
- 2 Presentación y visualización de los datos
- 3 Representación gráfica de datos multivariados
- 4 Vectores aleatorios
- 5 Distribuciones conjuntas, marginales y condicionales

¿Qué es el Análisis Multivariado?

Definición

El **Análisis Multivariado** es un área de la Estadística que busca estudiar y desarrollar métodos que permitan **describir y analizar datos multivariados**.

¿Qué son datos multivariados?

Son datos en los que **se observan varias características** de cada unidad de la muestra.

Ejemplo: una empresa eléctrica desea identificar los factores que influyen en el consumo mensual de energía eléctrica en una ciudad:

- Consumo mensual de electricidad (en kWh),
- Número de personas que viven en el hogar,
- Área de la vivienda (en metros cuadrados), entre otras.

Ejemplo: consumo de energía eléctrica

- las **unidades muestrales** son las **viviendas**,
- las **variables** están **correlacionadas**; por ejemplo, el “consumo mensual de electricidad (kWh)” puede estar relacionado con el “área de la vivienda”.

Esa **correlación** entre las variables conlleva al estudio del **comportamiento conjunto y condicional** entre ellas.

	Consumo	Personas	Área
Hogar 1	x_{11}	x_{12}	x_{1p}
$\vdots$	$\vdots$	$\vdots$	$\vdots$
Hogar j	x_{j1}	x_{j2}	x_{jp}
$\vdots$	$\vdots$	$\vdots$	$\vdots$
Hogar n	x_{n1}	x_{n2}	x_{np}

Observación: aquí se tienen $p = 3$ variables y n unidades muestrales.

- El **análisis multivariado** corresponde a una **variedad de métodos/técnicas** que **involucran simultáneamente a todas (o parte de) las variables** en la interpretación del conjunto de datos.
- Existen varios **métodos** con **finalidades muy diferentes**. La **determinación** de cada método **depende de los objetivos de la investigación** o del conocimiento que se pretenda generar. Se debe tener precaución al elegir las técnicas más adecuadas para detectar los patrones esperados en los datos y comprender las limitaciones de estos análisis.
- En general, el análisis multivariado es un análisis de tipo **exploratorio**, utilizado para **generar hipótesis** y no para proporcionar confirmaciones sobre las mismas.

Objetivos específicos de los métodos multivariados

- ➊ **Reducir los datos o su dimensionalidad:** representar los datos de la forma más simple posible sin pérdida de información.
- ➋ **Agrupar y ordenar:** crear grupos de objetos o de variables que sean “similares”.
- ➌ **Clasificar:** generar reglas para clasificar objetos dentro de grupos bien definidos.
- ➍ **Investigar la dependencia entre variables:** generalmente las variables de interés están correlacionadas.
- ➎ **Predecir:** una vez establecidas las relaciones entre las variables, predecir los valores de una o más variables con base en las observaciones de las demás.
- ➏ **Construir pruebas de hipótesis:** validar supuestos o reforzar convicciones a priori.

Panorama: principales técnicas multivariadas (I)

- **Análisis de Componentes Principales (PCA):** técnica de reducción de datos cuyo objetivo es construir combinaciones lineales (no correlacionadas entre sí) de las variables originales (componentes principales) que contengan gran parte de la variabilidad total original.
- **Análisis de Agrupamiento, Conglomerados o *Cluster*:** técnica de reducción de datos cuyo objetivo es identificar un número pequeño de grupos, donde las observaciones de cada grupo sean similares (respecto a alguna medida de distancia) y muy diferentes a las de los otros grupos.
- **Análisis Discriminante:** técnica análoga a la regresión donde la variable dependiente (respuesta) es categórica (grupos predefinidos) y las independientes (regresoras) son continuas. Busca relaciones (lineales o no) entre las variables independientes que mejor discriminen a los grupos.
- **Análisis Factorial:** reduce la dimensionalidad de los datos agrupando variables altamente correlacionadas en factores comunes, facilitando la interpretación y el análisis.

Panorama: principales técnicas multivariadas (II)

- **Análisis de Correlación Canónica:** identifica y cuantifica la asociación entre *dos conjuntos* de variables, mediante combinaciones lineales de las variables de cada grupo (variables canónicas) que maximizan la correlación entre ellas (correlación canónica).
- **Análisis de Correspondencia:** técnica descriptiva/exploratoria diseñada para el análisis de tablas de contingencia que contienen algún tipo de correspondencia entre sus filas y columnas.
- **Árboles de Clasificación/Decisión:** representación de un conjunto de reglas para tomar decisiones: clasificar un registro (clasificación) o estimar un valor (regresión). En cada pregunta del árbol se responde “SÍ” o “NO” hasta llegar a la decisión final.
- **Regresión Lineal y NO Lineal:** centrada en la relación entre una variable dependiente (respuesta) y un conjunto de variables regresoras/predictoras. El objetivo es medir el efecto de cada regresora sobre la respuesta (regresión múltiple, análisis de varianza, logística, etc.).

Dos familias de métodos y tipos de aprendizaje

- (**Regresión Lineal, Análisis Factorial, Análisis Discriminante**) se enfocan en problemas donde hay variables independientes (regresoras, predictoras, explicativas) y variables dependientes (respuesta).
- (**Componentes Principales, Agrupamiento, Correlaciones Canónicas, Correspondencia**) centran su objetivo en estudiar la variabilidad de los datos de forma multivariada (*no hay variable respuesta*), principalmente con interés en reducir la dimensionalidad.

Aprendizaje supervisado vs. no supervisado

- Use **aprendizaje supervisado** cuando tenga **datos etiquetados** y el interés sea hacer predicciones. *Ejemplo:* imágenes de animales donde cada una está clasificada como perro, gato, caballo, etc.; el modelo aprende de esas etiquetas para predecir nuevas etiquetas.
- Use **aprendizaje NO supervisado** cuando sus datos no estén etiquetados: el modelo debe descubrir patrones o estructuras por sí mismo, agrupando observaciones similares o identificando las más diferentes.

- **Tipos de datos:** los datos recolectados pueden provenir de:
 - **Experimentos:** a través de diseños experimentales (datos experimentales).
 - **Observaciones:** se recoge la información existente (datos observacionales).
- **Presentación de los datos** (su objetivo es facilitar el análisis): **tablas, arreglos matriciales, medidas de resumen o descriptivas y gráficos.**

Suponga que se observan $p \geq 1$ variables en n unidades muestrales: x_{jk} es la medida de la k -ésima variable en la j -ésima unidad muestral, $j = 1, \dots, n$; $k = 1, \dots, p$.

La matriz de datos

Podemos organizar los datos en una matriz $\mathbf{X}$ de n filas y p columnas:

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1k} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2k} & \cdots & x_{2p} \\ \vdots & \vdots & & \vdots & & \vdots \\ x_{j1} & x_{j2} & \cdots & x_{jk} & \cdots & x_{jp} \\ \vdots & \vdots & & \vdots & & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nk} & \cdots & x_{np} \end{bmatrix}_{n \times p}$$

- Cada **fila** contiene la información de una unidad muestral: **cada fila es una observación multivariada**.
- Cada **columna** contiene la información de una variable.
- Para manipular gran cantidad de variables/datos y “relajar” la matemática subyacente de las técnicas multivariadas, usaremos **conceptos algebraicos** (vectores y matrices).

Análisis univariado de cada columna

Si extraemos de $\mathbf{X}$ la información de la k -ésima variable, ésta puede almacenarse en un vector columna

$$\mathbf{x}_k = \begin{bmatrix} x_{1k} \\ x_{2k} \\ \vdots \\ x_{nk} \end{bmatrix}_{n \times 1}$$

y analizarse individualmente (análisis **univariado**), calculando estadísticas descriptivas de **localización, dispersión, asimetría y curtosis**.

Medidas univariadas: localización y dispersión

Media muestral (localización)

$$\bar{x}_k = \frac{1}{n} \sum_{j=1}^n x_{jk}, \quad k = 1, 2, \dots, p$$

Varianza muestral (dispersión)

$$s_k^2 = \frac{1}{n-1} \sum_{j=1}^n (x_{jk} - \bar{x}_k)^2$$

Desviación estándar muestral

Medida de dispersión con las mismas unidades de los datos: $s_k = \sqrt{s_k^2}$.

Coeficiente de asimetría muestral

Describe la asimetría de la distribución de los datos respecto a la media muestral:

$$sk(x_k) = \frac{\sqrt{n} \sum_{j=1}^n (x_{jk} - \bar{x}_k)^3}{\left[\sum_{j=1}^n (x_{jk} - \bar{x}_k)^2 \right]^{3/2}}$$

Observación:

- Datos de distribuciones simétricas: $sk(x_k) \approx 0$.
- $sk(x_k) > 0$: distribución asimétrica positiva o a derecha.
- $sk(x_k) < 0$: distribución asimétrica negativa o a izquierda.


Medidas univariadas: curtosis

Coeficiente de curtosis muestral

Describe el comportamiento en las colas de la distribución de los datos:

$$k(x_k) = \frac{n \sum_{j=1}^n (x_{jk} - \bar{x}_k)^4}{\left[\sum_{j=1}^n (x_{jk} - \bar{x}_k)^2 \right]^2}$$

- Datos de una distribución **normal**: $k(x_k) \approx 3$.
- $k(x_k) > 3$: distribución **leptocúrtica**.
- $k(x_k) < 3$: distribución **platicúrtica**.



Covarianza muestral

Medida de **asociación lineal** entre **dos variables** ($i, k = 1, \dots, p; i \neq k$):

$$s_{ik} = \frac{1}{n-1} \sum_{j=1}^n (x_{ji} - \bar{x}_i) (x_{jk} - \bar{x}_k)$$

Observación:

- $s_{ik} = 0$: **no hay asociación lineal** entre las dos variables.
- $s_{ik} > 0$: **asociación lineal positiva**.
- $s_{ik} < 0$: **asociación lineal negativa**.
- $s_{ii} = s_i^2$ es la **varianza muestral** de la i -ésima variable (covarianza de la variable con ella misma).

La covarianza indica la relación lineal; sin embargo, **NO proporciona la magnitud de esa relación**.

Correlación muestral

Medida de correlación lineal entre la i -ésima y la k -ésima variable:

$$r_{ik} = \frac{s_{ik}}{\sqrt{s_i^2} \sqrt{s_k^2}} = \frac{\sum_{j=1}^n (x_{ji} - \bar{x}_i)(x_{jk} - \bar{x}_k)}{\sqrt{\sum_{j=1}^n (x_{ji} - \bar{x}_i)^2} \sqrt{\sum_{j=1}^n (x_{jk} - \bar{x}_k)^2}}$$

Observaciones:

- $-1 \leq r_{ik} \leq 1$.
- $r_{ik} \approx 1$: correlación lineal **positiva fuerte**.
- $r_{ik} \approx -1$: correlación lineal **negativa fuerte**.
- $r_{ik} \approx 0$: **NO** hay correlación lineal.

Arreglos muestrales: $\bar{\mathbf{x}}$, $\mathbf{S}$ y $\mathbf{R}$

Las medias muestrales se agrupan en el **vector de medias**; las varianzas y covarianzas, en la **matriz de varianzas y covarianzas muestral**; y las correlaciones, en la **matriz de correlaciones muestral**:

$$\bar{\mathbf{x}} = \begin{bmatrix} \bar{x}_1 \\ \bar{x}_2 \\ \vdots \\ \bar{x}_p \end{bmatrix}_{p \times 1}, \quad \mathbf{S} = \begin{bmatrix} s_{11} & s_{12} & \cdots & s_{1p} \\ s_{21} & s_{22} & \cdots & s_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ s_{p1} & s_{p2} & \cdots & s_{pp} \end{bmatrix}_{p \times p}, \quad \mathbf{R} = \begin{bmatrix} 1 & r_{12} & \cdots & r_{1p} \\ r_{21} & 1 & \cdots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \cdots & 1 \end{bmatrix}_{p \times p}$$

Observe que:

- en la diagonal de $\mathbf{S}$ están las varianzas y por fuera de la diagonal las covarianzas,
- las matrices $\mathbf{S}$ y $\mathbf{R}$ son **simétricas**.

Ejemplo 1 (Johnson & Wichern, Ej. 1.1, p. 6)

En una librería universitaria se recolectó información sobre 4 registros de ventas de libros, con el objetivo de investigar la naturaleza de las ventas:

Valor total de ventas	No. de libros vendidos
42	4
52	5
48	4
58	3

Ejemplo 1 (Johnson & Wichern, Ej. 1.1, p. 6)

En una librería universitaria se recolectó información sobre 4 registros de ventas de libros, con el objetivo de investigar la naturaleza de las ventas:

Valor total de ventas	No. de libros vendidos
42	4
52	5
48	4
58	3

Se tienen $p = 2$ variables y $n = 4$ unidades muestrales; la matriz de datos es

$$\mathbf{X} = \begin{bmatrix} 42 & 4 \\ 52 & 5 \\ 48 & 4 \\ 58 & 3 \end{bmatrix}_{4 \times 2}$$

Medias muestrales:

$$\bar{x}_1 = \frac{1}{4}(42 + 52 + 48 + 58) = 50, \quad \bar{x}_2 = \frac{1}{4}(4 + 5 + 4 + 3) = 4 \Rightarrow \bar{\mathbf{x}} = \begin{bmatrix} 50 \\ 4 \end{bmatrix}$$

Medias muestrales:

$$\bar{x}_1 = \frac{1}{4}(42 + 52 + 48 + 58) = 50, \quad \bar{x}_2 = \frac{1}{4}(4 + 5 + 4 + 3) = 4 \Rightarrow \bar{\mathbf{x}} = \begin{bmatrix} 50 \\ 4 \end{bmatrix}$$

Varianzas muestrales:

$$s_1^2 = \frac{1}{3}[(42 - 50)^2 + \cdots + (58 - 50)^2] = 45,33, \quad s_2^2 = \frac{1}{3}[(4 - 4)^2 + \cdots + (3 - 4)^2] = 0,67$$

Medias muestrales:

$$\bar{x}_1 = \frac{1}{4}(42 + 52 + 48 + 58) = 50, \quad \bar{x}_2 = \frac{1}{4}(4 + 5 + 4 + 3) = 4 \Rightarrow \bar{\mathbf{x}} = \begin{bmatrix} 50 \\ 4 \end{bmatrix}$$

Varianzas muestrales:

$$s_1^2 = \frac{1}{3}[(42 - 50)^2 + \cdots + (58 - 50)^2] = 45,33, \quad s_2^2 = \frac{1}{3}[(4 - 4)^2 + \cdots + (3 - 4)^2] = 0,67$$

Covarianza y correlación muestrales:

$$s_{12} = \frac{1}{3}[(42 - 50)(4 - 4) + \cdots + (58 - 50)(3 - 4)] = -2, \quad r_{12} = \frac{-2}{\sqrt{45,33}\sqrt{0,67}} = -0,36$$

Medias muestrales:

$$\bar{x}_1 = \frac{1}{4}(42 + 52 + 48 + 58) = 50, \quad \bar{x}_2 = \frac{1}{4}(4 + 5 + 4 + 3) = 4 \Rightarrow \bar{\mathbf{x}} = \begin{bmatrix} 50 \\ 4 \end{bmatrix}$$

Varianzas muestrales:

$$s_1^2 = \frac{1}{3}[(42 - 50)^2 + \cdots + (58 - 50)^2] = 45,33, \quad s_2^2 = \frac{1}{3}[(4 - 4)^2 + \cdots + (3 - 4)^2] = 0,67$$

Covarianza y correlación muestrales:

$$s_{12} = \frac{1}{3}[(42 - 50)(4 - 4) + \cdots + (58 - 50)(3 - 4)] = -2, \quad r_{12} = \frac{-2}{\sqrt{45,33}\sqrt{0,67}} = -0,36$$

$$\mathbf{S} = \begin{bmatrix} 45,33 & -2 \\ -2 & 0,67 \end{bmatrix}, \quad \mathbf{R} = \begin{bmatrix} 1 & -0,36 \\ -0,36 & 1 \end{bmatrix}$$

Ejemplo 1: cálculo en R

```
# --- Ingresamos los datos --- #
X <- matrix ( c (42 ,52 ,48 ,58 , 4 ,5 ,4 ,3) , ncol = 2 , nrow = 4)
X <- data.frame ( X )
colnames(X)<- c("Ventas","No.Libros")
# --- Vector de medias muestrales --- #
x_media <- apply (X , 2 , mean ) # Ventas = 50 , No . Libros = 4
# --- Matriz de varianzas y covarianzas muestral --- #
S <- cov (X) # diag : 45.33 , 0.67 ; s12 = -2
# --- Matriz de correlacion muestral --- #
R <- cor ( X ) # r12 = -0.3638
# --- Coeficientes de asimetria y curtosis --- #
install.packages("moments")
require ( moments )
skewness (X$Ventas);skewness (X$No.Libros) # 0 y 0
kurtosis (X$Ventas) ; kurtosis (X$No.Libros) # 1.78 y 2
```

Realizamos los mismos cálculos con la base de datos de olimpiadas.

Gráficos unidimensionales

Se pueden construir **gráficos** hasta para 3 variables (tridimensionales). Dentro de los **gráficos unidimensionales** (variables individuales) más recomendados están:

- **Gráfico de puntos:** Recomendado para **variables cuantitativas discretas**, principalmente cuando el conjunto de datos es razonablemente pequeño o existen pocos valores distintos.
- **Histograma:** Recomendado para **muestras moderadas o grandes**.
- **Boxplot (diagrama de caja y bigotes):** Basado en los **cuartiles**; recomendado para muestras moderadas o grandes; permite detectar **valores extremos, discrepantes u outliers** y es útil para **comparar varios conjuntos de datos**.

Todos proporcionan información sobre el **centro**, la **dispersión** y la **forma** de la distribución de los datos.

Gráficos bidimensionales

Los **gráficos bidimensionales** (pares de variables) informan sobre la orientación de los datos en el plano y la asociación entre ellos. El **diagrama de dispersión** (*scatter plot*) es el más usado: cada eje representa una variable. **Ejemplo** usando mtcars: Los datos se extrajeron de la revista Motor Trend de Estados Unidos de 1974 y comprenden el consumo de combustible y 10 aspectos del diseño y el rendimiento de 32 automóviles.

Variable	Descripción
mpg	Millas por galón (EE. UU.)
cyl	Número de cilindros
disp	Cilindrada (pulgadas cúbicas)
hp	Potencia bruta (caballos de fuerza)
drat	Relación del eje trasero
wt	Peso (1000 libras)
qsec	Tiempo en 1/4 de milla
vs	Motor (0 = en V, 1 = en línea)
am	Transmisión (0 = automática, 1 = manual)
gear	Número de marchas hacia adelante
carb	Número de carburadores

Cuadro 1: Descripción de las variables del conjunto de datos.

Diagrama de dispersión





Figura 2: Gráfico de dispersión

Para el estudio de aspectos **tridimensionales** (o de más variables):

- **Matrices de dispersión**
- **Representaciones pictóricas** (estrellas, caras de Chernoff)
- **Diagramas de dispersión 3D con rotación** (*spinning 3D scatterplots*): visualizan la relación entre tres o más variables.
- **Coordenadas paralelas y curvas de Andrews**: cada observación se representa como una línea o curva.

Matriz de dispersión

Matriz de dispersión (múltiples diagramas de dispersión): presentan conjuntamente todos los diagramas de dispersión para cada par de variables.



```
pairs(~mpg+disp+hp+drat+wt+qsec, data=mtcars, pch=16, col="deepskyblue")
```

Representaciones pictóricas (estrellas, caras de Chernoff): se emplean para reconocer observaciones similares, por lo que las variables deben estar medidas en la misma escala.

Caras de Chernoff

- Se recomiendan para n pequeño.
- Cada unidad muestral se representa por una cara; cada característica (ojos, boca, cejas, etc.) describe una variable.
- Útil para agrupar unidades muestrales y detectar posibles outliers.

Caras de Chernoff

Modified item	Var
height of face	mpg
width of face	cyl
structure of face	disp
height of mouth	hp
width of mouth	wt
smiling	mpg
height of eyes	cyl
width of eyes	disp
height of hair	hp
width of hair	wt
style of hair	mpg
height of nose	cyl
width of nose	disp
width of ear	hp
height of ear	wt

Caras de Chernoff con variables estandarizadas





Gráfico de estrellas o radar


- Se recomienda para n y p pequeños.
- Se muestra una estrella por observación, con tantos rayos o ejes como variables haya.
- Las longitudes de los rayos son proporcionales a los valores de las variables (la leyenda indica la orientación de cada variable).
- Útil para agrupar unidades muestrales

Gráfico de estrellas o radar



Empezando desde arriba, el orden de los rayos sigue el orden de las columnas.

Comparación de dos automóviles



De la muestra a la población: vectores aleatorios

Los datos muestrales $\mathbf{X} = [\mathbf{x}_1 \quad \mathbf{x}_2 \quad \cdots \quad \mathbf{x}_p]$ provienen de alguna **población p -variada**. Denotamos por

$$\mathbf{X}_{p \times 1} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_k \\ \vdots \\ X_p \end{bmatrix}$$

al **vector aleatorio** que contiene las p variables aleatorias.

- Cada observación multivariada (fila de la matriz de datos) es una realización de $\mathbf{X}$.
- Su comportamiento se describe mediante distribuciones *marginales*, *conjuntas por pares* y la *conjunta completa*.



Comportamiento marginal de cada variable

✓ Cada **variable aleatoria** X_i ($i = 1, 2, \dots, p$) tiene su propia **distribución** de probabilidad (**marginal**) que permite estudiar su comportamiento; por ejemplo:

- su **media poblacional**:

$$\mu_i = E[X_i]$$

- su **varianza poblacional**:

$$\sigma_i^2 = \text{Var}[X_i] = E[(X_i - \mu_i)^2]$$

Comportamiento conjunto por pares

✓ El comportamiento conjunto de **cada par de variables aleatorias**, digamos X_i y X_k ($i, k = 1, \dots, p, i \neq k$), está descrito por su **función de probabilidad conjunta**, que permite estudiar las **asociaciones lineales** entre ellas:

- **Covarianza poblacional:**

$$\sigma_{ik} = \text{Cov}[X_i, X_k] = \text{E}[(X_i - \mu_i)(X_k - \mu_k)]$$

- **Correlación poblacional:**

$$\rho_{ik} = \frac{\sigma_{ik}}{\sqrt{\sigma_i^2} \sqrt{\sigma_k^2}}$$

Distribución conjunta e independencia

✓ El comportamiento conjunto de las p variables aleatorias $X_1, X_2, \dots, X_p$ está descrito por la **función de densidad de probabilidad conjunta** (fdpc):

$$f_{\mathbf{X}}(\mathbf{x}) = f_{\mathbf{X}}(x_1, x_2, \dots, x_k, \dots, x_p)$$

Independencia

Si las X_i 's son **mutuamente independientes**, entonces

$$f_{\mathbf{X}}(\mathbf{x}) = f_{X_1}(x_1) f_{X_2}(x_2) \cdots f_{X_k}(x_k) \cdots f_{X_p}(x_p)$$

y las covarianzas son cero (**lo contrario no necesariamente es cierto**).

Parámetros poblacionales: vector de medias

Algunas características poblacionales (parámetros) de interés:

✓ **Vector de medias poblacional:**

$$\boldsymbol{\mu}_{p \times 1} = E[\mathbf{X}] = E \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_k \\ \vdots \\ X_p \end{bmatrix} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_k \\ \vdots \\ \mu_p \end{bmatrix}_{p \times 1}$$

donde $\mu_k = E[X_k]$ es la media poblacional (marginal) de la k -ésima variable, $k = 1, 2, \dots, p$.

✓ Matriz de varianzas y covarianzas poblacional:

$$\Sigma_{p \times p} = E[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top] = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_{pp} \end{bmatrix}_{p \times p}$$

donde:

- $\sigma_{kk} = \sigma_k^2 = E[(X_k - \mu_k)^2]$ es la **varianza poblacional (marginal)** de la k -ésima variable, $k = 1, \dots, p$;
- $\sigma_{ik} = E[(X_i - \mu_i)(X_k - \mu_k)]$ es la **covarianza poblacional** entre la i -ésima y la k -ésima variable, $i \neq k = 1, \dots, p$.

Parámetros poblacionales: matriz $\mathbf{P}$ y su relación con Σ

Matriz de correlación poblacional:

$$\mathbf{P}_{p \times p} = \begin{bmatrix} 1 & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{21} & 1 & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \cdots & 1 \end{bmatrix}, \quad \rho_{ik} = \frac{\sigma_{ik}}{\sqrt{\sigma_{ii}}\sqrt{\sigma_{kk}}}$$

Densidad conjunta

Para un vector aleatorio continuo $\mathbf{X} = (X_1, \dots, X_p)'$, la densidad conjunta $f(x_1, \dots, x_p)$ satisface $f \geq 0$ y $\int_{\mathbb{R}^p} f d\mathbf{x} = 1$, y describe completamente el comportamiento probabilístico simultáneo de las p variables.

El ejemplo central del curso es la **normal multivariada** $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$:

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} |\boldsymbol{\Sigma}|^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right\}$$

cuyos contornos de densidad constante son elipsoides centrados en $\boldsymbol{\mu}$.

Marginal: distribución de un subconjunto de componentes, ignorando las demás. Se obtiene integrando la conjunta:

$$f_{X_1}(x_1) = \int f(x_1, x_2) dx_2$$

Si particionamos $\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix}$, $\boldsymbol{\mu} = \begin{bmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{bmatrix}$, $\boldsymbol{\Sigma} = \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{bmatrix}$ y $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, la marginal es también normal:

$$\mathbf{X}_1 \sim N_q(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_{11})$$

¡Cuidado!

Las marginales **no** determinan la conjunta: distintas conjuntas pueden tener las mismas marginales (marginales normales no garantizan normalidad conjunta).

Distribuciones condicionales e independencia

Condicional: distribución de unas componentes dado el valor observado de otras:

$$f(x_1 | x_2) = \frac{f(x_1, x_2)}{f_{X_2}(x_2)}$$

En el caso normal multivariado, $\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2$ es normal con

$$E(\mathbf{X}_1 | \mathbf{x}_2) = \boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2), \quad \text{Cov}(\mathbf{X}_1 | \mathbf{x}_2) = \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}$$

(¡la media condicional es lineal en $\mathbf{x}_2$: base de la regresión!)

Independencia

X_1 y X_2 son independientes $\iff f(x_1, x_2) = f_{X_1}(x_1)f_{X_2}(x_2)$. Independencia $\Rightarrow$ covarianza cero; el recíproco solo es válido bajo normalidad conjunta.

- El análisis multivariado describe y analiza datos donde se observan varias características (correlacionadas) por unidad muestral, organizadas en una matriz $n \times p$.
- Es principalmente **exploratorio** (genera hipótesis); sus objetivos: reducir dimensionalidad, agrupar/ordenar, clasificar, investigar dependencia, predecir y construir pruebas de hipótesis.
- El panorama de métodos incluye PCA, conglomerados, discriminante, factorial, correlación canónica, correspondencia, árboles y regresión, organizados según haya o no variable respuesta (aprendizaje supervisado vs. no supervisado).
- Las medidas de resumen muestrales ($\bar{x}$, $\mathbf{S}$, $\mathbf{R}$, asimetría y curtosis) y los gráficos (puntos, histograma, boxplot, dispersión, matriz de dispersión, coordenadas paralelas, estrellas, caras de Chernoff, 3D) permiten describir los datos.
- A nivel poblacional, el vector aleatorio $\mathbf{X}$ se resume con $\boldsymbol{\mu}$, $\boldsymbol{\Sigma}$ y $\mathbf{P}$, con $\boldsymbol{\Sigma} = \mathbf{V}^{1/2} \mathbf{P} \mathbf{V}^{1/2}$.
- Conjunta, marginales y condicionales describen niveles distintos de la estructura probabilística; independencia implica covarianza cero, pero no al revés (salvo normalidad conjunta).

- **Johnson, R. y Wichern, D.W. *Applied Multivariate Statistical Analysis*. Prentice Hall.** (Texto guía; Ejemplo 1.1, p. 6; gráficos de estrellas, pp. 26–27.)
- Mardia, K.V.; Kent, J.T. y Bibby, J.M. *Multivariate Analysis*. Academic Press.
- Morrison, D.F. *Multivariate Statistical Methods*. McGraw-Hill.
- Peña, D. *Análisis Multivariado de Datos*. McGraw-Hill.
- Rencher, A.C. *Multivariate Statistical Inference and Applications*. John Wiley and Sons.
- Srivastava, M.S. *Methods of Multivariate Statistics*. John Wiley and Sons.
- Fisher, R.A. (1936). The use of Multiple Measurements in Taxonomic Problems. *Annals of Eugenics*, 7, 179–188.