

Distribución Normal Multivariada - Parte 2

Profesora: Diana Marcela Martínez Ruiz

Facultad de Ciencias — Departamento de Matemáticas
Pontificia Universidad Javeriana

Semestre 2630 — 2026

Propiedad Importante:

- Si $X \sim \mathcal{N}_p(\mu, \Sigma)$ y si $Z = \Sigma^{-1/2}(X - \mu)$, entonces $Z \sim \mathcal{N}_p(0, I_p)$.
- De lo anterior se tiene:

$$(X - \mu)^\top \Sigma^{-1} (X - \mu) = \sum_{i=1}^p Z_i^2 \sim \chi_p^2$$

Observación:


- La cantidad $(X - \mu)^\top \Sigma^{-1}(X - \mu)$ es llamada **Distancia de Mahalanobis** entre X y μ . Note que ésta es una distancia (cuadrática) entre dos vectores, que es ponderada por Σ^{-1} .
- Esa ponderación se hace necesaria cuando las variables en X tienen magnitudes muy diferentes y en casos consecuencias varianzas muy diferentes. Si en esos casos no se hace esa ponderación (estandarización), las variables con mayor varianza podrían dominar esa distancia.
- Si las distancias de Mahalanobis observadas o muestrales, $d_i^2 = (X - \bar{x})^\top \Sigma^{-1}(X - \bar{x})$, se ajustan a una distribución χ_p^2 tendremos indicios o sospechas sobre la normalidad multivariada de X .

Distribución Normal Multivariada

Vamos a verificar la distribución de distancia de Mahalanobis en R:

```
# Distribucion de la Distancia de Mahalanobis
require(MASS)
mu<-c(0,0)
sigma<-matrix(c(2,1,1,2),ncol=2)
n<-500
x<-mvrnorm(n,mu,sigma)
xbarra<-colMeans(x)
S<-cov(x)
dm<-mahalanobis(x,xbarra,S)
cuantiles<-qchisq(ppoints(length(dm)), df=2)
qqplot(cuantiles,dm)
abline(0,1)
```

Distribución Normal Multivariada



Recordemos que la ecuación de una elipse:

$$(x - h)^T A (x - h) = 1$$

- $h = [h_1, h_2]^T$ es el centro del elipsoide.
- A es una matriz simétrica definida positiva que determina la forma y orientación del elipsoide.
- Los autovalores de A están relacionados con el tamaño de los ejes del elipsoide.
- Los autovectores de A determinan la dirección de los ejes principales.

Note que en el exponente se tiene la forma geométrica de una elipse. Sea

$$\{x : (x - \mu)^\top \Sigma^{-1}(x - \mu) = c^2, c > 0\}$$

el conjunto de todos los puntos x cuya distancia a μ es constante. Entonces, la densidad de la normal multivariada es constante sobre superficies donde la distancia cuadrática es constante. Estos conjuntos de puntos son llamados **contornos**.

Ejemplo 3: Obtenga los ejes de los contornos de densidad de probabilidad constante de una distribución normal bivariada tal que $\sigma_{11} = \sigma_{22}$.

Obtención de los Ejes de los Contornos de Densidad Constante

Los contornos de densidad constante de una distribución normal bivariada son elipses definidas por el conjunto de puntos x que cumplen la ecuación de la distancia de Mahalanobis:

$$(x - \mu)^\top \Sigma^{-1} (x - \mu) = c^2$$

Estas elipses están centradas en el vector de medias μ . Su forma, tamaño y orientación dependen exclusivamente de la estructura de la matriz de varianzas y covarianzas Σ .

Relación con autovalores y autovectores

Los ejes de la elipse están determinados por los autovalores (λ_i) y autovectores (e_i) de Σ :

- **Dirección:** Los autovectores e_1 y e_2 indican la dirección de los ejes principales.
- **Longitud:** La longitud de los semiejes es proporcional a $\sqrt{\lambda_1}$ y $\sqrt{\lambda_2}$. Los extremos de los ejes se encuentran en $\pm c\sqrt{\lambda_i}e_i$.

Caso específico: $\sigma_{11} = \sigma_{22} = \sigma^2$

Cuando las varianzas son iguales, la matriz de covarianza tiene la forma:

$$\Sigma = \begin{pmatrix} \sigma^2 & \sigma_{12} \\ \sigma_{12} & \sigma^2 \end{pmatrix}$$

❶ **Cálculo de autovalores:** Resolviendo $\det(\Sigma - \lambda I) = 0$:

$$(\sigma^2 - \lambda)^2 - \sigma_{12}^2 = 0 \implies \lambda_1 = \sigma^2 + \sigma_{12}, \quad \lambda_2 = \sigma^2 - \sigma_{12}$$

❷ **Cálculo de autovectores:** Resolviendo $(\Sigma - \lambda_i I)e_i = 0$, obtenemos:

$$e_1 = \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}, \quad e_2 = \begin{pmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \end{pmatrix}$$

- **Eje mayor:** Si $\sigma_{12} > 0$, el eje mayor está alineado con e_1 (recta de 45°) con longitud proporcional a $\sqrt{\sigma^2 + \sigma_{12}}$.
- **Eje menor:** El eje menor está alineado con e_2 (recta perpendicular de -45°) con longitud proporcional a $\sqrt{\sigma^2 - \sigma_{12}}$.

Gráfico de Contornos: Se intercepta a la densidad bivariada con un plano que tiene una elipse pequeña, la cual se hace más grande en la medida que se baja ese plano.

```
# Grafico de Contornos
```

```
contour(x1, x2, f, draw=T, nlevels=20, labcex=0.8,  
        xlab=expression(x[1]), ylab=expression(x[2]))
```

Distribución Normal Multivariada




Figura 4.3 de Johnson and Wichern (2013) - Applied Multivariate Statistical Analysis, pp. 154

Visualización con la función `contour()`

La función `contour()` permite proyectar una densidad bivariada en un plano 2D mediante líneas de nivel:

```
contour(x1, x2, f, draw=T, nlevels=20, labcex=0.8,  
        xlab=expression(x[1]), ylab=expression(x[2]))
```

Desglose de argumentos:

- `x1, x2, f`: Coordenadas y matriz de densidades (creada con `outer`).
- `nlevels=20`: Número de curvas de nivel a representar.
- `labcex=0.8`: Tamaño de fuente para las etiquetas de los niveles.
- `expression(x[1])`: Permite usar notación matemática (x_1, x_2) en los ejes.

Interpretación: Las curvas cerradas indican zonas de igual probabilidad. El centro de la elipse representa la media μ , y su orientación revela la correlación ρ .

Salida esperada: Elipses concéntricas

Distribución Normal Multivariada

Si las observaciones fueran generadas por una distribución normal multivariada:

- Todas las distribuciones bivariadas deberían ser normales y los contornos de densidad constante deberían ser elipses.
- Para un α dado, se esperaría que alrededor del $\alpha\%$ de las observaciones caigan dentro de la elipse dada por:

$$\{x : (x - \bar{x})^\top \mathcal{S}^{-1}(x - \bar{x}) \leq \chi_2^2(\alpha)\}$$

Observación: Estas son verificaciones informales.

¿Cómo verificamos normalidad multivariada formalmente? Rta:
Probando las hipótesis:

H_0 : Los datos provienen de una población Normal Multivariada

H_1 : Los datos NO provienen de una población Normal Multivariada

Matemáticamente

$$H_0 : X_{p \times 1} \sim \mathcal{N}_p(\mu, \Sigma)$$

Existen varias estadísticas de pruebas y varios paquetes para probar estas hipótesis.

Distribución Normal Multivariada

```
# Prueba de Shapiro  
require(mvShapiroTest)  
mvShapiro.Test(X)
```

```
# Otras Pruebas  
require(MVN)  
mvn(X, mvnTest="mardia")      # test de Mardia  
mvn(X, mvnTest="hz")          # test de Henze-Zirkler  
mvn(X, mvnTest="royston")     # test de Royston  
mvn(X, mvnTest="dh")          # test de Doornik-Hansen
```

Veremos en detalle más adelante (próxima clase).

Ejercicio 1. Sea $Z = (Z_1, Z_2, Z_3)^T \sim \mathcal{N}_3(\nu, \Omega)$, donde $\nu = [1, 0, -2]^T$ y $\Omega = \begin{bmatrix} 5 & 2 & 0 \\ 2 & 4 & -1 \\ 0 & -1 & 3 \end{bmatrix}$.

- a) Determine la distribución marginal de Z_2 y Z_3 .
- b) Si $W = 2Z_1 + Z_2 - Z_3$, halle la distribución de W .
- c) Determine la distribución condicional de Z_3 dado que $Z_1 = 1$.

Ejercicio 2. Considere $X \sim \mathcal{N}_2(\mu, \Sigma)$, donde $\mu = [4, 1]^T$, $\Sigma = \begin{bmatrix} 3 & 0.5 \\ 0.5 & 2 \end{bmatrix}$.

- a) Calcule la distancia de Mahalanobis del punto $x = (7, 0)$.
- b) Genere 150 observaciones simuladas de $\mathcal{N}_2(\mu, \Sigma)$ en R y calcule sus distancias de Mahalanobis respecto a μ .
- c) Utilice un QQ-plot para verificar si siguen χ^2 con 2 grados de libertad.

Ejercicio 3. Considere $X \sim \mathcal{N}_2(\mu, \Sigma)$ donde $\mu = [1, -1]^T$, $\Sigma = \begin{bmatrix} 3 & 1 \\ 1 & 2 \end{bmatrix}$.

- a) Represente gráficamente los contornos de nivel de $f(x)$ utilizando `filled.contour()` en R.
- b) Calcule autovalores y autovectores de Σ e interprete geoméricamente.
- c) Determine la ecuación del contorno elíptico que encierra el 90% de la probabilidad.

Ejercicio 2 - Inciso a)

Problema: Calcule la distancia de Mahalanobis para $x = (7, 0)^\top$ con $\mu = [4, 1]^\top$ y $\Sigma = \begin{pmatrix} 3 & 0.5 \\ 0.5 & 2 \end{pmatrix}$.

Desarrollo:

- Diferencia: $(x - \mu) = \begin{pmatrix} 7 - 4 \\ 0 - 1 \end{pmatrix} = \begin{pmatrix} 3 \\ -1 \end{pmatrix}$
- Inversa de Σ : $|\Sigma| = 6 - 0.25 = 5.75$.

$$\Sigma^{-1} = \frac{1}{5.75} \begin{pmatrix} 2 & -0.5 \\ -0.5 & 3 \end{pmatrix}$$

- Distancia al cuadrado:

$$d^2 = (x - \mu)^\top \Sigma^{-1} (x - \mu) = \frac{1}{5.75} \begin{pmatrix} 3 & -1 \end{pmatrix} \begin{pmatrix} 2 & -0.5 \\ -0.5 & 3 \end{pmatrix} \begin{pmatrix} 3 \\ -1 \end{pmatrix}$$

$$d^2 = \frac{1}{5.75} \begin{pmatrix} 3 & -1 \end{pmatrix} \begin{pmatrix} 6.5 \\ -4.5 \end{pmatrix} = \frac{19.5 + 4.5}{5.75} = \frac{24}{5.75} \approx 4.174$$

Ejercicio 2 - Inciso b)

Simulación en R: Generación de 150 observaciones y cálculo de distancias.

```
library(MASS)
mu <- c(4, 1)
Sigma <- matrix(c(3, 0.5, 0.5, 2), ncol = 2)

# Simulación
set.seed(123)
X <- mvrnorm(n = 150, mu = mu, Sigma = Sigma)

# Cálculo de distancias (parámetros poblacionales)
dm <- mahalanobis(X, center = mu, cov = Sigma)
```

Ejercicio 2 - Inciso c)

Verificación con QQ-plot: Se espera que las distancias sigan una distribución χ^2 con $p = 2$ grados de libertad.

```
cuantiles <- qchisq(ppoints(length(dm)), df = 2)

qqplot(cuantiles, dm,
       main = "QQ-plot de distancias de Mahalanobis",
       xlab = "Cuantiles teóricos (Chi-sq df=2)",
       ylab = "Distancias observadas")
abline(0, 1, col = "red", lwd = 2)
```

Interpretación: Si los puntos se alinean sobre la recta roja ($y = x$), se tiene evidencia de que las observaciones provienen de una distribución Normal Multivariada.

Ejercicio 3 - Inciso a)

Gráfico de contornos en R:

```
mu <- c(1, -1)
Sigma <- matrix(c(3, 1, 1, 2), ncol = 2)

# Definir rango
x1 <- seq(-3, 5, length.out = 100)
x2 <- seq(-5, 3, length.out = 100)

# Calcular densidad
library(mvtnorm)
f <- outer(x1, x2, function(x, y) dmvnorm(cbind(x, y), mu, Sigma))

# Graficar
filled.contour(x1, x2, f, main = "Contornos de N(mu, Sigma)",
               xlab = "x1", ylab = "x2")
```


Ejercicio 3 - Incisos b) y c)

- **Autovalores:** $\lambda_1 \approx 3.618, \lambda_2 \approx 1.382$.

- **Autovectores:**

$$e_1 \approx \begin{pmatrix} 0.851 \\ 0.526 \end{pmatrix}, \quad e_2 \approx \begin{pmatrix} -0.526 \\ 0.851 \end{pmatrix}$$

- **Interpretación:** Los ejes de la elipse están orientados según e_1 y e_2 . La forma es alargada siguiendo la dirección de e_1 .
- **Contorno 90%:**

$$(x - \mu)^\top \Sigma^{-1} (x - \mu) = \chi_{2,0.90}^2 \approx 4.605$$

La elipse se centra en $\mu = (1, -1)^\top$ con semiejes determinados por $\sqrt{4.605 \cdot \lambda_i}$.