

Análisis Multivariado

Semana 3: Normal Multivariada: Evaluando Normal Multivariada

Profesora: Diana Marcela Martínez Ruiz

13 de agosto de 2026



- ¿Las distribuciones marginales de las variables del vector $\mathbf{X}_p$ tienen apariencia normal?
- ¿Los gráficos de dispersión de pares de variables tienen forma elíptica?
- ¿Hay observaciones atípicas que merezcan atención?

Las respuestas a estas preguntas permiten identificar si hay desviaciones de la suposición de normalidad multivariada, y en caso de haberlas la calidad de la inferencia de algunas técnicas multivariadas estará comprometida.

En notación estadística se plantean las siguientes hipótesis para contrastar formalmente si la distribución marginal de la variable X_j es normal.

$$H_0 : X_j \sim N_1(\mu_j, \sigma_j^2) \text{ v.s } H_1 : X_j \not\sim N_1(\mu_j, \sigma_j^2)$$

Sabemos que para ello están las siguiente pruebas estadísticas:

- Shapiro-Wilk.
- Kolmogorov-Sminoff.
- Anderson-Darling.
- Entre otras.

Las hipótesis son:

$$H_0 : \mathbf{X}_{2 \times 1} \sim N_2(\boldsymbol{\mu}_{2 \times 1}, \boldsymbol{\Sigma}_{2 \times 1}^2) \text{ v.s } H_1 : \mathbf{X}_{2 \times 1} \not\sim N_2(\boldsymbol{\mu}_{2 \times 1}, \boldsymbol{\Sigma}_{2 \times 1}^2)$$

Informalmente puede sospecharse que $\mathbf{X}_{2 \times 1}$ tiene una distribución normal bivariada a través de:

- Gráfico qq-plot
- Con las distancias de Mahalanobis.

Importante

La normalidad univariada o bivariada **NO** implican que el vector aleatorio $\mathbf{X}_{p \times 1}$ tenga una distribución multivariada. Es decir,

$$\text{Si } X_j \sim N_1(\mu_j, \sigma_j^2) \text{ o } \mathbf{X}_{2 \times 1} \sim N_2(\mu_{2 \times 1}, \Sigma_{2 \times 2}^2) \nRightarrow \mathbf{X}_{p \times 1} \sim N_p(\boldsymbol{\mu}_{p \times 1}, \Sigma_{p \times p}^2)$$

Pero,

Si las observaciones de $\mathbf{X}_{p \times 1}$ son generadas por una normal multivariada, **todas** las distribuciones **bivariadas** deberían ser normales y los **contornos** de densidad constante deberían ser **elipses**.

Con estudiar las distribuciones univariadas (marginales) y bivariadas de los elementos de $\mathbf{X}_{p \times 1}$ es, en ocasiones, suficiente para comprobar la suposición de normal multivariada.

Verificación empírica: De acuerdo con el Resultado 4.7. del Libro Wichern J. se tiene que:

Sea $\mathbf{X}$ con distribución $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ con $|\boldsymbol{\Sigma}| > 0$. Entonces:

- (a) $(\mathbf{X} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu})$ se distribuye como χ_p^2 , donde χ_p^2 denota la distribución chi-cuadrada con p grados de libertad.
- (b) La distribución $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ asigna una probabilidad $1 - \alpha$ al elipsoide sólido $\{\mathbf{x} : (\mathbf{x} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \leq \chi_p^2(\alpha)\}$, donde $\chi_p^2(\alpha)$ denota el percentil (100α) -superior de la distribución χ_p^2 .

Criterio Teórico

El elipsoide definido por la distancia generalizada menor o igual al percentil contiene exactamente el 50 % de la probabilidad teórica:

$$\{\mathbf{x} : (\mathbf{x} - \bar{\mathbf{x}})' \mathbf{S}^{-1} (\mathbf{x} - \bar{\mathbf{x}}) \leq \chi_2^2(0,5)\}$$

Entonces, en una muestra que provenga de una población normalmente distribuida, aproximadamente el 50 % de las observaciones deben caer dentro de esta elipse.

Si la proporción de distancias que caen dentro del elipsoide es menor al 50 % se tendría evidencia para rechazar la normalidad.

Ejemplo (Comprobación de la normalidad bivariada)

A continuación el vector de medias y matriz de varianzas y covarianzas del vector $\mathbf{X}^T = [x_1 = \text{ventas}, x_2 = \text{ganancias}]$ de datos de 10 empresas más grandes del mundo.

$$\bar{\mathbf{x}} = \begin{bmatrix} 155,60 \\ 14,70 \end{bmatrix}, \quad \mathbf{S} \approx \begin{bmatrix} 7476,45 & 303,62 \\ 303,62 & 26,19 \end{bmatrix}$$

por lo que

$$\begin{aligned} \mathbf{S}^{-1} &= \frac{1}{103,623,12} \begin{bmatrix} 26,19 & -303,62 \\ -303,62 & 7476,45 \end{bmatrix} \\ &= \begin{bmatrix} ,000253 & -,002930 \\ -,002930 & ,072148 \end{bmatrix} \end{aligned}$$

Se tiene que $\chi^2_2(,5) = 1,39$. Por lo tanto, cualquier observación $\mathbf{x}' = [x_1, x_2]$ que satisfaga

$$\begin{bmatrix} x_1 - 155,60 \\ x_2 - 14,70 \end{bmatrix}' \begin{bmatrix} ,000253 & -,002930 \\ -,002930 & ,072148 \end{bmatrix} \begin{bmatrix} x_1 - 155,60 \\ x_2 - 14,70 \end{bmatrix} \leq 1,39$$

está sobre o dentro del contorno estimado del 50 %. De lo contrario, la observación se encuentra fuera de este contorno.

Asuma que se tiene este par de observaciones $[x_1, x_2]' = [108,28, 17,05]$. En este caso:

$$\begin{bmatrix} 108,28 - 155,60 \\ 17,05 - 14,70 \end{bmatrix}' \begin{bmatrix} ,000253 & -,002930 \\ -,002930 & ,072148 \end{bmatrix} \begin{bmatrix} 108,28 - 155,60 \\ 17,05 - 14,70 \end{bmatrix} \\ = 1,61 > 1,39$$

y este punto cae fuera del contorno del 50 %. Ahora asuma que las distancias generalizadas de las otras nueve empresas son $\bar{x}$ de ,30, ,62, 1,79, 1,30, 4,38, 1,64, 3,53, 1,71 y 1,16. Dado que cuatro de estas distancias son menores que 1,39, una proporción de ,40 de los datos cae dentro del contorno del 50 %. **Esta diferencia en las proporciones ordinariamente podría proporcionar evidencia para rechazar la noción de normalidad bivariada.**




Ejemplo 4.14 Libro

Los datos del archivo DataExample414.txt corresponden a 4 medidas de rigidez de $n = 30$ tablas. La primera medición (x_1) implica enviar una onda de choque hacia abajo por la tabla, la segunda medición (x_2) se determina mientras se hace vibrar a la tabla y las dos últimas mediciones (x_3, x_4) se obtienen a partir de pruebas estáticas.

Ejemplo 4.14 Libro: Gráfico de Elipse

```
x1x2 <- data.frame(  
  DataExample_4_14$x1,  
  DataExample_4_14$x2  
)  
mat12 <- as.matrix.data.frame(x1x2)  
  
# Instalar y cargar HSAUR2  
install.packages("HSAUR2")  
library(HSAUR2)  
  
# Generar gráfico bvbox  
MVA::bvbox(mat12, method = "robust",  
  xlab = expression(x[1]),  
  ylab = expression(x[2]))
```




- **Distancia al cuadrado (d_j^2):** Mide la distancia de cada observación al centro muestral:

$$d_j^2 = (\mathbf{x}_j - \bar{\mathbf{x}})' \mathbf{S}^{-1} (\mathbf{x}_j - \bar{\mathbf{x}}), \quad j = 1, \dots, n$$

- **Comportamiento asintótico:** Si n y $n - p$ son grandes (> 25 o 30), cada d_j^2 se comporta aproximadamente como una variable χ_p^2 .
- **Gráfico Chi-Cuadrada (χ^2 -plot):**
 - Compara las distancias ordenadas con los cuantiles teóricos de la χ^2 .
 - Una tendencia lineal respalda la normalidad multivariada.
 - Desviaciones marcadas o puntos extremos señalan falta de normalidad o valores atípicos.

QQ plot Normal Multivariada



El gráfico Q-Q de χ^2 muestra que el alejamiento de los puntos a la recta indica desviación del supuesto de normalidad multivariante.

Algunas pruebas formales:

Prueba de Mardia: Una prueba de normalidad multivariada la cual está basada en la extensión de la asimetría ($\hat{\gamma}_{1,p}$) y curtosis ($\hat{\gamma}_{2,p}$):

$$\hat{\gamma}_{1,p} = \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n m_{ij}^3, \quad \hat{\gamma}_{2,p} = \frac{1}{n} \sum_{i=1}^n m_{ii}^2 \quad (1)$$

Donde $m_{ij} = (\mathbf{x}_i - \bar{\mathbf{x}})' \mathbf{S}^{-1} (\mathbf{x}_j - \bar{\mathbf{x}})$ es la distancia al cuadrado de Mahalanobis y p es el número de variables.

- **Asimetría:** La estadística de prueba $(n/6)\hat{\gamma}_{1,p}$ se distribuye aproximadamente como una Chi-cuadrada con $p(p+1)(p+2)/6$ grados de libertad.
- **Curtosis:** La estadística de prueba $\hat{\gamma}_{2,p}$ se distribuye aproximadamente normal con media $p(p+2)$ y varianza $8p(p+2)/n$.

```
testMardia<-mvn(data = DataExample_4_14, mvn_test = "mardia")
testMardia$multivariate_normality
```

	Test	Statistic	p.value	Method	MVN
1	Mardia Skewness	112.490	<0.001	asymptotic	Not normal
2	Mardia Kurtosis	2.377	0.017	asymptotic	Not normal

Con ambas pruebas, asimetría y curtosis, hay evidencia suficiente para rechazar la hipótesis de que estas variables provienen de una distribución normal multivariante.

Otras Pruebas para la Normal Multivariante

Prueba	Evaluación	Ventajas	Desventajas	Recomendado
Mardia	Asimetría/Curtosis	Rápida, común	Sensible a extremos	$p < 5, n > p$
Henze-Zirkler	Función Carac.	Indep. de Σ	Costosa	Cualq. $p, n > 10$
Royston	Ext. Shapiro-Wilk	Pocas dim.	Pierde poder (alta dim.)	$p \leq 5, n \geq 20$
Doornik-Hansen	Box-Cox + J-B	Buena alta dim.	Falla si alejada de norm.	$p > 5, n > p$
Shapiro-Wilk G	Gen. Shapiro	Muestras pequeñas	Costosa alta dim.	$p \leq 10, n \geq 5p$

En casos de alta dimensionalidad se usa la distancia de Mahalanobis ($d_j = (\mathbf{x}_j - \bar{\mathbf{x}})' \mathbf{S}^{-1} (\mathbf{x}_j - \bar{\mathbf{x}})$, $j = 1, \dots, n$) para identificación de valores atípicos. Así distancia grandes sugieren una observación inusual

¿Cómo detectar observaciones atípicas?

- **Univariado:** Boxplot por variable.
- **Bivariado:** Diagrama de dispersión por pares.
- **Multivariado:**
 - **Estandarización:**

$$z_{jk} = \frac{x_{jk} - \bar{x}_k}{\sqrt{s_{kk}}}$$

donde $j = 1, \dots, n$ y $k = 1, \dots, p$.

Como guía: valores de 3.5 podrían ser considerados atípicos.

- **Distancias generalizadas** d_j^2

Se usan distancias generalizadas:

$$d_j^2 = (X_j - \bar{X})^\top S^{-1} (X_j - \bar{X})$$

se examinan aquellas que sean inusualmente grandes, es decir, si

$$d_j^2 > \chi_p^2(\alpha)$$

la observación se considera atípica multivariada.

Nota: Para $n = 100$, esperar aprox. 5 observaciones excediendo el percentil 99.5 % de χ_p^2 .

Detección usando paquete MVN:

```
> Out<-mvn(DataExample_4_14[,2:5],  
+          multivariate_outlier_method ="adj" )  
> summary(Out, select = "outliers")
```

— Multivariate Outliers —

	Observation	Mahalanobis.Distance
1	16	174.912
2	3	49.624
3	21	47.526
4	4	30.287
5	2	25.203
6	7	18.900
7	9	12.847

```
> qchisq(0.005,4,lower.tail = F)  
[1] 14.86026
```

Nota: Utiliza distancia Mahalanobis Robusta (medias y matriz de covarianza robustas). Las observaciones 9 y 16 presentan las mayores distancias de Mahalanobis:

- $d_9^2 \approx 12,86$

¿Qué hacer si no se cumple el supuesto de normalidad?

- Ignorar el supuesto puede llevar a conclusiones incorrectas.
- Aplicar transformaciones para aproximar a la normalidad (sugeridas por datos o teoría).

Escala original	Escala transformada
Conteo x	$\sqrt{x}$
Proporción $\hat{p}$	$\text{logit}(\hat{p}) = \frac{1}{2} \ln\left(\frac{\hat{p}}{1-\hat{p}}\right)$
Correlación r	$z(r) = \frac{1}{2} \ln\left(\frac{1+r}{1-r}\right)$

Transformación de Box-Cox:

$$x^\lambda = \begin{cases} \frac{x^\lambda - 1}{\lambda} & \lambda \neq 0 \\ \ln(x) & \lambda = 0 \end{cases}$$

Selección de λ : maximiza el logaritmo de la función de verosimilitud de una normal.

Multivariado:

- Aplicar transformación a cada variable: $\lambda_1, \lambda_2, \dots, \lambda_p$.
- Observación: Normalidad univariada no implica multivariada, pero es suficiente en aplicaciones prácticas.


```
> # ----- Transformacion BoxCox ----- #  
> require(car)  
> powerTransform(DataExample_4_14$x1)  
Estimated transformation parameter  
DataExample_4_14$x1  
-0.6209551
```

Ejercicio 1

Considere la base de datos del Ejemplo 4.14

- a. Grafique la distribución univariada de cada variable.
- c. Dibuje elipses entre pares de variables.
- d. Realice las transformaciones a las variables que considere y pruebe la normalidad multivariante de manera gráfica y con el test.