

Análisis Multivariado ID 033521

Semana 4 y 5: Inferencial para el media - Comparación de medias

Profesora: Diana Marcela Martínez Ruiz

27 de agosto de 2026

Comparación de medias en una población

Con los intervalos simultáneos T^2 se puede contrastar hipótesis sobre combinaciones lineales de las medias del vector $\boldsymbol{\mu}_{p \times 1}$. Una de estas combinaciones puede ser la diferencias, es decir

$$H_0 : \mu_j = \mu_k \text{ vs. } \mu_j \neq \mu_k, \mu_j, \mu_k \in \boldsymbol{\mu}$$

Intervalos simultáneos T^2 para combinaciones lineales de las componentes de μ

Para cualquier combinación lineal arbitraria de las medias $\mathbf{a}'\mu$ (con $\mathbf{a}$ un vector constante de $p \times 1$), el intervalo de confianza simultáneo con un nivel de confianza $1 - \alpha$

$$\mathbf{a}'\bar{x} \pm \sqrt{\frac{p(n-1)}{n-p} F_{p,n-p}(\alpha)} \sqrt{\mathbf{a}' \frac{S}{n} \mathbf{a}}$$

Por ejemplo para el vector $\mathbf{a}' = [a_1 = 0, a_2 = 0, \dots, a_j = 1, \dots, a_k = -1, \dots, a_p = 0]$, los intervalos simultáneos T^2 para las diferencias $\mu_j - \mu_k$ están dados por

$$\bar{x}_j - \bar{x}_k \pm \sqrt{\frac{p(n-1)}{n-p} F_{p,n-p}(\alpha)} \sqrt{\frac{s_{22} + s_{33} - 2s_{23}}{n}}$$

Ejemplo: usando sweat_data.txt

Hallar el intervalo simultaneo T^2 Hotelling con una confianza del 90 % para la combinación lineal $\mathbf{a}'\boldsymbol{\mu}$, con $\mathbf{a}' = [0, 1, -1]$.

Ejemplo: usando sweat_data.txt

Hallar el intervalo simultaneo T^2 Hotelling con una confianza del 90 % para la combinación lineal $\mathbf{a}'\boldsymbol{\mu}$, con $\mathbf{a}' = [0, 1, -1]$.

Es decir, hallar el intervalo para contrastar las hipótesis

$$H_0 : \mu_2 = \mu_3 \text{ vs. } \mu_2 \neq \mu_3, \mu_2, \mu_3 \in \boldsymbol{\mu}$$

Para ello tenemos que

$$\bar{\mathbf{x}} = \begin{bmatrix} 4,640 \\ 45,400 \\ 9,965 \end{bmatrix}, \quad \mathbf{S}^{-1} = \begin{bmatrix} ,586 & -,022 & ,258 \\ -,022 & ,006 & -,002 \\ ,258 & -,002 & ,402 \end{bmatrix}, \quad \frac{(n-1)p}{n-p} F_{p,n-p}(0,10) = 8,18$$

¿Cuánto da este intervalo? Cómo se interpreta?

Usando R

```
n <- nrow(sweat_data)  # Muestra
p <- ncol(sweat_data)  # Variables
# 2. Estadísticos muestrales
X_bar <- colMeans(sweat_data[, -1])
S <- cov(sweat_data[, -1])
alpha <- 0.05

# 3. Multiplicador crítico de Hotelling
f_critico <- qf(1 - alpha, df1 = p, df2 = n - p)
mult_hotelling <- sqrt((p * (n - 1) / (n - p)) * f_critico)

# 4. Vector de contraste para (X1_Sweat_rate - X2_Sodium)
a <- rep(0, p); names(a) <- colnames(sweat_data)
a["X1_Sweat_rate"] <- 1
a["X2_Sodium"] <- -1

# 5. Cálculo del intervalo
media_comb <- sum(a * X_bar);
ee_comb <- as.numeric(sqrt(t(a) %*% (S / n) %*% a))

lim_inf <- media_comb - (mult_hotelling * ee_comb)
lim_sup <- media_comb + (mult_hotelling * ee_comb)
```

Introducción a la Comparación de Medias

En la situación multivariada, consideraremos el problema de evaluar la igualdad de medias de diferentes poblaciones[cite: 2]. Para esto, debemos considerar los siguientes casos

fundamentales[cite: 2]:

- **Muestras pareadas o medidas repetidas:** Las p variables se evalúan en la misma unidad de muestreo bajo dos condiciones diferentes (por ejemplo, antes y después de un tratamiento)[cite: 2].
- **Dos poblaciones independientes:** Las muestras se extraen de dos grupos distintos y no relacionados[cite: 2].
- **Más de dos poblaciones independientes:** Comparación simultánea de varios grupos mediante el Análisis de Varianza Multivariado (MANOVA)[cite: 2].

1. Muestras Pareadas (Medidas Repetidas)

Suponga que se miden p variables en las mismas n unidades en dos situaciones diferentes. Etiquetamos las p mediciones dentro de la j -ésima unidad de la siguiente manera

X_{1j1} = variable 1 dentro del tratamiento 1

X_{1j2} = variable 2 dentro del tratamiento 1

$\vdots$

X_{1jp} = variable p dentro del tratamiento 1

- - -

X_{2j1} = variable 1 dentro del tratamiento 2

X_{2j2} = variable 2 dentro del tratamiento 2

$\vdots$

X_{2jp} = variable p dentro del tratamiento 2



Sea $\mathbf{D}_j = \mathbf{X}_{1j} - \mathbf{X}_{2j}$ el vector de diferencias para la unidad j .

$$D_{j1} = X_{1j1} - X_{2j1}$$

$$D_{j2} = X_{1j2} - X_{2j2}$$

$$\vdots$$

$$D_{jp} = X_{1jp} - X_{2jp}$$

Sea $\mathbf{D}'_j = [D_{j1}, D_{j2}, \dots, D_{jp}]$, y suponga, para $j = 1, 2, \dots, n$, que:

$$E(\mathbf{D}_j) = \boldsymbol{\delta} = \begin{bmatrix} \delta_1 \\ \delta_2 \\ \vdots \\ \delta_p \end{bmatrix} \quad \text{y} \quad \text{Cov}(\mathbf{D}_j) = \boldsymbol{\Sigma}_d$$

Si, además, $\mathbf{D}_1, \mathbf{D}_2, \dots, \mathbf{D}_n$ son vectores aleatorios independientes $N_p(\boldsymbol{\delta}, \boldsymbol{\Sigma}_d)$, las inferencias sobre el vector de diferencias de medias $\boldsymbol{\delta}$ se pueden basar en una estadística T^2 .

Queremos probar si hay diferencias significativa entre los tratamientos:

$$H_0 : \boldsymbol{\mu}_D = \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2 = \mathbf{0}$$

$$H_1 : \boldsymbol{\mu}_D \neq \mathbf{0}$$

La estadística de prueba T^2 de Hotelling está dada por[cite: 2]:

$$T^2 = n\bar{\mathbf{D}}^\top \mathbf{S}_D^{-1} \bar{\mathbf{D}}$$

donde,

$$\bar{\mathbf{D}} = \frac{1}{n} \sum_{j=1}^n \mathbf{D}_j \quad y \quad \mathbf{S}_d = \frac{1}{n-1} \sum_{j=1}^n (\mathbf{D}_j - \bar{\mathbf{D}})(\mathbf{D}_j - \bar{\mathbf{D}})'$$

Bajo H_0 , $T^2 \sim \frac{(n-1)p}{n-p} F_{p,n-p}$. Se rechaza H_0 a un nivel α si

$$T_{obs}^2 > \frac{(n-1)p}{n-p} F_{p,n-p}(\alpha)$$

Ejemplo 6.1 (Johnson & Wichern): Datos de Efluentes

Contexto: Se dividieron muestras de efluentes de $n = 11$ plantas de tratamiento de agua y se enviaron a dos laboratorios (Comercial y Estatal) para su análisis[cite: 1, 2].

- Se midieron dos variables ($p = 2$): Demanda Bioquímica de Oxígeno (BOD) y Sólidos Suspendidos (SS)[cite: 1, 2].
- ¿Coinciden los análisis químicos de los dos laboratorios?[cite: 2]

Las diferencias calculadas son $\mathbf{D}_j = \mathbf{X}_{Comercial,j} - \mathbf{X}_{Estatal,j}$ [cite: 2].

Table 6.1 Effluent Data				
Sample j	Commercial lab		State lab of hygiene	
	x_{1j1} (BOD)	x_{1j2} (SS)	x_{2j1} (BOD)	x_{2j2} (SS)
1	6	27	25	15
2	6	23	28	13
3	18	64	36	22
4	8	44	35	29
5	11	30	15	31
6	34	75	44	64
7	28	26	42	30
8	71	124	54	64
9	43	54	34	56
10	33	30	29	20
11	20	14	39	21
Source: Data courtesy of S. Weber.				

Observe que el vector $\mathbf{X}'_{1j} = [X_{1j1}, X_{1j2}]$ contiene las $j = 11$ observaciones de las $p = 2$ variables del tratamiento $k = 1$

Código en R: Muestras Pareadas (Ejemplo 6.1)

```
# Ejemplo 6.1 de Johnson and Wichern
library(readxl)
effluent <- read_excel("effluent.xlsx")

# Calculo de diferencias
Dj1 <- effluent$BOD_COM - effluent$BOD_ST
Dj2 <- effluent$SS_COM - effluent$SS_ST

Dbarra <- c(mean(Dj1), mean(Dj2))
SD <- cov(cbind(Dj1, Dj2))

n <- nrow(effluent); p <- 2; alpha <- 0.05

# Estadística T2 de Hotelling
T2 <- n * t(Dbarra) %*% solve(SD) %*% Dbarra # solve() calcula SD^-1

# Valor critico
vc <- (((n - 1) * p) / (n - p)) * qf(alpha, p, n - p, lower.tail = FALSE)
```

```

> Dj1
[1] -19 -22 -18 -27 -4 -10 -14 17 9 4 -19
> Dj2
[1] 12 10 42 15 -1 11 -4 60 -2 10 -7
> Dbarra
[1] -9.363636 13.272727
> SD
      Dj1      Dj2
Dj1 199.25455 88.30909
Dj2 88.30909 418.61818
> cat("Estadística T2:", T2, "\n")
Estadística T2: 13.63931
> cat("Valor crítico:", vc, "\n")
valor crítico: 9.458877

```

Como $T^2 = 13,6 > 9,46$, rechazamos H_0 y concluimos que los laboratorios difieren sistemáticamente.

2. Dos Poblaciones Normales Independientes

Sean $\mathbf{X}_{11}, \dots, \mathbf{X}_{1n_1}$ y $\mathbf{X}_{21}, \dots, \mathbf{X}_{2n_2}$ muestras aleatorias independientes de poblaciones $N_p(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_1)$ y $N_p(\boldsymbol{\mu}_2, \boldsymbol{\Sigma}_2)$ [cite: 2].

Asumiendo homocedasticidad ($\boldsymbol{\Sigma}_1 = \boldsymbol{\Sigma}_2 = \boldsymbol{\Sigma}$), queremos probar:

$$H_0 : \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2 = \boldsymbol{\delta}_0$$

$$H_1 : \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2 \neq \boldsymbol{\delta}_0$$

La matriz de covarianza ponderada (pooled) es[cite: 2]:

$$\mathbf{S}_{pooled} = \frac{n_1 - 1}{n_1 + n_2 - 2} \mathbf{S}_1 + \frac{n_2 - 1}{n_1 + n_2 - 2} \mathbf{S}_2$$

Estadística de Prueba (Dos Poblaciones Independientes)

Bajo H_0 , la estadística de prueba es:

$$T^2 = (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - \boldsymbol{\delta}_0)^\top \left[\left(\frac{1}{n_1} + \frac{1}{n_2} \right) \mathbf{S}_{pooled} \right]^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 - \boldsymbol{\delta}_0)$$

Rechazamos H_0 a un nivel de significancia α si:

$$T^2 > \frac{(n_1 + n_2 - 2)p}{n_1 + n_2 - p - 1} F_{p, n_1 + n_2 - p - 1}(\alpha)$$

Ejemplo: Comparación de dos poblaciones independientes

Considere que se tienen mediciones de productividad (X_{i1}) y altura (X_{i2}) de plantas correspondientes a dos variedades distintas (Poblaciones independientes).

Variedad A (Población 1)		Variedad B (Población 2)	
X_{11}	X_{12}	X_{21}	X_{22}
5.7	2.10	4.4	1.80
8.9	1.90	7.5	1.75
6.2	1.98	5.4	1.78
5.8	1.92	4.6	1.89
6.8	2.00	5.9	1.90
6.2	2.01		

Observe que los tamaños de muestra, n_1 y n_2 son distintos. Pruebe la igualdad del vector medio de las dos variedades, bajo homocedasticidad.



- Dos muestras de poblaciones **independientes**, variedad A y la variedad B.
- En cada muestra se miden **dos** características (**variables**).

	Variedad A		Variedad B	
	X_{11}	X_{12}	X_{21}	X_{22}
	5.7	2.1	4.4	1.8
	8.9	1.9	7.5	1.75
	6.2	1.98	5.4	1.78
	5.8	1.92	4.6	1.89
	6.8	2	5.9	1.9
	6.2	2.01		
Media	6.6	1.985	5.56	1.824
Varianza	1.42	0.005	1.543	0.0045

Código en R: Dos Poblaciones Independientes

```
# Datos del Ejemplo de Variedades A y B
x1_bar <- c(6.6, 1.985)
x2_bar <- c(5.56, 1.824)

S1 <- matrix(c(1.42, -0.0504, -0.0504, 0.005), 2, 2)
S2 <- matrix(c(1.543, -0.037, -0.037, 0.0045), 2, 2)
n1 <- 6; n2 <- 5; p <- 2; alpha <- 0.05

# Covarianza Pooled
S_pool <- ((n1 - 1)*S1 + (n2 - 1)*S2) / (n1 + n2 - 2)


# Estadística T2
dif <- x1_bar - x2_bar
T2 <- t(dif) %*% solve((1/n1 + 1/n2) * S_pool) %*% dif

# Valor critico
vc <- ((n1 + n2 - 2)*p / (n1 + n2 - p - 1)) * qf(alpha, p, n1 + n2 - p - 1, lower.tail = FALSE)

cat("T2 =", T2, "| Valor critico =", vc, "\n")
```

$T^2 = 30.58 > 10.03$, por lo tanto, se rechaza $H_0 : \mu_A = \mu_B$ [cite: 2].

Comparación de más de dos poblaciones



Asumiendo que todas las poblaciones son **independientes entre sí**, el interés es probar las hipótesis

$$H_0 = \mu_1 = \dots = \mu_g = \mu$$

H_1 : al menos un μ_i es diferente

Comparaciones en más de dos poblaciones independientes

Para probar esas hipótesis consideramos la **reparametrización**:

$$\mu_k = \mu + \tau_k \quad k = 1, \dots, g$$

Por lo que basta probar:

$$H_0 : \tau_1 = \tau_2 = \dots = \tau_g = 0$$

$$H_1 : \text{al menos un } \tau_k \text{ es diferente de } 0$$

Observación: τ_k es el efecto del grupo k .

3. Más de Dos Poblaciones Independientes (MANOVA)

Consideremos g poblaciones independientes $N_p(\boldsymbol{\mu}_k, \boldsymbol{\Sigma})$ con $k = 1, \dots, g$ [cite: 2].
El modelo MANOVA (Análisis de Varianza Multivariado) es:

$$\mathbf{X}_{kj} = \boldsymbol{\mu} + \boldsymbol{\tau}_k + \mathbf{e}_{kj}$$

Queremos probar[cite: 2]:

$$H_0 : \boldsymbol{\tau}_1 = \boldsymbol{\tau}_2 = \dots = \boldsymbol{\tau}_g = \mathbf{0}$$

$$H_1 : \text{Al menos un } \boldsymbol{\tau}_k \text{ es diferente de } \mathbf{0}$$

Se utiliza la estadística **Lambda de Wilks** (Λ^*), comparando la suma de cuadrados intra-grupos (**W**) con la suma de cuadrados totales (**T**)[cite: 2]:

$$\Lambda^* = \frac{|\mathbf{W}|}{|\mathbf{B} + \mathbf{W}|} = \frac{|\mathbf{W}|}{|\mathbf{T}|}$$

El modelo ANOVA multivariado (MANOVA)

El modelo MANOVA está dado por[cite: 2]:

$$\mathbf{X}_{kj} = \boldsymbol{\mu} + \boldsymbol{\tau}_k + \boldsymbol{\epsilon}_{kj} \quad \text{para } j = 1, \dots, n_k, \quad k = 1, \dots, g$$

Supuestos del modelo[cite: 2]:

- $\boldsymbol{\epsilon}_{kj} \stackrel{iid}{\sim} N_p(\mathbf{0}, \boldsymbol{\Sigma})$.
- $\boldsymbol{\mu}$ es la media general.
- $\boldsymbol{\tau}_k$ es el efecto del k -ésimo grupo.
- $\sum_{k=1}^g n_k \boldsymbol{\tau}_k = \mathbf{0}$ (para garantizar la identificabilidad del modelo).

Tabla MANOVA y Descomposición de la Suma de Cuadrados

La tabla MANOVA queda dada por[cite: 2]:

Fuente de variación	Sumas de Cuadrados	Grados de Libertad
Tratamiento (B)	B	$g - 1$
Residuo (W)	W	$N - g$
Total (T)	T	$N - 1$

Donde $N = \sum_{k=1}^g n_k$, y las matrices se definen como[cite: 2]:

$$\mathbf{T} = \sum_{k=1}^g \sum_{j=1}^{n_k} (\mathbf{X}_{kj} - \bar{\mathbf{X}})(\mathbf{X}_{kj} - \bar{\mathbf{X}})^\top$$

$$\mathbf{B} = \sum_{k=1}^g n_k (\bar{\mathbf{X}}_k - \bar{\mathbf{X}})(\bar{\mathbf{X}}_k - \bar{\mathbf{X}})^\top$$

$$\mathbf{W} = \sum_{k=1}^g \sum_{j=1}^{n_k} (\mathbf{X}_{kj} - \bar{\mathbf{X}}_k)(\mathbf{X}_{kj} - \bar{\mathbf{X}}_k)^\top$$

Lo que se desea verificar es si $\mathbf{W}$ es pequeño con respecto a $\mathbf{T}$ [cite: 2]. Si todas las medias pueden ser consideradas diferentes, sobraría poco para el residuo[cite: 2].

En consecuencia, para probar esto, usamos la estadística **Lambda de Wilks** (Varianza Generalizada)[cite: 2]:

$$\Lambda^* = \frac{|\mathbf{W}|}{|\mathbf{W} + \mathbf{B}|} = \frac{|\mathbf{W}|}{|\mathbf{T}|}$$

La distribución de Λ^* es complicada y depende del número de variables (p) y del número de grupos (g)[cite: 2]. Se estudiaron algunos casos para los cuales existen tablas (o aproximaciones F y χ^2)[cite: 2].

Ejemplo 4: Datos Skulls (Cráneos Egipcios)

Los datos `Skulls` del paquete `heplots` de R contienen 150 observaciones y 5 variables de cráneos egipcios de cinco épocas[cite: 2]:

- `epoch`: época en que el cráneo fue atribuido. Es un factor ordenado con 5 niveles (c4000BC, c3300BC, c1850BC, c200BC, cAD150).
- `mB`: largura máxima del cráneo.
- `bh`: altura de la base bregmática del cráneo.
- `bl`: longitud de la base alveolar del cráneo.
- `nh`: altura nasal del cráneo.

Tenemos $g = 5$ grupos. El interés es probar[cite: 2]:

$$H_0 : \mu_1 = \mu_2 = \mu_3 = \mu_4 = \mu_5 = \mu$$

$$H_1 : \text{al menos un } \mu_i \text{ es diferente}$$

Prueba de Normalidad y MANOVA en R (Datos Skulls)

```
# ----- Ex. Datos Skulls ----- #
require(heplots)
data("Skulls")
require(mvShapiroTest)

# ----- Prueba de Normalidad Multivariada ----- #
mvShapiro.Test(as.matrix(Skulls[,2:5]))
# MVW = 0.99212, p-value = 0.755 (No se rechaza normalidad)

# ----- MANOVA ----- #
mod <- manova(cbind(mb, bh, bl, nh) ~ epoch, data = Skulls)
summary(mod, test = "Wilks")
#           Df      Wilks approx F num Df den Df    Pr(>F)
# epoch       4 0.66359    3.9009    16 434.45 7.01e-07 ***
# Residuals 145
```

Observe que el p -valor = $7,01e - 07$ es altamente significativo, por lo tanto, hay suficiente evidencia en la muestra para rechazar H_0 ; al menos un μ_i es diferente de los otros[cite: 21]



Una vez rechazada la hipótesis global en el MANOVA, se evalúan los ANOVAs univariados para cada variable con el fin de identificar en cuál (o cuáles) hay diferencias significativas debido a los grupos[cite: 2].

```
# ----- Modelo para cada variable ----- #  
mod.skulls <- aov(mod, data = Skulls)  
summary(mod.skulls)
```

Observación: Ya que se están haciendo pruebas múltiples simultáneas sobre las diferentes variables, es necesario ajustar el nivel de significancia α , por ejemplo, utilizando la corrección de Bonferroni para evitar inflar el error Tipo I[cite: 2].

Código en R: MANOVA (Datos Skulls)

El objetivo es comparar medias multidimensionales de 4 dimensiones craneales en 5 épocas históricas[cite: 2].

```
# Ejemplo Datos Skulls
require(heplots)
data("Skulls")

# Ajuste del modelo MANOVA
mod <- manova(cbind(mb, bh, bl, nh) ~ epoch, data = Skulls)

# Prueba Lambda de Wilks
summary(mod, test = "Wilks")

# Análisis Post-hoc: Modelo para cada variable univariada
mod_skulls <- aov(mod)
summary(mod_skulls)
```

Un p-valor pequeño en el test de Wilks indica que las características craneales varían significativamente a través de las diferentes épocas[cite: 2].

