

Análisis Multivariado ID 033521

Semana 4: Inferencial para el media: Intervalos simultaneos y comparación de medias

Profesora: Diana Marcela Martínez Ruiz

25 de agosto de 2026



Quedamos en que:

- Las regiones de confianza proporcionan un conocimiento conjunto sobre los valores plausibles para μ .
- Si se necesita tener conclusiones sobre los componentes individuales del vector de medias, es decir, sobre los μ_i , se requiere estimar **intervalos individuales** de forma tal que simultáneamente cada uno de ellos contenga a su media bajo una probabilidad especificada.

Aquellos intervalos son denominados **intervalos de confianza simultáneos**

Intervalos de confianza simultáneos

Sea $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ y la combinación lineal:

$$Z = a_1X_1 + a_2X_2 + \cdots + a_pX_p = \mathbf{a}'\mathbf{X}$$

A partir de las propiedades de la normal p-variada:

$$\mu_Z = E(Z) = \mathbf{a}'\boldsymbol{\mu} \text{ y } \sigma_Z^2 = \text{Var}(Z) = \mathbf{a}'\boldsymbol{\Sigma}\mathbf{a} \text{ así } Z \sim N(\mathbf{a}'\boldsymbol{\mu}; \mathbf{a}'\boldsymbol{\Sigma}\mathbf{a})$$

Resultado

Sea $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ una muestra aleatoria de una población $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ con $\boldsymbol{\Sigma}$ definida positiva. Entonces, simultáneamente para todo $\mathbf{a}$, el intervalo

$$\left(\mathbf{a}'\bar{\mathbf{X}} - \sqrt{\frac{p(n-1)}{n(n-p)}} F_{p, n-p}(\alpha) \sqrt{\mathbf{a}'\mathbf{S}\mathbf{a}}, \quad \mathbf{a}'\bar{\mathbf{X}} + \sqrt{\frac{p(n-1)}{n(n-p)}} F_{p, n-p}(\alpha) \sqrt{\mathbf{a}'\mathbf{S}\mathbf{a}} \right)$$

contendrá a $\mathbf{a}'\boldsymbol{\mu}$ con probabilidad $1 - \alpha$.

Contrucción de los intervalos simultaneos

$$\mu_1 = [1 \quad 0 \quad \cdots \quad 0]_{1 \times p} \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix}_{p \times 1} = \mathbf{a}^\top \boldsymbol{\mu}$$

$\vdots$

$$\mu_p = [0 \quad 0 \quad \cdots \quad 1]_{1 \times p} \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix}_{p \times 1} = \mathbf{a}^\top \boldsymbol{\mu}$$

Nota: el vector fila $\mathbf{a}^\top$ es un vector canónico. Es decir, es un vector unitario que tiene un valor de uno en una posición específica y ceros en el resto de las componentes.

Sabemos que Z tiene una distribución $N(\mathbf{a}'\boldsymbol{\mu}, \mathbf{a}'\boldsymbol{\Sigma}\mathbf{a})$. Si se cuenta con una muestra aleatoria $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ de una población $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, se puede crear una muestra correspondiente de valores de Z tomando combinaciones lineales. Por lo tanto,

$$Z_j = a_1 X_{j1} + a_2 X_{j2} + \dots + a_p X_{jp} = \mathbf{a}'\mathbf{X}_j, \quad j = 1, 2, \dots, n$$

de esa muestra se obtiene $\bar{z} = \mathbf{a}'\bar{x}$ y $s^2 = \mathbf{a}'\mathbf{S}\mathbf{a}$ son la media y varianza muestral de los valores observados $z_1, z_2, \dots, z_n$.

Sabemos que Z tiene una distribución $N(\mathbf{a}'\boldsymbol{\mu}, \mathbf{a}'\boldsymbol{\Sigma}\mathbf{a})$. Si se cuenta con una muestra aleatoria $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ de una población $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, se puede crear una muestra correspondiente de valores de Z tomando combinaciones lineales. Por lo tanto,

$$Z_j = a_1 X_{j1} + a_2 X_{j2} + \dots + a_p X_{jp} = \mathbf{a}'\mathbf{X}_j, \quad j = 1, 2, \dots, n$$

de esa muestra se obtiene $\bar{z} = \mathbf{a}'\bar{\mathbf{x}}$ y $s^2 = \mathbf{a}'\mathbf{S}\mathbf{a}$ son la media y varianza muestral de los valores observados $z_1, z_2, \dots, z_n$.

Entonces, para un $\mathbf{a}$ fijo y un σ_Z desconocido, un intervalo del $100(1 - \alpha)\%$ para $\mu_Z = \mathbf{a}'\boldsymbol{\mu}$ se basa en

$$t = \frac{\bar{z} - \mu_Z}{s_z/\sqrt{n}} = \frac{\sqrt{n}(\mathbf{a}'\bar{\mathbf{x}} - \mathbf{a}'\boldsymbol{\mu})}{\sqrt{\mathbf{a}'\mathbf{S}\mathbf{a}}} \sim t_{n-1}$$

Así,

$$\bar{z} - t_{n-1}(\alpha/2) \frac{s_Z}{\sqrt{n}} \leq \mu_z \leq \bar{z} + t_{n-1}(\alpha/2) \frac{s_Z}{\sqrt{n}}$$

o

$$\mathbf{a}'\bar{\mathbf{x}} - t_{n-1}(\alpha/2) \frac{\sqrt{\mathbf{a}'\mathbf{S}\mathbf{a}}}{\sqrt{n}} \leq \mathbf{a}'\boldsymbol{\mu} \leq \mathbf{a}'\bar{\mathbf{x}} + t_{n-1}(\alpha/2) \frac{\sqrt{\mathbf{a}'\mathbf{S}\mathbf{a}}}{\sqrt{n}}$$

donde $t_{n-1}(\alpha/2)$ es el percentil superior $100(\alpha/2)$ de una distribución t con $n - 1$ grados de libertad (d.f.).

Esta desigualdad se puede interpretar como una afirmación sobre los componentes del vector de medias $\boldsymbol{\mu}$.

en el caso que $\mathbf{a}' = [1, 0, \dots, 0]$, tendríamos

$$\mathbf{a}^\top \boldsymbol{\mu} = [1 \quad 0 \quad \dots \quad 0]_{1 \times p} \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix}_{p \times 1} = \mu_1$$

Entonces, $\bar{z} = \mathbf{a}^\top \bar{x} = \bar{x}_1$ y $s^2 = \mathbf{a}^\top \mathbf{S} \mathbf{a} = s_{11}$.

Por lo tanto tendríamos el intervalo de confianza para la media de una población normal.

$$\bar{x}_1 - t_{n-1}(\alpha/2) \frac{s_{11}}{\sqrt{n}} \leq \mu_1 \leq \bar{x}_1 + t_{n-1}(\alpha/2) \frac{s_{11}}{\sqrt{n}}$$

Podríamos escoger diferentes valores para $\mathbf{a}'$ para hacer varias afirmaciones de confianza sobre los componentes de $\boldsymbol{\mu}$, cada una con un coeficiente de confianza asociado $1 - \alpha$. Es decir,

$$\bar{x}_1 - t_{(n-1)}(\alpha/2)\sqrt{\frac{s_{11}}{n}} \leq \mu_1 \leq \bar{x}_1 + t_{(n-1)}(\alpha/2)\sqrt{\frac{s_{11}}{n}}$$

$$\bar{x}_2 - t_{(n-1)}(\alpha/2)\sqrt{\frac{s_{22}}{n}} \leq \mu_2 \leq \bar{x}_2 + t_{(n-1)}(\alpha/2)\sqrt{\frac{s_{22}}{n}}$$

$\vdots$

$$\bar{x}_p - t_{(n-1)}(\alpha/2)\sqrt{\frac{s_{pp}}{n}} \leq \mu_p \leq \bar{x}_p + t_{(n-1)}(\alpha/2)\sqrt{\frac{s_{pp}}{n}}$$

Sin embargo, la confianza asociada con todas las afirmaciones tomadas en conjunto **no** es $1 - \alpha$.

¿Por qué la confianza asociada con todas las afirmaciones tomadas en conjunto **no** es $1 - \alpha$?

Aquellos intervalos *ignoran la estructura de covarianza* de las p variables. Considere que $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, donde

$$\boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix}, \quad \boldsymbol{\Sigma} = \begin{bmatrix} \sigma_{11} & 0 & \cdots & 0 \\ 0 & \sigma_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_{pp} \end{bmatrix}$$

Observe que se está *asumiendo* que las *variables son independientes*. Entonces, si I_i denota al intervalo aleatorio para μ_i :

$$P[\mu_1 \in I_1, \mu_2 \in I_2, \dots, \mu_p \in I_p] = \prod_{i=1}^p (1 - \alpha) = (1 - \alpha)^p$$

Cálculo de Intervalos Univariados en R con sweat_data.txt

Aquí se muestra el código en R para calcular los intervalos de confianza univariados y sus respectivas longitudes:

```
# ----- IC Univariados ----- #
IC1 <- t.test(sweat_data$X1_Sweat_rate, mu = 4, conf.level = 0.90)
IC2 <- t.test(sweat_data$X2_Sodium, mu = 50, conf.level = 0.90)
IC3 <- t.test(sweat_data$X3_Potassium, mu = 10, conf.level = 0.90)

IC1$conf.int
IC2$conf.int
IC3$conf.int

# ----- Longitud
L1 <- IC1$conf.int[2] - IC1$conf.int[1]
L2 <- IC2$conf.int[2] - IC2$conf.int[1]
L3 <- IC3$conf.int[2] - IC3$conf.int[1]
```

Se analizó la transpiración de 20 mujeres sanas.

$$H_0 : \mu' = [4, 50, 10] \text{ vs. } H_1 : \mu' \neq [4, 50, 10]$$

con $\alpha = 0,10$.

Media de X_i	Intervalo	Longitud del IC
μ_1	[3,98, 5,30]	1,31
μ_2	[39,93, 50,87]	10,93
μ_3	[9,23, 10,70]	1,47

Observe que todos los intervalos contienen el respectivo valor de μ_0 . En este caso

$$P[\mu_1 \in I_1, \mu_2 \in I_2, \mu_3 \in I_3] = \prod_{i=1}^3 (1 - 0,10) = (1 - 0,10)^3 = 0,729$$

la “confianza conjunta” disminuyó.

¿Qué hacemos para que la confianza no disminuya?

Intervalos simultáneos basados en la estadística T^2 de Hotelling:

Estos permiten asociar una confianza “colectiva” de $1 - \alpha$ a todos los intervalos de confianza que pueden ser generados por las diferentes elecciones de $\mathbf{a}'$.

Intervalos simultáneos basados en la estadística T^2 de Hotelling

Para una muestra dada $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ y para todo $\mathbf{a} \in \mathbb{R}^p$ el intervalo:

$$\mathbf{a}^\top \bar{\mathbf{X}} \pm \sqrt{\frac{(n-1)p}{(n-p)n} F_{p, n-p}(\alpha)} \sqrt{\mathbf{a}^\top \mathbf{S} \mathbf{a}}$$

contendrá a $\mathbf{a}^\top \boldsymbol{\mu}$ con probabilidad $1 - \alpha$. Estos intervalos simultáneos son llamados **intervalos T^2** .

Las sucesivas elecciones de $\mathbf{a}$:

$$\mathbf{a} = \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, \quad \mathbf{a} = \begin{bmatrix} 0 \\ 1 \\ \vdots \\ 0 \end{bmatrix}, \quad \dots, \quad \mathbf{a} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{bmatrix}$$

para los intervalos T^2 , permite concluir que

$$\bar{x}_1 - \sqrt{\frac{(n-1)p}{n-p} F_{p,n-p}(\alpha)} \sqrt{\frac{s_{11}}{n}} \leq \mu_1 \leq \bar{x}_1 + \sqrt{\frac{(n-1)p}{n-p} F_{p,n-p}(\alpha)} \sqrt{\frac{s_{11}}{n}}$$

$$\bar{x}_2 - \sqrt{\frac{(n-1)p}{n-p} F_{p,n-p}(\alpha)} \sqrt{\frac{s_{22}}{n}} \leq \mu_2 \leq \bar{x}_2 + \sqrt{\frac{(n-1)p}{n-p} F_{p,n-p}(\alpha)} \sqrt{\frac{s_{22}}{n}}$$

⋮

$$\bar{x}_p - \sqrt{\frac{(n-1)p}{n-p} F_{p,n-p}(\alpha)} \sqrt{\frac{s_{pp}}{n}} \leq \mu_p \leq \bar{x}_p + \sqrt{\frac{(n-1)p}{n-p} F_{p,n-p}(\alpha)} \sqrt{\frac{s_{pp}}{n}}$$

Tienen una **confianza simultánea** de $1 - \alpha$, la cuál no cambia para cualquier elección de $\mathbf{a}$.

Volviendo al ejemplo de sudoración de 20 mujeres, estos intervalos se estiman en R de la siguiente manera:

Intervalos simultáneos T^2 de Hotelling con sweat_data.txt

```
# ----- Intervalos simultaneos T2 Hotelling ----- #
install.packages("MVTests")
require(MVTests)
OneSampleHT2(sweat_data[,-1], mu0=c(4,50,10), alpha = 0.10)$CI

> OneSampleHT2(sweat_data[,-1], mu0=c(4,50,10), alpha = 0.10)$CI
      Lower      Upper Mu0 Important Variables?
X1_Sweat_rate 3.555292  5.724708      4          FALSE
X2_Sodium     36.364555 54.435445     50          FALSE
X3_Potassium   8.747476 11.182524     10          FALSE
```

	Intervalo	Longitud del IC	longitud IC simultaneos
μ_1	3.55 - 5.72	2.17	1.31
μ_2	36.36 - 54.43	18.07	10.93
μ_3	8.74 - 11.18	2.14	1.47

Observe que todos los intervalos contienen el respectivo valor de μ_0 . Además que la longitud de estos es superior a los intervalos simultaneos.

Intervalos de Bonferroni: Método para múltiples comparaciones

Son una alternativa a los intervalos de confianza simultaneos T^2 Hotelling, permitiendo que estos tengan mayor precisión.

Supóngase que, antes de la recolección de datos, se requieren declaraciones de confianza sobre m combinaciones lineales, es decir se quieren construir intervalos simultáneos para:

$$\mathbf{a}'_1\boldsymbol{\mu}, \mathbf{a}'_2\boldsymbol{\mu}, \dots, \mathbf{a}'_m\boldsymbol{\mu}$$

Intervalos de Confianza

Sea C_i un intervalo de $(1 - \alpha_i)100\%$ acerca del valor de $\mathbf{a}'_i\boldsymbol{\mu}$ tal que la probabilidad de acierto es:

$$P[C_i \text{ contiene } \mathbf{a}'_i\boldsymbol{\mu}] = 1 - \alpha_i, \quad i = 1, 2, \dots, m$$

Desigualdad de Bonferroni

A partir de la probabilidad conjunta de que todas las declaraciones sean verdaderas:

$$\begin{aligned}P[\text{todos } C_i \text{ contengan } \mathbf{a}'_i \boldsymbol{\mu}] &= 1 - P[\text{al menos un } C_i \text{ no contenga } \mathbf{a}'_i \boldsymbol{\mu}] \\&\geq 1 - \sum_{i=1}^m P(C_i \text{ no contenga } \mathbf{a}'_i \boldsymbol{\mu}) \\&= 1 - (\alpha_1 + \alpha_2 + \cdots + \alpha_m)\end{aligned}$$

denotando por $\alpha_i = \frac{\alpha}{m}$, $i = 1, \dots, m$

$$P[\text{todos } C_i \text{ contengan } \mathbf{a}'_i \boldsymbol{\mu}] \geq 1 - \left(\frac{\alpha}{m} + \cdots + \frac{\alpha}{m}\right) = 1 - \alpha$$

Estimaciones de Intervalos Simultáneos

Desarrollemos estimaciones para los componentes individuales μ_i de $\boldsymbol{\mu}$. Considerando los intervalos t individuales:

$$\bar{x}_i \pm t_{n-1} \left(\frac{\alpha_i}{2} \right) \sqrt{\frac{s_{ii}}{n}}, \quad i = 1, 2, \dots, m$$

Si definimos $\alpha_i = \alpha/m$, cada intervalo individual satisface:

$$P \left[\bar{x}_i \pm t_{n-1} \left(\frac{\alpha}{2m} \right) \sqrt{\frac{s_{ii}}{n}} \text{ contiene } \mu_i, \forall i \right] \geq 1 - \left(\frac{\alpha}{m} + \dots + \frac{\alpha}{m} \right) = 1 - \alpha$$

Por lo tanto, con un nivel de confianza global mayor o igual a $1 - \alpha$, podemos hacer las siguientes $m = p$ afirmaciones:

$$\begin{aligned} \bar{x}_1 - t_{n-1} \left(\frac{\alpha}{2p} \right) \sqrt{\frac{s_{11}}{n}} &\leq \mu_1 \leq \bar{x}_1 + t_{n-1} \left(\frac{\alpha}{2p} \right) \sqrt{\frac{s_{11}}{n}} \\ \bar{x}_2 - t_{n-1} \left(\frac{\alpha}{2p} \right) \sqrt{\frac{s_{22}}{n}} &\leq \mu_2 \leq \bar{x}_2 + t_{n-1} \left(\frac{\alpha}{2p} \right) \sqrt{\frac{s_{22}}{n}} \\ &\vdots \qquad \qquad \qquad \vdots \qquad \qquad \qquad \vdots \\ \bar{x}_p - t_{n-1} \left(\frac{\alpha}{2p} \right) \sqrt{\frac{s_{pp}}{n}} &\leq \mu_p \leq \bar{x}_p + t_{n-1} \left(\frac{\alpha}{2p} \right) \sqrt{\frac{s_{pp}}{n}} \end{aligned} \quad (5-29)$$



Listing 1: Intervalos simultáneos de Bonferroni

```
# ---- Intervalos simultaneos de Boferroni

ICB <- function(x, alpha, p, n){
  xbarra <- mean(x)
  sii    <- var(x)
  tc     <- qt(alpha/(2*p), n - 1, lower.tail = FALSE)
  error  <- tc * sqrt(sii / n)
  linf   <- xbarra - error
  lsup   <- xbarra + error
  ICB    <- c(linf, lsup)
  return(ICB)
}

ICB1 <- ICB(sweat_data$X1_Sweat_rate, 0.10, 3, 20)
ICB2 <- ICB(sweat_data$X2_Sodium, 0.10, 3, 20)
ICB3 <- ICB(sweat_data$X3_Potassium, 0.10, 3, 20)

l1 <- round(ICB1[2] - ICB1[1], 2)
l2 <- round(ICB2[2] - ICB2[1], 2) # Nota: corregido de ICB1 a ICB2
l3 <- round(ICB3[2] - ICB3[1], 2) # Nota: corregido de ICB1 a ICB3
```

Para los datos de `sweat_data.xlsx` los intervalos de Bonferroni son

	Intervalo	Longitud
μ_1	[3,77 , 5,51]	1,74
μ_2	[38,15 , 52,65]	14,5
μ_3	[8,99 , 10,94]	1,95

Observe que estos intervalos son **más cortos** que los simultáneos T^2 .

Control Global del Error

Permite al investigador controlar la tasa de error global en:

$$\alpha_1 + \alpha_2 + \cdots + \alpha_m$$

sin importar la estructura de correlación subyacente.

Flexibilidad

Ofrece flexibilidad para asignar tasas de error diferenciadas a grupos de declaraciones importantes frente a las menos relevantes.

Comparación: Intervalos de Bonferroni vs. T^2

Los intervalos de Bonferroni para combinaciones lineales $\mathbf{a}'\boldsymbol{\mu}$ y los intervalos T^2 análogos tienen la misma forma general:

$$\mathbf{a}'\bar{\mathbf{X}} \pm (\text{valor crítico}) \sqrt{\frac{\mathbf{a}'\mathbf{S}\mathbf{a}}{n}}$$

Por consiguiente, en cualquier instancia donde $\alpha_i = \alpha/m$:

$$\frac{\text{Longitud del intervalo de Bonferroni}}{\text{Longitud del intervalo } T^2} = \frac{t_{n-1} \left(\frac{\alpha}{2m} \right)}{\sqrt{\frac{p(n-1)}{n-p} F_{p, n-p}(\alpha)}} \quad (5-30)$$

Esta razón **no depende** de las cantidades aleatorias $\bar{\mathbf{X}}$ ni $\mathbf{S}$. Para un número pequeño m , los intervalos de Bonferroni suelen ser más cortos y fáciles de aplicar.

Comparación de Longitudes: Bonferroni vs. T^2

Para cualquier instancia con $\alpha_i = \alpha/m$, la razón de longitudes está dada por:

$$\frac{\text{Long. Bonferroni}}{\text{Long. } T^2} = \frac{t_{n-1} \left(\frac{\alpha}{2m} \right)}{\sqrt{\frac{p(n-1)}{n-p} F_{p, n-p}(\alpha)}} \quad (5-30)$$

Tabla 5.4 (Long. Bonferroni) / (Long. T^2 -Intervalo) para $1 - \alpha = ,95$ y $\alpha_i = ,05/m$

n	$m = p$		
	2	4	10
15	.88	.69	.29
25	.90	.75	.48
50	.91	.78	.58
100	.91	.80	.62
∞	.91	.81	.66

El método de Bonferroni proporciona intervalos más cortos cuando $m = p$ es pequeño, siendo muy útil y fácil de aplicar en inferencia.

- Johnson, R. A., & Wichern, D. W. (2013). *Applied Multivariate Statistical Analysis* (6th ed.). Pearson.
- Diapositivas de la profesora Lina Hernández.