

Análisis Multivariado ID 033521

Semana 5: Inferencia para la Varianza (Matriz de Covarianzas)

Profesora: Diana Marcela Martínez Ruiz

Facultad de Ciencias — Departamento de Matemáticas Pontificia Universidad Javeriana

Semestre 2630 — 2026

Introducción y Distribución Muestral

Sea $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ una muestra aleatoria de vectores p -variados de una población $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$.

El estimador de máxima verosimilitud (MLE) de $\boldsymbol{\Sigma}$ está dado por:

$$\hat{\boldsymbol{\Sigma}} = \frac{1}{n} \sum_{j=1}^n (\mathbf{x}_j - \bar{\mathbf{x}})(\mathbf{x}_j - \bar{\mathbf{x}})^\top = \frac{n-1}{n} \mathbf{S}$$

donde $\mathbf{S}$ es la matriz de covarianzas muestral insesgada.

Distribución Muestral:

$$n\hat{\boldsymbol{\Sigma}} = (n-1)\mathbf{S} \sim \text{Wishart}_p(\boldsymbol{\Sigma}, n-1)$$

Sea $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ una muestra aleatoria de vectores p -variados de una población $N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Entonces

$$\mathbf{W}_{p \times p} = \mathbf{X}\mathbf{X}^\top$$

es una **matriz de Wishart**, con $n - 1$ grados de libertad, matriz de covarianzas $\boldsymbol{\Sigma}$ y parámetro de **no centralidad**

$$\boldsymbol{\lambda} = \frac{1}{2} \boldsymbol{\mu}^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}$$

y se denota por

$$\mathbf{W} \sim \text{Wishart}_p(\boldsymbol{\Sigma}, n, \boldsymbol{\lambda})$$

Propiedades de la Distribución Wishart

La distribución de Wishart es la generalización multivariada de la distribución χ^2 . Sus propiedades clave para la inferencia son:

- $E[n\hat{\Sigma}] = E[(n-1)\mathbf{S}] = (n-1)\mathbf{\Sigma}$, por lo que $E[\mathbf{S}] = \mathbf{\Sigma}$.
- Si $\mathbf{B}$ es una matriz de dimensiones $k \times p$, entonces:

$$\mathbf{BSB}^\top \sim \text{Wishart}_k(\mathbf{B}\mathbf{\Sigma}\mathbf{B}^\top, n-1)$$

- La suma de matrices Wishart independientes sigue siendo Wishart. Es decir, si $W_1, \dots, W_q$ son matrices $p \times p$ **independientes** y $W_i \sim \text{Wishart}_p(\mathbf{\Sigma}, n-1)$, entonces

$$\sum_{i=1}^q \sim \text{Wishart}(\mathbf{\Sigma}, \sum_{i=1}^q n_i)$$

- Cualquier partición de la matriz $\mathbf{S}$ (por ejemplo, tomar un subconjunto de variables) también tiene distribución Wishart.

Sea $\mathbf{W} = \begin{pmatrix} \mathbf{W}_{11} & \mathbf{W}_{12} \\ \mathbf{W}_{21} & \mathbf{W}_{22} \end{pmatrix} \sim \mathcal{W}(\boldsymbol{\Sigma}, p, n)$, con

$\boldsymbol{\Sigma} = \begin{pmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{pmatrix}$, $\mathbf{W}_{11} \in \mathbb{R}^{k \times k}$ y $\boldsymbol{\Sigma}_{11} \in \mathbb{R}^{k \times k}$, entonces

- ★ $\mathbf{W}_{11} \sim \mathcal{W}(\boldsymbol{\Sigma}_{11}, k, n)$
- ★ $\mathbf{W}_{22} \sim \mathcal{W}(\boldsymbol{\Sigma}_{22}, p - k, n)$
- ★ Si $\boldsymbol{\Sigma}_{12} = \mathbf{0} \implies \mathbf{W}_{11}$ y $\mathbf{W}_{22}$ son independientes

Estructuras de la Matriz de Covarianzas

La complejidad del análisis está ligada a la estructura que asuma Σ :

- **Diagonal:** Se asume que no hay correlaciones (independencia lineal). Puede haber homocedasticidad (varianzas iguales) o heterocedasticidad (varianzas diferentes).

$$\Sigma = D = \begin{bmatrix} \sigma_{11} & 0 & \cdots & 0 \\ 0 & \sigma_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_{pp} \end{bmatrix}$$

- **Permutable (Correlación Uniforme):** Todas las variables están igualmente correlacionadas entre sí y tienen la misma varianza.

$$\Sigma = \sigma^2 \begin{bmatrix} 1 & \rho & \cdots & \rho \\ \rho & 1 & \cdots & \rho \\ \vdots & \vdots & \ddots & \vdots \\ \rho & \rho & \cdots & 1 \end{bmatrix}$$

- **Autoregresiva de Orden 1:** La covarianza disminuye exponencialmente a medida que aumenta la distancia entre sus índices (común en series de tiempo).

$$\Sigma = \begin{bmatrix} \sigma^2 & \rho\sigma^2 & \dots & \rho^{t-1}\sigma^2 \\ \rho\sigma^2 & \sigma^2 & \dots & \rho^{t-2}\sigma^2 \\ \vdots & \vdots & \ddots & \vdots \\ \rho^{t-1}\sigma^2 & \rho^{t-2}\sigma^2 & \dots & \sigma^2 \end{bmatrix}$$

- **No Estructurada:** No se asume ninguna restricción sobre Σ . Es muy flexible pero requiere estimar muchos parámetros $\left[\frac{1}{2}p(p+1)\right]$.

Inferencias sobre Σ Una sola población

Inferencia sobre Σ : Una Población

Sea $X_1, \dots, X_n$ una m.a de vectores p -variados de una población $N_p(\mu, \Sigma)$. Y queremos probar si la matriz de covarianzas poblacional es igual a una matriz dada Σ_0 (**no estructurada**):

$$H_0 : \Sigma = \Sigma_0 \text{ vs. } H_1 : \Sigma \neq \Sigma_0$$

La estadística de la prueba de Razón de Verosimilitud (LRT) para muestras grandes es:

$$\Lambda_1 = (n - 1) \left[\sum_{i=1}^p (\lambda_i - \ln \lambda_i) - p \right] \stackrel{H_0 \text{ cierta}}{\sim} \chi^2_{\left[\frac{1}{2}p(p+1)\right]}$$

donde $\lambda_1, \dots, \lambda_p$ son los autovalores de la matriz $\mathbf{S}\Sigma_0^{-1}$.

Decisión:

Se rechaza H_0 a un nivel de significancia α si $\Lambda_1 \geq \chi^2_{\left[\frac{1}{2}p(p+1)\right]}(\alpha)$.

Ejemplo

Se le midieron los tiempos (en centésimas de segundos) de reacción ante un estímulo a **20 sujetos**. Estos estímulos consisten en la preparación de los sujetos mediante **tres intervalos de tiempo** con duraciones diferentes. Asuma que los tiempos se distribuyen de acuerdo con una normal trivariada y que el interés es verificar si

$$\Sigma = \begin{bmatrix} 4 & 3 & 2 \\ 3 & 6 & 5 \\ 2 & 5 & 10 \end{bmatrix}$$

Sabiendo que la matriz de covarianzas muestrales es

$$S = \begin{bmatrix} 3,42 & 2,6 & 1,89 \\ 2,6 & 8 & 6,51 \\ 1,89 & 6,51 & 9,62 \end{bmatrix}$$

Ejemplo 1 en R: Prueba para Σ No Estructurada

```
#Valores dados en el problema

n <- 20; p <- 3
Sigma_0 <- matrix(c(4,3,2, 3,6,5, 2,5,10), ncol=3)
S <- matrix(c(3.42,2.6,1.89, 2.6,8,6.51, 1.89,6.51,9.62), ncol=3)

#Calculo de autovalores de S * Sigma_0^{-1}

auto <- eigen(S %*% solve(Sigma_0))
lambda_i <- auto$values

#Estadistico de prueba

Lambda1 <- (n-1) * (sum(lambda_i - log(lambda_i)) - p)

#Valor critico chi-cuadrado

vc <- qchisq(0.05, p*(1+p)/2, lower.tail=FALSE)

cat("Lambda1:", Lambda1, "| Valor critico:", vc, "\n")
```

Usando R encontramos los **autovalores** de $\mathbf{S}\Sigma_0^{-1}$:

$$\lambda_1 = 1,6225141 \quad \lambda_2 = 0,8633999 \quad \lambda_3 = 0,7357139$$

y

$$\Lambda_1 = 3,637404 \quad \chi^2_{\left[\frac{1}{2}p(p+1)\right]}(0,05) = 12,59159$$

Note que

$$\Lambda_1 = 3,6374 < 12,5916 = \chi^2_{\left[\frac{1}{2}p(p+1)\right]}(0,05)$$

por lo tanto, **NO** hay suficiente evidencia en la muestra para **rechazar** H_0 .

Inferencia sobre Σ : Casos Especiales

Si Σ_0 tiene estructuras particulares, las pruebas se simplifican:

1. Independencia y Heterocedasticidad (Σ_0 es Diagonal):

$$\Lambda_2 = -(n-1) \sum_{i=1}^p \ln \lambda_i \stackrel{H_0 \text{ verdad}}{\sim} \chi^2_{\left[\frac{1}{2}p(p-1)\right]}$$

Para un α dado se rechaza H_0 si $\Lambda_2 \geq \chi^2_{\left[\frac{1}{2}p(p+1)\right]}(\alpha)$

2. Independencia y Homocedasticidad ($\Sigma_0 = \sigma^2 \mathbf{I}$):

$$\Lambda_3 = - \left[(n-1) - \frac{2p^2 + p + 2}{6p} \right] \ln(\Lambda^*) \stackrel{H_0}{\sim} \chi^2_{\left[\frac{1}{2}p(p+1)-1\right]}$$

donde $\Lambda^* = \frac{p^p \prod_{i=1}^p \lambda_i}{(\sum_{i=1}^p \lambda_i)^p}$ y λ_i son los autovalores de $\mathbf{S}$.

Ejemplo 2

Un proceso industrial fabrica elementos cuyas características de calidad se miden por un vector de **tres variables**. Cuando el **proceso** está en estado de **control**, los **valores medios de las variables** deben ser (12,4,2). Para comprobar si el proceso funciona adecuadamente, se toma una **muestra de 20 elementos** y se miden las tres características, encontrando que:

$$\bar{\mathbf{x}} = \begin{bmatrix} 11,5 \\ 4,3 \\ 1,2 \end{bmatrix} \quad \mathbf{S} = \begin{bmatrix} 10 & 4 & -5 \\ 4 & 12 & -3 \\ -5 & -3 & 4 \end{bmatrix}$$

Verifique si es posible pensar que las **variables** son **independientes**, con **varianzas iguales a las estimadas**.

Solución:

El interés es probar

$$H_0 : \Sigma = \Sigma_0$$

$$H_1 : \Sigma \neq \Sigma_0$$

donde

$$\Sigma_0 = \begin{bmatrix} 10 & 0 & 0 \\ 0 & 12 & 0 \\ 0 & 0 & 4 \end{bmatrix}$$

En este caso, usamos

$$\Lambda_2 = -(n-1) \sum_{i=1}^p \ln \lambda_i \stackrel{H_0 \text{ verd.}}{\sim} \chi^2_{\left[\frac{1}{2}p(p-1)\right]}$$

Ejemplo 2 en R: Independencia y Heterogeneidad

```
n <- 20; p <- 3
S <- matrix(c(10,4,-5, 4,12,-3, -5,-3,4), ncol=3)
Sigma0 <- matrix(c(10,0,0, 0,12,0, 0,0,4), ncol=3)

#Autovalores

auto <- eigen(S %*% solve(Sigma0))
lambdai <- auto$values

#Estadística de prueba

Lambda2 <- -(n-1)*sum(log(lambdai))

Valor critico

vc <- qchisq(0.05, (1/2)p(p-1), lower.tail=FALSE)

cat("Lambda2:", Lambda2, "| Valor critico:", vc, "\n")
```

Conclusión: $\Lambda_2 = 22,61 > 7,81$. Sí se rechaza H_0 . Existe dependencia entre las variables.

Homogeneidad de Matrices (Varias Poblaciones)

Si tenemos q poblaciones independientes con distribución $N_p(\boldsymbol{\mu}_g, \boldsymbol{\Sigma}_g)$, con $g = 1, \dots, q$ y queremos probar la igualdad de sus matrices de covarianza (homocedasticidad multivariada):

$$H_0 : \boldsymbol{\Sigma}_1 = \boldsymbol{\Sigma}_2 = \dots = \boldsymbol{\Sigma}_q = \boldsymbol{\Sigma} \text{ vs. } H_1 : \text{Al menos una } \boldsymbol{\Sigma}_g \text{ es diferente}$$

La estadística de prueba es

$$\Lambda = \nu \ln(|\mathbf{S}_p|) - \sum_{g=1}^q \nu_g \ln(|\mathbf{S}_g|)$$

con $\nu_g = n_g - 1$, $\nu = \sum \nu_g$, ρ un factor de corrección y $\mathbf{S}_p = \frac{1}{\nu} \sum \nu_g \mathbf{S}_g$ la matriz de covarianza común ponderada (pooled).

Asintóticamente

$$\varphi = \rho \Lambda \stackrel{H_0 \text{ verd.}}{\sim} \chi^2_{\left[\frac{1}{2}p(p+1)(q-1)\right]}$$

donde

$$\rho = 1 - \frac{2p^2 + 3p - 1}{6(p+1)(q-1)} \left[\sum_{g=1}^q \frac{1}{v_g} - \frac{1}{v} \right]$$

Para un nivel de significancia α , se **rechaza** H_0 si

$$\varphi \geq \chi^2_{\left[\frac{1}{2}p(p+1)(q-1)\right]}(\alpha)$$

Ejemplo 3

La longitud (cm) del fémur y el tiempo empleado para recorrer una distancia de 100 m a “paso normal” fue medida en **26 personas** que trabajan en **oficinas**, **23** trabajan como **operadores de máquinas** y **25** trabajan como **conductores**. Se quiere verificar

$$H_0 : \Sigma_1 = \Sigma_2 = \Sigma_3$$

$$H_0 : \text{al menos una } \Sigma_g \text{ es diferente}$$

A partir de las **muestras** se obtuvo

$$S_1 = \begin{bmatrix} 12,65 & -16,45 \\ -16,45 & 73,04 \end{bmatrix}$$

$$S_2 = \begin{bmatrix} 11,44 & -27,77 \\ -27,77 & 100,64 \end{bmatrix}$$

$$S_3 = \begin{bmatrix} 14,46 & -31,26 \\ -31,26 & 101,03 \end{bmatrix}$$

Ejemplo 3 en R: Homogeneidad de Σ en Grupos

```
p <- 2; q <- 3; n1 <- 26; n2 <- 23; n3 <- 25
v1 <- n1-1; v2 <- n2-1; v3 <- n3-1; v <- v1+v2+v3

S1 <- matrix(c(12.65, -16.45, -16.45, 73.04), ncol=2)
S2 <- matrix(c(11.44, -27.77, -27.77, 100.64), ncol=2)
S3 <- matrix(c(14.46, -31.26, -31.26, 101.03), ncol=2)

Sp <- (1/v)(v1S1 + v2S2 + v3S3)
Lambda3 <- vlog(det(Sp)) - (v1log(det(S1)) + v2log(det(S2)) + v3log(det(S3)))

b <- (1/v1 + 1/v2 + 1/v3 - 1/v)
rho <- 1 - (2p^2 + 3p - 1)/(6*(p+1)*(q-1)) * b
varphi <- rho * Lambda3

vc <- qchisq(0.05, (1/2)p(p+1)*(q-1), lower.tail=FALSE)
```

Conclusión: $\varphi = 6,647 < 12,591$. NO se rechaza H_0 . Las variabilidades entre los 3 grupos pueden asumirse iguales.

Independencia entre Grupos de Variables

Suponga que tenemos un vector dividido en dos subconjuntos de tamaño p y q , y queremos verificar su independencia (no correlación):

$$[\mathbf{X}(1) \ \mathbf{X}(2)] \sim N_{p+q} \left([\boldsymbol{\mu}_{(1)} \ \boldsymbol{\mu}_{(2)}], [\boldsymbol{\Sigma}_{11} \ \boldsymbol{\Sigma}_{12} \ \boldsymbol{\Sigma}_{21} \ \boldsymbol{\Sigma}_{22}] \right)$$

Queremos probar $H_0 : \boldsymbol{\Sigma}_{12} = \mathbf{0}$ (o equivalentemente $\boldsymbol{\Sigma}_{21} = \mathbf{0}$).

La estadística de prueba asintótica es $\varphi^* = -2\rho\Lambda^* \stackrel{H_0}{\sim} \chi_{pq}^2$, donde:

$$\Lambda^* = \frac{n}{2} \sum_{i=1}^p \ln(1 - \lambda_i), \quad \rho = 1 - \frac{p + q + 3}{2n}$$

y λ_i son los autovalores de $\mathbf{S}_{12}\mathbf{S}_{22}^{-1}\mathbf{S}_{21}\mathbf{S}_{11}^{-1}$.

Ejemplo 3

Un investigador en cultivos tomó **40 árboles de durazno**, de edades semejantes, midió

- el diámetro (cm) del tronco principal (x_1)
- el área (cm^2) foliar (x_2)
- tiempo (días) para la maduración del fruto (x_3)
- el peso (gm) en pulpa por fruto (x_3)

Estas medidas son el promedio de algunas mediciones preliminares, es el caso del peso por fruto el cual corresponde al promedio del peso de frutos tomados aleatoriamente de la parte inferior, media y superior de cada árbol. Con los datos recogidos (redondeados para facilitar cálculos) se **estimó la matriz de covarianzas**:

$$\mathbf{S} = \begin{bmatrix} 2 & 5 & 1 & 1 \\ 5 & 15 & 1 & 2 \\ 1 & 1 & 5 & 3 \\ 1 & 2 & 3 & 2 \end{bmatrix}$$

El objetivo es **verificar** la hipótesis que **la contextura del árbol está relacionada con la calidad del fruto que produce**. Específicamente, que estas **variables fisiológicas** $\mathbf{X}_{(1)} = \{x_1, x_2\}$ están asociadas con las **variables morfológicas** $\mathbf{X}_{(2)} = \{x_3, x_4\}$ o de estructura del árbol.

Solución:

Tenemos que

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \dots \\ X_3 \\ X_4 \end{bmatrix} = \begin{bmatrix} \mathbf{X}_{(1)} \\ \dots \\ \mathbf{X}_{(2)} \end{bmatrix} \sim N_{p+q} \left(\begin{bmatrix} \boldsymbol{\mu}_{(1)} \\ \boldsymbol{\mu}_{(2)} \end{bmatrix}, \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{bmatrix} \right)$$

$p = 2 = q$ y

$$\mathbf{S} = \begin{bmatrix} 2 & 5 & \vdots & 1 & 1 \\ 5 & 15 & \vdots & 1 & 2 \\ \dots & \dots & \dots & \dots & \dots \\ 1 & 1 & \vdots & 5 & 3 \\ 1 & 2 & \vdots & 3 & 2 \end{bmatrix}$$

de ahí

$$\mathbf{S}_{11} = \begin{bmatrix} 2 & 5 \\ 5 & 15 \end{bmatrix} \quad \mathbf{S}_{12} = \mathbf{S}_{21} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix} \quad \mathbf{S}_{22} = \begin{bmatrix} 5 & 3 \\ 3 & 2 \end{bmatrix}$$

Usando R tenemos los autovalores de $\mathbf{S}_{12}\mathbf{S}_{22}^{-1}\mathbf{S}_{21}\mathbf{S}_{11}^{-1}$:

$$\lambda_1 = 0,7236068 \quad \lambda_2 = 0,2763932$$

y

$$\begin{aligned} \Lambda^* &= -32,18876 & \rho &= 0,9125 \\ \varphi^* &= 58,74448 & \chi_{pq}^2(0,01) &= 13,2767 \end{aligned}$$

$$\varphi^* = 58,74448 > 13,2767 = \chi_{pq}^2(0,01)$$

por lo que **HAY suficiente evidencia** en la muestra para **rechazar** H_0 , es decir que **existe alguna clase de dependencia entre estos pares de variables** o equivalentemente, la **calidad del fruto está asociada con la estructura del árbol**.

Ejemplo 4 en R: Independencia por Particiones

```
n <- 40; p <- 2; q <- 2
S11 <- matrix(c(2,5, 5,15), ncol=2)
S12 <- matrix(c(1,1, 1,2), ncol=2)
S22 <- matrix(c(5,3, 3,2), ncol=2)

#Se asume S21 = t(S12)

Matriz <- S12 %% solve(S22) %% t(S12) %% solve(S11)
lambdai <- eigen(Matriz)$values

#Estadístico de prueba
Lambda <- (n/2) * sum(log(1 - lambdai))
rho <- 1 - ((p + q + 3)/(2*n))
varphi <- -2 * rho * Lambda

#Valor critico
vc <- qchisq(0.01, pq, lower.tail=FALSE)
```

Conclusión: $\varphi = 58,74 > 13,27$. Se rechaza H_0 . Los dos grupos de variables están correlacionados.