

# Análisis de Componentes Principales (ACP)

¿Cómo describir un conjunto de datos multivariado mediante nuevas variables no correlacionadas?

Profesora: Diana Marcela Martínez Ruiz

Facultad de Ciencias – Departamento de Matemáticas  
Pontificia Universidad Javeriana

Semana 7 – Material de estudio autónomo

# ¿Cómo usar este material?

Esta presentación está diseñada para estudiarse de manera **autónoma** antes de la próxima clase.

- Está basada en el capítulo 8 de Johnson & Wichern (2007) y en el capítulo 5 de Díaz (2007).
- Cada bloque sigue la secuencia: **objetivo** → **intuición** → **ejemplo** → **advertencia**.
- Los cuadros marcados con **Verifique en R** pueden reproducirse línea a línea; hágalo.
- Al final hay **dos ejercicios en R** que revisaremos en la próxima sesión.

## Pregunta que guía toda la sesión

Si tengo  $p$  variables correlacionadas medidas sobre  $n$  individuos, ¿puedo construir unas *pocas* variables nuevas, *no correlacionadas entre sí*, que conserven casi toda la información (variabilidad) de las originales?

- 1 Motivación y objetivos del ACP
- 2 Interpretación geométrica
- 3 Generación de las componentes principales
- 4 Selección del número de componentes
- 5 Síntesis y ejercicios

- 1 Motivación y objetivos del ACP
- 2 Interpretación geométrica
- 3 Generación de las componentes principales
- 4 Selección del número de componentes
- 5 Síntesis y ejercicios

# El problema: muchas variables, poca comprensión

En las etapas iniciales de una investigación suele haber poca teoría, así que se miden *muchas* variables “por si acaso”.

- Con  $p = 10$  variables hay que estimar  $\binom{10}{2} = 45$  correlaciones.
- Con  $p = 20$ , ya son 190.
- Con  $p = 50$ , son 1225.

Dos dificultades crecen con  $p$ :

- 1 **Estimación:** muchos parámetros para pocos datos.
- 2 **Comprensión:** nadie “ve” una nube de puntos en  $\mathbb{R}^{50}$ .

## Idea del ACP

Transformar las  $p$  variables originales en un conjunto *más pequeño* de variables nuevas, que son **combinaciones lineales** de las primeras y que contienen **la mayor parte de la variabilidad** del conjunto inicial.

El ACP es un método de **interdependencia**: no hay variable respuesta; todas las variables juegan el mismo papel. En lenguaje de *machine learning*: es **aprendizaje no supervisado** y una técnica de *extracción de características*.

# Objetivos del análisis en componentes principales

## Según Díaz (2007):

- Generar nuevas variables que expresen la información contenida en el conjunto de datos.
- Reducir la dimensión del espacio donde están inscritos los datos.
- Eliminar (si es posible) las variables que aporten poco al estudio.
- Facilitar la interpretación de la información contenida en los datos.

## Según Johnson & Wichern (2007):

- Explicar la estructura de varianzas–covarianzas de un conjunto de variables mediante *unas pocas combinaciones lineales*.
- Dos objetivos generales: **(1) reducción de datos** y **(2) interpretación**.
- El ACP suele ser un *medio*, no un fin: sus componentes alimentan regresiones, análisis de conglomerados, análisis factorial, etc.

## Advertencia

El ACP es una metodología **matemática**: no requiere suponer ninguna distribución de probabilidad. La normalidad sólo se necesita para hacer *inferencia* sobre las componentes (y da una interpretación geométrica muy bonita, como veremos).

# Las propiedades “deseables” de las nuevas variables

Buscamos nuevas variables  $Y_1, \dots, Y_p$  tales que:

- 1 Cada  $Y_i$  es una **combinación lineal** de las originales:  $Y_i = a_{i1}X_1 + \dots + a_{ip}X_p = \mathbf{a}_i'\mathbf{X}$ .
- 2 Las  $Y_i$  están **ordenadas por varianza**:  $\text{Var}(Y_1) \geq \text{Var}(Y_2) \geq \dots \geq \text{Var}(Y_p)$ .
- 3 Las  $Y_i$  son **no correlacionadas** entre sí:  $\text{Cov}(Y_i, Y_k) = 0$  para  $i \neq k$ .
- 4 La **variabilidad total se conserva**:  $\sum_i \text{Var}(X_i) = \sum_i \text{Var}(Y_i)$ .

## Consecuencia

Si las primeras  $k \ll p$  componentes retienen (por ejemplo) el 80–90 % de la variabilidad total, la matriz de datos de  $n \times p$  puede **reemplazarse** por una de  $n \times k$  “sin mucha pérdida de información”.

**Caso trivial.** Si las  $X_i$  ya son no correlacionadas, el ACP “no tiene nada que hacer”: la primera componente es la variable de mayor varianza, la segunda la de segunda mayor varianza, y así sucesivamente.

# Contenido

- 1 Motivación y objetivos del ACP
- 2 Interpretación geométrica**
- 3 Generación de las componentes principales
- 4 Selección del número de componentes
- 5 Síntesis y ejercicios

## Un ejemplo con dos variables (Díaz, Tabla 5.1)

| Obs.     | $X_1$  | $X_1^*$ | $X_2$  | $X_2^*$ |
|----------|--------|---------|--------|---------|
| 1        | 16     | 8       | 8      | 5       |
| 2        | 12     | 4       | 10     | 7       |
| 3        | 13     | 5       | 6      | 3       |
| 4        | 11     | 3       | 2      | -1      |
| 5        | 10     | 2       | 8      | 5       |
| 6        | 9      | 1       | -1     | -4      |
| 7        | 8      | 0       | 4      | 1       |
| 8        | 7      | -1      | 6      | 3       |
| 9        | 5      | -3      | -3     | -6      |
| 10       | 3      | -5      | -1     | -4      |
| 11       | 2      | -6      | -3     | -6      |
| 12       | 0      | -8      | 0      | -3      |
| Media    | 8      | 0       | 3      | 0       |
| Varianza | 23.091 | 23.091  | 21.091 | 21.091  |


$X_j^* = X_j - \bar{X}_j$  son los datos **centrados** (corregidos por la media).

$$\mathbf{S} = \begin{pmatrix} 23.091 & 16.455 \\ 16.455 & 21.091 \end{pmatrix}, \quad \mathbf{R} = \begin{pmatrix} 1 & 0.746 \\ 0.746 & 1 \end{pmatrix}$$

- Varianza total:  $\text{tr}(\mathbf{S}) = 23.091 + 21.091 = 44.182$ .
- $X_1$  retiene el 52.26 % y  $X_2$  el 47.74 % de esa variabilidad.
- Las dos variables están claramente correlacionadas ( $r = 0.746$ ): hay información *redundante*.

**Pregunta:** ¿existe una dirección en el plano en la que los datos “se esparzan” más que a lo largo de  $X_1$  o de  $X_2$ ?

Proyectar sobre un nuevo eje  $Y_1$  que forma un ángulo  $\theta$  con  $X_1^*$



Datos centrados (●) y sus proyecciones sobre  $Y_1$  para  $\theta = 10^\circ$ .

Por geometría elemental, la coordenada de cada punto sobre el eje  $Y_1$  es

$$y_1 = \cos \theta x_1^* + \sin \theta x_2^*.$$


Para  $\theta = 10^\circ$ :

$$\begin{aligned} y_1 &= 0.985 x_1^* + 0.174 x_2^* \\ &= 0.985(x_1 - 8) + 0.174(x_2 - 3) \\ &= -8.402 + 0.985 x_1 + 0.174 x_2. \end{aligned}$$

- La nueva variable  $Y_1$  sigue centrada (media 0).
- $\text{Var}(Y_1) = 28.659$ , es decir, retiene el  $28.659/44.182 = 64.87\%$  de la variabilidad total.
- ¡Más que cualquiera de las dos variables originales!

## ¿Qué ángulo retiene la máxima varianza?


| Ángulo $\theta$ | $\text{Var}(Y_1)$ | % retenido   |
|-----------------|-------------------|--------------|
| 0               | 23.091            | 52.26        |
| 10              | 28.659            | 64.87        |
| 20              | 33.434            | 75.68        |
| 30              | 36.841            | 83.39        |
| 40              | 38.469            | 87.07        |
| <b>43.261</b>   | <b>38.576</b>     | <b>87.31</b> |
| 50              | 38.122            | 86.28        |
| 60              | 35.841            | 81.12        |
| 70              | 31.902            | 72.20        |
| 80              | 26.779            | 60.60        |
| 90              | 21.091            | 47.77        |



Hay un único eje óptimo

$\text{Var}(Y_1)$  crece con  $\theta$ , alcanza su máximo en  $\theta \approx 43.261^\circ$  y luego decrece. Ese eje es la **primera componente principal**.

# Las dos componentes principales del ejemplo



Nuevos ejes ortogonales  $Y_1$  y  $Y_2$  con  $\theta = 43.261^\circ$ .

**Primera componente** ( $\theta = 43.261^\circ$ ):

$$y_1 = 0.728 x_1^* + 0.685 x_2^* = -7.879 + 0.728 x_1 + 0.685 x_2$$

**Segunda componente** (ortogonal a  $Y_1$ ; forma el mismo ángulo  $\theta$  con  $X_2^*$ ):

$$y_2 = -\sin \theta x_1^* + \cos \theta x_2^* = -0.685 x_1^* + 0.728 x_2^*$$

$$\mathbf{S}_Y = \begin{pmatrix} 38.576 & 0 \\ 0 & 5.606 \end{pmatrix}, \quad \mathbf{R}_Y = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

- $Y_1$  retiene el 87.31 % y  $Y_2$  el 12.69 %.
- $38.576 + 5.606 = 44.182$ : la variabilidad total **no** cambió.
- $\text{Cov}(Y_1, Y_2) = 0$ : las componentes son **no** correlacionadas.

## Puntajes de las componentes (Díaz, Tabla 5.4)


| Obs.     | $X_1^*$ | $X_2^*$ | $Y_1$  | $Y_2$  |
|----------|---------|---------|--------|--------|
| 1        | 8       | 5       | 9.253  | -1.841 |
| 2        | 4       | 7       | 7.710  | 2.356  |
| 3        | 5       | 3       | 5.697  | -1.242 |
| 4        | 3       | -1      | 1.499  | -2.784 |
| 5        | 2       | 5       | 4.883  | 2.271  |
| 6        | 1       | -4      | -2.013 | -3.598 |
| 7        | 0       | 1       | 0.685  | 0.728  |
| 8        | -1      | 3       | 1.328  | 2.870  |
| 9        | -3      | -6      | -6.297 | -2.313 |
| 10       | -5      | -4      | -6.382 | 0.514  |
| 11       | -6      | -6      | -8.481 | -0.257 |
| 12       | -8      | -3      | -7.882 | 3.298  |
| Media    | 0       | 0       | 0      | 0      |
| Varianza | 23.091  | 21.091  | 38.576 | 5.606  |

### Lo que aprendimos de la ilustración:

- 1 La *configuración* de los puntos no cambia: sólo cambiamos el sistema de coordenadas (una **rotación rígida**).
- 2 Las proyecciones sobre los ejes nuevos son los valores de las nuevas variables. Los ejes se llaman **componentes principales** y sus valores, **puntajes** (*scores*).
- 3 Cada nueva variable es combinación lineal de las originales y sigue centrada.
- 4 La variabilidad total se conserva bajo transformaciones ortogonales.
- 5  $Y_1$  reúne más varianza que cualquier variable original;  $Y_2$  reúne la que quedó.
- 6 Las nuevas variables son no correlacionadas.

**Verifique en R:**  $\cos(43.261^\circ) = 0.728$  y  $\sin(43.261^\circ) = 0.685$  son exactamente las entradas del primer vector propio de  $S$ .

# Generalización a $p$ dimensiones: la “mejor” recta por mínimos cuadrados



Cada individuo  $Q_i \in \mathbb{R}^p$  se proyecta sobre  $CP_1$ , generada por  $\mathbf{u}$ .

Sea  $\mathbf{X}$  la matriz de datos *centrada* ( $n \times p$ ). Buscamos la recta por el origen que “mejor” ajuste la nube de  $n$  puntos.

- La proyección de la fila  $\mathbf{x}'_i$  sobre  $\mathbf{u}$  (unitario) es  $\mathbf{x}'_i \mathbf{u}$ ; todas las proyecciones:  $\mathbf{X}\mathbf{u}$ .
- Por Pitágoras en cada triángulo  $OP_iQ_i$ :  
$$\sum_i (Q_i P_i)^2 = \sum_i (OQ_i)^2 - \sum_i (OP_i)^2.$$
- Como  $\sum_i (OQ_i)^2$  está fijo, **minimizar** las distancias a la recta equivale a **maximizar**

$$\sum_{i=1}^n (OP_i)^2 = (\mathbf{X}\mathbf{u})'(\mathbf{X}\mathbf{u}) = \mathbf{u}'\mathbf{X}'\mathbf{X}\mathbf{u}, \quad \text{s.a. } \mathbf{u}'\mathbf{u} = 1.$$

## Resultado (Lagrange)

$\mathbf{X}'\mathbf{X}\mathbf{u} = \lambda\mathbf{u}$ :  $\mathbf{u}_1$  es el vector propio del mayor valor propio  $\lambda_1$  de  $\mathbf{X}'\mathbf{X}$  y el máximo vale  $\lambda_1$ ;  $\mathbf{u}_2 \perp \mathbf{u}_1$  es el del segundo valor propio, y así sucesivamente.

# Interpretación bajo normalidad: los ejes del elipsoide




Figura 8.1 de J&W: elipse de densidad constante y componentes principales.

Si  $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ , la densidad es constante sobre los elipsoides

$$(\mathbf{x} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) = c^2,$$

cuyos ejes son  $\pm c \sqrt{\lambda_i} \mathbf{e}_i$ , con  $(\lambda_i, \mathbf{e}_i)$  los pares valor–vector propio de  $\boldsymbol{\Sigma}$ .

Escribiendo  $y_i = \mathbf{e}_i' (\mathbf{x} - \boldsymbol{\mu})$  (con  $\boldsymbol{\mu} = \mathbf{0}$ ):

$$c^2 = \frac{1}{\lambda_1} y_1^2 + \frac{1}{\lambda_2} y_2^2 + \cdots + \frac{1}{\lambda_p} y_p^2.$$

- El **eje mayor** del elipsoide va en la dirección  $\mathbf{e}_1$  (mayor  $\lambda_1$ ); los menores, en  $\mathbf{e}_2, \dots, \mathbf{e}_p$ .
- Las componentes se obtienen **rotando** los ejes originales un ángulo  $\theta$  hasta que coincidan con los ejes del elipsoide (vale para cualquier  $p$ ).
- Bajo normalidad, no correlacionadas  $\Rightarrow$  **independientes**.

# Contenido

- 1 Motivación y objetivos del ACP
- 2 Interpretación geométrica
- 3 Generación de las componentes principales**
- 4 Selección del número de componentes
- 5 Síntesis y ejercicios

## Planteamiento poblacional (J&W, sección 8.2)

Sea  $\mathbf{X}' = [X_1, \dots, X_p]$  un vector aleatorio con matriz de covarianzas  $\Sigma$  y valores propios  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$ . Considere las combinaciones lineales

$$Y_i = \mathbf{a}_i' \mathbf{X} = a_{i1}X_1 + a_{i2}X_2 + \dots + a_{ip}X_p, \quad i = 1, \dots, p.$$

Entonces

$$\text{Var}(Y_i) = \mathbf{a}_i' \Sigma \mathbf{a}_i, \quad \text{Cov}(Y_i, Y_k) = \mathbf{a}_i' \Sigma \mathbf{a}_k.$$

### Definición secuencial

Primera CP: la combinación  $\mathbf{a}_1' \mathbf{X}$  que **maximiza**  $\text{Var}(\mathbf{a}_1' \mathbf{X})$  sujeto a  $\mathbf{a}_1' \mathbf{a}_1 = 1$ .

Segunda CP: la combinación  $\mathbf{a}_2' \mathbf{X}$  que maximiza  $\text{Var}(\mathbf{a}_2' \mathbf{X})$  sujeto a  $\mathbf{a}_2' \mathbf{a}_2 = 1$  y  $\text{Cov}(\mathbf{a}_1' \mathbf{X}, \mathbf{a}_2' \mathbf{X}) = 0$ .

$i$ -ésima CP: la combinación  $\mathbf{a}_i' \mathbf{X}$  que maximiza  $\text{Var}(\mathbf{a}_i' \mathbf{X})$  sujeto a  $\mathbf{a}_i' \mathbf{a}_i = 1$  y  $\text{Cov}(\mathbf{a}_i' \mathbf{X}, \mathbf{a}_k' \mathbf{X}) = 0$ ,  $k < i$ .

**¿Por qué la restricción  $\mathbf{a}_i' \mathbf{a}_i = 1$ ?** Porque  $\text{Var}(c \mathbf{a}_i' \mathbf{X}) = c^2 \text{Var}(\mathbf{a}_i' \mathbf{X})$ : sin ella, la varianza se podría hacer tan grande como se quiera simplemente multiplicando  $\mathbf{a}_1$  por una constante. La norma unitaria elimina esa indeterminación.

## Resultado 8.1: las componentes son los vectores propios de $\Sigma$

### Resultado 8.1 (J&W)

Sean  $(\lambda_1, \mathbf{e}_1), \dots, (\lambda_p, \mathbf{e}_p)$  los pares valor–vector propio de  $\Sigma$ , con  $\lambda_1 \geq \dots \geq \lambda_p \geq 0$  y  $\mathbf{e}_i' \mathbf{e}_i = 1$ . La  $i$ -ésima componente principal es

$$Y_i = \mathbf{e}_i' \mathbf{X} = e_{i1}X_1 + e_{i2}X_2 + \dots + e_{ip}X_p, \quad i = 1, \dots, p,$$

y con esta elección

$$\text{Var}(Y_i) = \mathbf{e}_i' \Sigma \mathbf{e}_i = \lambda_i, \quad \text{Cov}(Y_i, Y_k) = \mathbf{e}_i' \Sigma \mathbf{e}_k = 0 \quad (i \neq k).$$

**Equivalente en Díaz (5.9–5.10):** con multiplicadores de Lagrange, maximizar  $\Gamma' \Sigma \Gamma$  s.a.  $\Gamma' \Gamma = 1$  lleva a  $(\Sigma - \lambda \mathbf{I})\Gamma = \mathbf{0}$ , cuya solución no trivial exige  $|\Sigma - \lambda \mathbf{I}| = 0$ : la *ecuación característica*.

**Advertencia:** si hay valores propios repetidos, los vectores propios (y por tanto las  $Y_i$ ) no son únicos.

## Resultado 8.2: la varianza total se conserva

Por la descomposición espectral  $\Sigma = \mathbf{P}\mathbf{\Lambda}\mathbf{P}'$  con  $\mathbf{P} = [\mathbf{e}_1, \dots, \mathbf{e}_p]$  ortogonal y  $\mathbf{\Lambda} = \text{Diag}(\lambda_1, \dots, \lambda_p)$ :

$$\text{tr}(\Sigma) = \text{tr}(\mathbf{P}\mathbf{\Lambda}\mathbf{P}') = \text{tr}(\mathbf{\Lambda}\mathbf{P}'\mathbf{P}) = \text{tr}(\mathbf{\Lambda}) = \lambda_1 + \dots + \lambda_p.$$

### Resultado 8.2 (J&W)

$$\underbrace{\sigma_{11} + \sigma_{22} + \dots + \sigma_{pp}}_{\text{varianza total poblacional}} = \sum_{i=1}^p \text{Var}(X_i) = \lambda_1 + \lambda_2 + \dots + \lambda_p = \sum_{i=1}^p \text{Var}(Y_i).$$

En consecuencia,

$$\left( \begin{array}{c} \text{proporción de la varianza total} \\ \text{explicada por la } k\text{-ésima CP} \end{array} \right) = \frac{\lambda_k}{\lambda_1 + \lambda_2 + \dots + \lambda_p}, \quad k = 1, \dots, p.$$

Si para  $p$  grande el 80–90 % de la varianza total se atribuye a una, dos o tres componentes, éstas pueden “reemplazar” las  $p$  variables originales sin mucha pérdida de información.

En notación matricial (Díaz 5.13–5.15):  $\mathbf{Y} = \mathbf{\Gamma}'\mathbf{X}$  y  $\text{Cov}(\mathbf{Y}) = \mathbf{\Gamma}'\Sigma\mathbf{\Gamma} = \mathbf{\Gamma}'\mathbf{\Gamma}\mathbf{\Lambda}\mathbf{\Gamma}'\mathbf{\Gamma} = \mathbf{\Lambda}$ , diagonal.

## Resultado 8.3: ¿cómo leer una componente?

Hay dos formas de medir la importancia de la variable  $X_k$  en la componente  $Y_i$ :

**(a) Los coeficientes**  $e_{ik}$

La magnitud de  $e_{ik}$  mide la contribución de  $X_k$  a  $Y_i$  *en presencia de las demás variables* (Rencher recomienda usar sólo éstos).

**(b) Las correlaciones**  $\rho_{Y_i, X_k}$

Miden sólo la contribución *univariada* de  $X_k$  a  $Y_i$ , pero corrigen por las diferencias de escala de las variables.

### Resultado 8.3 (J&W)

Si  $Y_i = \mathbf{e}_i' \mathbf{X}$  son las componentes principales obtenidas de  $\Sigma$ , entonces  $\rho_{Y_i, X_k} = \frac{e_{ik} \sqrt{\lambda_i}}{\sqrt{\sigma_{kk}}}$ ,  $i, k = 1, \dots, p$ .

**Demostración.** Con  $\mathbf{a}_k' = [0, \dots, 1, \dots, 0]$ ,  $X_k = \mathbf{a}_k' \mathbf{X}$  y  $\text{Cov}(X_k, Y_i) = \mathbf{a}_k' \Sigma \mathbf{e}_i = \mathbf{a}_k' \lambda_i \mathbf{e}_i = \lambda_i e_{ik}$ . Luego

$$\rho_{Y_i, X_k} = \frac{\lambda_i e_{ik}}{\sqrt{\lambda_i} \sqrt{\sigma_{kk}}} = \frac{e_{ik} \sqrt{\lambda_i}}{\sqrt{\sigma_{kk}}}.$$

### Recomendación de J&W

Examinar **ambas** medidas. En la práctica, variables con coeficientes grandes (en valor absoluto) suelen tener correlaciones grandes, y los dos rankings rara vez difieren de forma *apreciable*.

## Ejemplo 8.1 (J&W): componentes de una población con $p = 3$

Suponga que  $X_1, X_2, X_3$  tienen matriz de covarianzas

$$\Sigma = \begin{pmatrix} 1 & -2 & 0 \\ -2 & 5 & 0 \\ 0 & 0 & 2 \end{pmatrix} \implies \begin{aligned} \lambda_1 &= 5.83, & \mathbf{e}'_1 &= [0.383, -0.924, 0] \\ \lambda_2 &= 2.00, & \mathbf{e}'_2 &= [0, 0, 1] \\ \lambda_3 &= 0.17, & \mathbf{e}'_3 &= [0.924, 0.383, 0] \end{aligned}$$

Las componentes principales son  $Y_1 = 0.383X_1 - 0.924X_2$ ,  $Y_2 = X_3$ ,  $Y_3 = 0.924X_1 + 0.383X_2$ .

**Verificación directa:**

$$\begin{aligned} \text{Var}(Y_1) &= (0.383)^2(1) + (-0.924)^2(5) \\ &\quad + 2(0.383)(-0.924)(-2) = 5.83 = \lambda_1 \end{aligned}$$

$$\begin{aligned} \text{Cov}(Y_1, Y_2) &= 0.383 \text{Cov}(X_1, X_3) \\ &\quad - 0.924 \text{Cov}(X_2, X_3) = 0 \end{aligned}$$

$$\begin{aligned} \sigma_{11} + \sigma_{22} + \sigma_{33} &= 1 + 5 + 2 = 8 \\ &= 5.83 + 2.00 + 0.17 \end{aligned}$$

**Interpretación:**

- $X_3$  es una componente por sí sola: no está correlacionada con las otras dos.
- $Y_1$  explica  $5.83/8 = 73\%$ ;  $Y_1$  y  $Y_2$  juntas,  $7.83/8 = 98\%$ : pueden reemplazar a las tres variables.
- $\rho_{Y_1, X_1} = 0.383\sqrt{5.83}/\sqrt{1} = 0.925$ ;  
 $\rho_{Y_1, X_2} = -0.924\sqrt{5.83}/\sqrt{5} = -0.998$ .
- Ambas importan en  $Y_1$ ;  $X_2$  pesa más y con signo opuesto:  $Y_1$  es un *contraste*.

# Componentes a partir de variables estandarizadas

Estandarizando  $Z_i = \frac{X_i - \mu_i}{\sqrt{\sigma_{ii}}}$ , es decir  $\mathbf{Z} = (\mathbf{V}^{1/2})^{-1}(\mathbf{X} - \boldsymbol{\mu})$ , se tiene  $E(\mathbf{Z}) = \mathbf{0}$  y  $\text{Cov}(\mathbf{Z}) = \boldsymbol{\rho}$ , la **matriz de correlaciones**.

## Resultado 8.4 (J&W)

La  $i$ -ésima componente principal de  $\mathbf{Z}$  es  $Y_i = \mathbf{e}_i' \mathbf{Z} = \mathbf{e}_i' (\mathbf{V}^{1/2})^{-1} (\mathbf{X} - \boldsymbol{\mu})$ , donde ahora  $(\lambda_i, \mathbf{e}_i)$  son los pares valor–vector propio de  $\boldsymbol{\rho}$ . Además

$$\sum_{i=1}^p \text{Var}(Y_i) = \sum_{i=1}^p \text{Var}(Z_i) = p, \quad \rho_{Y_i, Z_k} = e_{ik} \sqrt{\lambda_i}, \quad \left( \begin{array}{c} \text{proporción explicada} \\ \text{por la } k\text{-ésima CP} \end{array} \right) = \frac{\lambda_k}{p}.$$

- La varianza total ahora es  $p$  (la dimensión de  $\boldsymbol{\rho}$ ), porque cada  $Z_i$  tiene varianza 1.
- En la práctica se reemplaza  $\boldsymbol{\Sigma}$  por  $\mathbf{S}$  (matriz de covarianzas muestral) o  $\boldsymbol{\rho}$  por  $\mathbf{R}$  (matriz de correlaciones muestral); en Díaz,  $\mathbf{R} = \mathbf{D}^{-1/2} \mathbf{S} \mathbf{D}^{-1/2}$  con  $\mathbf{D}^{-1/2} = \text{Diag}(1/s_i)$ .

## Muy importante

Los pares  $(\lambda_i, \mathbf{e}_i)$  derivados de  $\boldsymbol{\Sigma}$  **no** son, en general, los derivados de  $\boldsymbol{\rho}$ , ni una función simple de ellos: la estandarización **sí** cambia el resultado.

## Ejemplo 8.2 (J&W): $\Sigma$ y $\rho$ dan componentes distintas

$$\Sigma = \begin{pmatrix} 1 & 4 \\ 4 & 100 \end{pmatrix}, \quad \rho = \begin{pmatrix} 1 & 0.4 \\ 0.4 & 1 \end{pmatrix}$$

Desde  $\Sigma$ :

$$\lambda_1 = 100.16, \quad \mathbf{e}'_1 = [0.040, 0.999]$$

$$\lambda_2 = 0.84, \quad \mathbf{e}'_2 = [0.999, -0.040]$$

$$Y_1 = 0.040X_1 + 0.999X_2$$

$$Y_2 = 0.999X_1 - 0.040X_2$$

$Y_1$  explica  $100.16/101 = 0.992$  de la varianza total.  $X_2$  **domina** la primera componente sólo porque su varianza es 100 veces mayor.

Desde  $\rho$ :

$$\lambda_1 = 1 + \rho = 1.4, \quad \mathbf{e}'_1 = [0.707, 0.707]$$

$$\lambda_2 = 1 - \rho = 0.6, \quad \mathbf{e}'_2 = [0.707, -0.707]$$

$$Y_1 = 0.707Z_1 + 0.707Z_2$$

$$= 0.707(X_1 - \mu_1) + 0.0707(X_2 - \mu_2)$$

$Y_1$  explica  $1.4/2 = 0.7$  de la varianza total;  $\rho_{Y_1, Z_1} = \rho_{Y_1, Z_2} = 0.707\sqrt{1.4} = 0.837$ : las dos variables **contribuyen por igual**. En las  $X$ , los pesos 0.707 y 0.0707 están en *oposición directa* a 0.040 y 0.999.

### ¿Cuándo usar S y cuándo R?

Use **R** si las variables están en **escalas muy distintas** o **unidades no comparables** (p. ej., ventas en \$10 000–\$350 000 y una razón en 0.01–0.60). Use **S** si las unidades son comparables y las diferencias de varianza son *informativas*. Siempre examine medias y varianzas *antes* de decidir.

# Componentes principales muestrales (J&W, sección 8.3)

Con  $n$  observaciones  $\mathbf{x}_1, \dots, \mathbf{x}_n$  de  $p$  variables se calcula  $\bar{\mathbf{x}}$ ,  $\mathbf{S}$  y  $\mathbf{R}$ . Las **componentes principales muestrales** son las combinaciones lineales no correlacionadas de máxima varianza muestral:

## Componentes principales muestrales

Si  $(\hat{\lambda}_1, \hat{\mathbf{e}}_1), \dots, (\hat{\lambda}_p, \hat{\mathbf{e}}_p)$  son los pares valor–vector propio de  $\mathbf{S}$  ( $\hat{\lambda}_1 \geq \dots \geq \hat{\lambda}_p \geq 0$ ),

$$\hat{y}_i = \hat{\mathbf{e}}_i'(\mathbf{x} - \bar{\mathbf{x}}) = \hat{e}_{i1}(x_1 - \bar{x}_1) + \dots + \hat{e}_{ip}(x_p - \bar{x}_p), \quad i = 1, \dots, p.$$

$$\text{Var. muestral}(\hat{y}_k) = \hat{\lambda}_k, \quad \text{Cov. muestral}(\hat{y}_i, \hat{y}_k) = 0, \quad \sum_{i=1}^p s_{ii} = \hat{\lambda}_1 + \dots + \hat{\lambda}_p, \quad r_{\hat{y}_i, x_k} = \frac{\hat{e}_{ik} \sqrt{\hat{\lambda}_i}}{\sqrt{s_{kk}}}.$$

- Centrar por  $\bar{\mathbf{x}}$  no afecta a  $\mathbf{S}$ ; sólo hace que cada componente tenga **media muestral cero**:  
 $\hat{\tilde{y}}_i = \frac{1}{n} \sum_j \hat{\mathbf{e}}_i'(\mathbf{x}_j - \bar{\mathbf{x}}) = \hat{\mathbf{e}}_i' \mathbf{0} = 0$ .
- Los valores  $\hat{y}_{ij} = \hat{\mathbf{e}}_i'(\mathbf{x}_j - \bar{\mathbf{x}})$ ,  $j = 1, \dots, n$ , son los **puntajes** de la componente  $i$ .
- En forma matricial (Díaz 5.25):  $\mathbf{Y} = (\mathbf{X} - \bar{\mathbf{X}})\mathbf{A}$ , con  $\mathbf{A} = [\hat{\mathbf{e}}_1, \dots, \hat{\mathbf{e}}_p]$  ortogonal; es una *rotación rígida* de los datos centrados.
- Si los datos son normales,  $\hat{\lambda}_i$  y  $\hat{\mathbf{e}}_i$  son los estimadores de máxima verosimilitud de  $\lambda_i$  y  $\mathbf{e}_i$  (salvo el factor  $(n-1)/n$ , que no altera las componentes ni las proporciones explicadas).

# Procedimiento para generar las componentes (Díaz, sección 5.4)

- 1 Decidir si se trabaja con la matriz de covarianzas  $\mathbf{S}$  o con la de correlaciones  $\mathbf{R}$  (examinar medias, varianzas y unidades).
- 2 Calcular  $\mathbf{S}$  (o  $\mathbf{R}$ ).
- 3 Obtener los valores propios  $l_1 \geq l_2 \geq \dots \geq l_p$ : son las **varianzas** de las componentes.
- 4 Calcular las proporciones  $l_k / \text{tr}(\mathbf{S})$  y acumularlas.
- 5 Los valores altos del paso anterior dan un indicio del **número de componentes** relevantes.
- 6 Calcular las correlaciones  $r_{X_i, Y_k} = a_{ki} \sqrt{l_k} / \sqrt{s_{ii}}$  (o  $a_{ki} \sqrt{l_k}$  con  $\mathbf{R}$ ): grado de asociación variable–componente.
- 7 Calcular los “nuevos” puntajes  $\mathbf{Y} = (\mathbf{X} - \bar{\mathbf{X}})\mathbf{A}$ .
- 8 **Interpretar** los nuevos ejes.

## La parte crucial

“La carencia de una interpretación puede hacer que este trabajo se convierta en un ejercicio puramente numérico” (Díaz). Por el orden decreciente de las varianzas, algunos usuarios llaman al ACP una *técnica de ordenamiento*.

## Reconstrucción y compresión de la matriz de datos (Díaz 5.2.2)

Con los  $m < p$  primeros vectores propios  $\mathbf{A}_m = [\mathbf{a}_1, \dots, \mathbf{a}_m]$  ( $p \times m$ ) y los puntajes  $\mathbf{Y}_m = \mathbf{X}\mathbf{A}_m$  ( $n \times m$ ), la matriz centrada se aproxima por

$$\mathbf{X} \approx \hat{\mathbf{X}} = \mathbf{Y}_m \mathbf{A}_m' \quad (n \times p).$$

- La aproximación es buena si  $l_1 + \dots + l_m$  es una proporción alta de  $\text{tr}(\mathbf{S}) = \sum_{k=1}^p l_k$ ; lo que queda ( $\sum_{k>m} l_k$ ) se toma como “ruido”.
- Se reemplazan  $n \times p$  números por  $m \times (n + p)$ :  $m$  vectores de puntajes ( $n \times 1$ ) y  $m$  vectores de coeficientes ( $p \times 1$ ).
- Ejemplo: una matriz  $100 \times 1000$  (100 000 datos) con  $m = 10$  se reduce a  $10 \times (100 + 1000) = 11\,000$  datos.

### El plano factorial

Es habitual representar los individuos (y/o las variables) en los dos primeros ejes. Ese plano facilita: interpretar los ejes, clasificar individuos, **detectar valores atípicos** y diagnosticar normalidad.

En *machine learning* esta reconstrucción es exactamente un *autoencoder lineal*: codificar  $\mathbf{x} \mapsto \mathbf{A}_m' \mathbf{x}$  y decodificar  $\mathbf{y} \mapsto \mathbf{A}_m \mathbf{y}$  minimizando el error cuadrático de reconstrucción.

## Verifique en R: el ejemplo de 12 observaciones “a mano” y con prcomp

```
x1 <- c(16,12,13,11,10,9,8,7,5,3,2,0)
x2 <- c(8,10,6,2,8,-1,4,6,-3,-1,-3,0)
X <- cbind(x1, x2)
# 1. Centrar y calcular S
Xc <- scale(X, center = TRUE, scale = FALSE)
S <- cov(X); sum(diag(S)) # 44.182
# 2. Valores y vectores propios de S
ev <- eigen(S); ev
ev$values / sum(ev$values) # 0.8731 0.1269
# 3. Angulo del primer eje con X1*
atan2(ev$vectors[2,1], ev$vectors[1,1]) * 180 /
pi
# 4. Puntajes = rotacion rigida de Xc
Y <- Xc %*% ev$vectors
round(cov(Y), 3) # diag: 38.576,
5.606
# 5. Comparar con prcomp (usa S por defecto)
acp <- prcomp(X)
acp$rotation; summary(acp)
```

### Qué debe observar:

- $\text{ev}\$vectors[,1] = \pm(0.728, 0.685)$ : el signo es arbitrario (un vector propio y su negativo generan la misma recta).
- El ángulo es  $43.26^\circ$  (o  $-136.74^\circ$  si el signo salió negativo).
- $\text{cov}(Y)$  es diagonal: las componentes son no correlacionadas.
- `prcomp` centra por defecto y usa  $S$ ; con `scale. = TRUE` usa  $R$ . `princomp` usa el divisor  $n$  en vez de  $n - 1$  (misma rotación, varianzas  $\times \frac{n-1}{n}$ ).
- `acp$x` son los puntajes; `acp$sdev^2` los valores propios.

## Ejemplo 8.3 (J&W): censo de Madison, Wisconsin ( $n = 61$ distritos, $p = 5$ )

Variables: población total (miles), % con título profesional, % empleados mayores de 16 años, % empleados por el gobierno, valor mediano de la vivienda (\$100 000). Se usa **S**.

| Variable                   | $\hat{e}_1$ ( $r_{\hat{y}_1, x_k}$ ) | $\hat{e}_2$ ( $r_{\hat{y}_2, x_k}$ ) | $\hat{e}_3$ | $\hat{e}_4$ | $\hat{e}_5$ |
|----------------------------|--------------------------------------|--------------------------------------|-------------|-------------|-------------|
| Población total            | -0.039 (-0.22)                       | 0.071 (0.24)                         | 0.188       | 0.977       | -0.058      |
| Profesión                  | 0.105 (0.35)                         | 0.130 (0.26)                         | -0.961      | 0.171       | -0.139      |
| Empleo (%)                 | -0.492 (-0.68)                       | 0.864 (0.73)                         | 0.046       | -0.091      | 0.005       |
| Empleo gobierno (%)        | 0.863 (0.95)                         | 0.480 (0.32)                         | 0.153       | -0.030      | 0.007       |
| Valor vivienda             | 0.009 (0.16)                         | 0.015 (0.17)                         | -0.125      | 0.082       | 0.989       |
| Varianza $\hat{\lambda}_i$ | 107.02                               | 39.67                                | 8.37        | 2.87        | 0.15        |
| % acumulado                | 67.7                                 | 92.8                                 | 98.1        | 99.9        | 100.0       |

- Las dos primeras componentes explican el 92.8 % de la varianza muestral total: reducir de  $61 \times 5$  a  $61 \times 2$  es razonable.
- $\hat{y}_1 \approx$  una **diferencia ponderada** entre el % de empleo público y el % de empleo total;  $\hat{y}_2 \approx$  una **suma ponderada** de los dos.
- Los coeficientes y las correlaciones cuentan la misma historia. Note que “Valor vivienda” casi no interviene en  $\hat{y}_1, \hat{y}_2$ : su varianza es pequeñísima en estas unidades (¿qué pasaría con **R**?).

# Contenido

- 1 Motivación y objetivos del ACP
- 2 Interpretación geométrica
- 3 Generación de las componentes principales
- 4 Selección del número de componentes**
- 5 Síntesis y ejercicios

# ¿Cuántas componentes retener?

## No hay una respuesta definitiva

“Siempre está la pregunta de cuántas componentes retener. No hay una respuesta definitiva” (J&W). “No hay criterios estrictamente formales, excepto bajo normalidad” (Díaz). Los criterios son **empíricos** y dependen de cuánta variabilidad (información) se quiera conservar.

Criterios habituales, que conviene usar **en conjunto**:

- 1 **Proporción acumulada de varianza explicada:**  $\frac{\sum_{k=1}^m l_k}{\sum_{k=1}^p l_k} \times 100\%$ ; retener el menor  $m$  que alcance un umbral fijado de antemano (típicamente 70–90 %).
- 2 **Valores propios por encima de la media:** retener las componentes con  $l_k > \bar{l} = \text{tr}(\mathbf{S})/p$ . Con  $\mathbf{R}$  la media es 1, así que la regla es  $l_k > 1$  (criterio de Kaiser).
- 3 **Gráfico de sedimentación (*scree plot*):** buscar el “codo”.
- 4 **Interpretabilidad** y conocimiento del problema: una componente que no se pueda interpretar rara vez es útil.
- 5 **Prueba de hipótesis** sobre la igualdad de los últimos valores propios (requiere normalidad).
- 6 **Validación cruzada** tipo PRESS (Krzanowski): ¿mejora la reconstrucción de  $\mathbf{X}$  al añadir la componente  $m$ ?

# El gráfico de sedimentación (*scree plot*)




Figura 8.2 de J&W (*scree*: pedregal al pie de un acantilado).

- Se grafican los  $\hat{\lambda}_i$  (de mayor a menor) contra  $i$ .
- Se busca el **codo**: el punto a partir del cual los valores propios restantes son *relativamente pequeños y aproximadamente iguales*.
- Aquí el codo está en  $i \approx 3$ : después de  $\hat{\lambda}_2$  los valores propios son pequeños y parecidos; dos (quizá tres) componentes bastan.
- Variante (Díaz, Fig. 5.8): si por los últimos valores propios puede trazarse una recta de pendiente pequeña, se retienen las componentes que quedan *por encima* de ella.

## Interpretación geométrica

Últimos  $p - m$  valores propios iguales  $\Leftrightarrow$  **isotropía**: en esas direcciones la nube es “esférica”; no hay dirección privilegiada, sólo ruido.

# Prueba bajo normalidad: ¿son iguales los últimos $k$ valores propios?

Se verifica  $H_0 : \lambda_{p-k+1} = \lambda_{p-k+2} = \dots = \lambda_p$  con  $k = p - m$ . Si  $H_0$  es cierta, las primeras  $m$  componentes capturan las dimensiones esenciales y las últimas  $k$  reflejan “ruido” (los últimos puntos del *scree plot* caen sobre una recta casi horizontal).

## Estadística de prueba (Díaz 5.30)

$$u = \left( n - \frac{2p+11}{6} \right) \left( k \ln \bar{\lambda} - \sum_{i=p-k+1}^p \ln \hat{\lambda}_i \right) \sim \chi^2_{\nu}, \quad \nu = \frac{1}{2}(k-1)(k+2),$$

donde  $\bar{\lambda}$  es el promedio de los últimos  $k$  valores propios. Se rechaza  $H_0$  si  $u \geq \chi^2_{\nu, \alpha}$ .

- **Procedimiento secuencial:** probar primero  $H_0^{(2)} : \lambda_{p-1} = \lambda_p$ ; si no se rechaza, probar  $H_0^{(3)} : \lambda_{p-2} = \lambda_{p-1} = \lambda_p$ , y así hasta que  $H_0^{(k)}$  se rechace.
- Antes puede ser útil probar la **independencia completa**  $H_0 : \Sigma = \text{Diag}(\sigma_{ii})$  (sección 4.3.1 de Díaz, vista en las semanas 5–6): si no se rechaza, cada variable es por sí misma una componente y el ACP no aporta.
- **Además**, una componente con valor propio  $\approx 0$  no es sólo “poco importante”: señala una **dependencia lineal** casi exacta entre las variables originales, lo cual es información valiosa (por ejemplo, multicolinealidad en regresión).

## Verifique en R: criterios de selección con iris

```
datos <- iris[, 1:4]
apply(datos, 2, var)          # escalas
                             # comparables (cm)
acp <- prcomp(datos, scale. = FALSE) # con S
lam <- acp$sdev^2; round(lam, 3)      #
                             # valores propios
round(cumsum(lam)/sum(lam), 3)        # %
                             # acumulado
# Criterio 2: valores propios por encima de la
# media
lam > mean(lam)

# Criterio 3: scree plot
plot(lam, type = "b", pch = 19, xlab = "
Componente",
      ylab = expression(hat(lambda)[i]))
abline(h = mean(lam), lty = 2)
# Correlaciones variable-componente
round(acp$rotation %*% diag(acp$sdev) /
      sqrt(apply(datos, 2, var)), 3)
# Plano factorial coloreado por especie
plot(acp$x[,1:2], col = iris$Species, pch =
19)
```

### Qué debe encontrar:

- $\hat{\lambda} \approx (4.23, 0.24, 0.08, 0.02)$ ; la primera componente explica  $\approx 92.5\%$  y las dos primeras  $\approx 97.8\%$ .
- Sólo  $\hat{\lambda}_1$  supera la media (1.14); el codo está en  $i = 2$ .
- Los tres criterios apuntan a **una** componente (dos si se quiere el plano factorial para graficar).
- En el plano factorial las tres especies se separan casi por completo sobre  $\hat{y}_1$ :  $\hat{y}_1$  es un “tamaño general” de la flor, dominado por la longitud del pétalo (la variable de mayor varianza).

Repita con `scale. = TRUE` y compare: ¿cambian los porcentajes?, ¿cambia el número sugerido de componentes?, ¿cambia la interpretación de  $\hat{y}_1$ ?

# Contenido

- 1 Motivación y objetivos del ACP
- 2 Interpretación geométrica
- 3 Generación de las componentes principales
- 4 Selección del número de componentes
- 5 Síntesis y ejercicios

# Síntesis: el ACP en una página

## Qué es

- Una **rotación rígida** de los ejes originales (centrados) hacia las direcciones de máxima varianza.
- Las nuevas variables  $Y_i = \mathbf{e}_i'(\mathbf{X} - \boldsymbol{\mu})$  son **no correlacionadas**, con  $\text{Var}(Y_i) = \lambda_i$  y  $\sum \lambda_i = \text{tr}(\boldsymbol{\Sigma})$ .
- $(\lambda_i, \mathbf{e}_i)$ : valores y vectores propios de  $\boldsymbol{\Sigma}$  (o  $\mathbf{S}$ ), o de  $\boldsymbol{\rho}$  (o  $\mathbf{R}$ ) si se estandariza.
- Geométricamente: los ejes del elipsoide de concentración; el subespacio de dimensión  $m$  que mejor ajusta la nube en el sentido de mínimos cuadrados.

## Advertencias frecuentes

- $\mathbf{S}$  y  $\mathbf{R}$  dan componentes **distintas**; la decisión depende de las unidades y escalas.
- El signo de cada  $\mathbf{e}_i$  es arbitrario: interpretar contrastes, no signos absolutos.
- Un porcentaje alto explicado **no** garantiza interpretabilidad; y un valor propio  $\approx 0$  es información, no basura.
- El ACP capta sólo estructura **lineal**; es sensible a valores atípicos (¡mire el plano factorial!).
- El ACP **no** es análisis factorial: no postula variables latentes ni un modelo de error (capítulo 9).

## Vocabulario paralelo (estadística clásica $\leftrightarrow$ *machine learning*)

componentes  $\leftrightarrow$  *features* latentes; puntajes  $\leftrightarrow$  *embedding*; vectores propios  $\leftrightarrow$  *loadings*; reconstrucción  $\hat{\mathbf{X}} = \mathbf{Y}_m \mathbf{A}_m'$   $\leftrightarrow$  *autoencoder lineal*; selección de  $m \leftrightarrow$  *hiperparámetro de dimensión*.

## Ejercicio 1 (para la próxima clase): construir el ACP paso a paso

Use los 12 datos de Díaz (Tabla 5.1) **sin** usar `prcomp` ni `princomp` salvo en el literal (f).

- (a) Calcule  $\bar{\mathbf{x}}$ , la matriz centrada  $\mathbf{X}^*$ ,  $\mathbf{S}$  y  $\mathbf{R}$ . Verifique que  $\text{tr}(\mathbf{S}) = 44.182$ .
- (b) Escriba una función `var_proy(theta)` que devuelva la varianza de  $y_1 = \cos \theta x_1^* + \sin \theta x_2^*$ . Evalúela en  $\theta = 0, 10, \dots, 90$  grados, reproduzca la Tabla 5.3 y grafique la curva. Encuentre el máximo numéricamente con `optimize()`.
- (c) Obtenga los valores y vectores propios de  $\mathbf{S}$  con `eigen()`. Compruebe que el ángulo del primer vector propio coincide con el máximo de (b) y que  $\lambda_1 = 38.576$ ,  $\lambda_2 = 5.606$ .
- (d) Calcule los puntajes  $\mathbf{Y} = \mathbf{X}^* \mathbf{A}$ , reproduzca la Tabla 5.4 y verifique que  $\text{Cov}(\mathbf{Y})$  es diagonal y que  $\text{tr}(\text{Cov}(\mathbf{Y})) = \text{tr}(\mathbf{S})$ .
- (e) Calcule las correlaciones  $r_{X_i, Y_k}$  y compárelas con los coeficientes  $a_{ki}$ . ¿Qué variable pesa más en  $Y_1$ ?
- (f) Repita el análisis desde  $\mathbf{R}$  (estandarizando). Compare los vectores propios y los porcentajes de varianza explicada con los obtenidos desde  $\mathbf{S}$ . ¿Por qué en este caso las diferencias son pequeñas? Confirme todo con `prcomp(X, scale.=TRUE)`.

## Ejercicio 2 (para la próxima clase): un ACP completo con mtcars

Use las variables numéricas continuas de `mtcars`: `mpg`, `disp`, `hp`, `drat`, `wt`, `qsec` ( $n = 32$  automóviles,  $p = 6$ ).

- (a) Calcule medias, varianzas y la matriz  $\mathbf{R}$ . Con base en las escalas de las variables, argumente si el ACP debe hacerse desde  $\mathbf{S}$  o desde  $\mathbf{R}$ .
- (b) Realice el ACP desde  $\mathbf{S}$  y desde  $\mathbf{R}$ . Para cada uno reporte los valores propios, la proporción explicada y la acumulada. ¿Qué variable domina la primera componente desde  $\mathbf{S}$  y por qué? (Relacione con el Ejemplo 8.2 de J&W.)
- (c) Para el ACP desde  $\mathbf{R}$ , decida cuántas componentes retener usando tres criterios: porcentaje acumulado ( $\geq 80\%$ ), valores propios  $> 1$  y *scree plot*. ¿Coinciden?
- (d) Interprete las dos primeras componentes usando los coeficientes y las correlaciones  $r_{\hat{y}_i, z_k}$ . Proponga un nombre para cada una (p. ej., “tamaño/potencia”, “deportividad”).
- (e) Grafique el plano factorial (`biplot(acp)` o a mano con `acp$x`). Identifique los dos automóviles más extremos en  $\hat{y}_1$  y explique su posición con los datos originales. ¿Hay algún posible valor atípico?
- (f) Reconstruya la matriz estandarizada con  $m = 2$  componentes ( $\hat{\mathbf{Z}} = \mathbf{Y}_2 \mathbf{A}'_2$ ) y calcule el error cuadrático medio de reconstrucción. Repita con  $m = 1, \dots, 6$  y grafique el error contra  $m$ . ¿Qué relación tiene esa curva con la proporción acumulada de varianza?

# Referencias

- Johnson, R. A. & Wichern, D. W. (2007). *Applied Multivariate Statistical Analysis* (6.<sup>a</sup> ed.). Pearson Prentice Hall. Capítulo 8, secciones 8.1–8.3 (pp. 430–445).
- Díaz Monroy, L. G. (2007). *Estadística multivariada: inferencia y métodos*. Universidad Nacional de Colombia. Capítulo 5, secciones 5.1–5.5 (pp. 197–225).
- Lebart, L., Morineau, A. & Fénelon, J. P. (1985). *Tratado de estadística multivariante*. (Citado en Díaz para la visión geométrica de la escuela francesa.)
- Dillon, W. R. & Goldstein, M. (1986). *Multivariate Analysis: Methods and Applications*. Wiley. (Métodos gráficos para elegir el número de componentes.)
- Krzanowski, W. J. (1994). *Principles of Multivariate Analysis*. Oxford University Press. (Estadística PRESS para el número de componentes.)

Funciones de R usadas: `eigen`, `cov`, `cor`, `scale`, `prcomp`, `princomp`, `biplot`, `optimize`.