

Análisis de Correlación Canónica

Análisis Multivariado - ID 033521 - Clase 1920

Lina Lucia Hernández Velasco



Departamento de Matemáticas
Ciencia de Datos

- Un **agrónomo** puede tomar p mediciones relativas al desarrollo de las plantas (altura, peso seco, número de hojas, etc) en sitios en una región y **al mismo tiempo**, puede registrar q variables relacionadas con las condiciones climáticas (precipitación diaria promedio, humedad, horas de sol, etc) en estos sitios. Esto con el interés de medir la **asociación** entre “desarrollo” y “clima”. Claramente, **la investigación completa envuelve** $p + q$ mediciones en n unidades (plantas).

- Un **agrónomo** puede tomar p mediciones relativas al **desarrollo de las plantas** (altura, peso seco, número de hojas, etc) en sitios en una región y **al mismo tiempo**, puede registrar q variables relacionadas con las **condiciones climáticas** (precipitación diaria promedio, humedad, horas de sol, etc) en estos sitios. Esto con el interés de medir la **asociación** entre “**desarrollo**” y “**clima**”. Claramente, **la investigación completa envuelve $p + q$ mediciones en n unidades (plantas).**
- En **psicología**, un investigador suele tomar p mediciones de variables de **aptitud** y q variables de **rendimiento** para **una muestra de n estudiantes** con el objetivo de estudiar la **relación** entre “**aptitud**” y “**rendimiento**”.

- En un **hospital**, n **pacientes** pueden ser evaluados por **dos conjuntos de variables**: **factores fisiológicos** (presión arterial, índice de masa corporal, ritmo cardíaco, etc) y **factores psicológicos** (niveles de estrés, calidad del sueño, estado emocional, etc) para estudiar, por ejemplo, la relación “**bienestar físico**” y “**salud mental**”.
- En una **empresa**, n **vendedores** pueden ser evaluados por **dos conjuntos de variables**: **desempeño en el trabajo** (crecimiento en ventas, ventas rentables, nuevas cuentas, etc) y **desempeño psicológico** (creatividad, matemática, raciocinio, etc) para estudiar por ejemplo la relación “**productividad**” y “**competencia**”.

- En un **hospital**, n **pacientes** pueden ser evaluados por **dos conjuntos de variables**: **factores fisiológicos** (presión arterial, índice de masa corporal, ritmo cardíaco, etc) y **factores psicológicos** (niveles de estrés, calidad del sueño, estado emocional, etc) para estudiar, por ejemplo, la relación “**bienestar físico**” y “**salud mental**”.
- En una **empresa**, n **vendedores** pueden ser evaluados por **dos conjuntos de variables**: **desempeño en el trabajo** (crecimiento en ventas, ventas rentables, nuevas cuentas, etc) y **desempeño psicológico** (creatividad, matemática, raciocinio, etc) para estudiar por ejemplo la relación “**productividad**” y “**competencia**”.

En todos los casos, es evidente que **se quiere establecer una relación** entre las p **variables** de un conjunto y las q **variables** de otro conjunto.

En el proceso de selección de una empresa se pueden tomar algunas medidas

- **iniciales** $(X_1, X_2, \dots, X_p)$, esto es **antes de ingresar** o cuando está aplicando algún cargo.
- medidas de productividad o de rendimiento $(Y_1, Y_2, \dots, Y_q)$ **cuando ya asumió el cargo**.

El **interés** es determinar si existe una **relación lineal** fuerte o debil entre las **puntuaciones** que los candidatos obtuvieron **durante el proceso de selección** y las **puntuación** de su rendimiento o productividad en el cargo **cuando fueron contratados**.

Así, se tienen dos conjuntos de variables

$$\text{Conjunto 1} : \{X_1, X_2, \dots, X_p\}$$

$$\text{Conjunto 2} : \{Y_1, Y_2, \dots, Y_q\}$$

y el interés es analizar las **relaciones lineales entre éstos dos conjuntos de variables**.

En particular, si se tienen **dos variables** en cada conjunto, esto es

$$\text{Conjunto 1} : \{X_1, X_2\}$$

$$\text{Conjunto 2} : \{Y_1, Y_2\}$$

se desea analizar las **relaciones lineales entre los dos conjuntos de variables**.

Seguramente usted pensó en una **matriz de correlación** para las **cuatro** variables, pues ésta contiene toda la información sobre las **asociaciones lineales entre pares de variables** en los dos conjuntos.

Suponga que se tiene la siguiente matriz de correlación

$$\begin{matrix} & \begin{matrix} Y_1 & Y_2 & X_1 & X_2 \end{matrix} \\ \begin{matrix} Y_1 \\ Y_2 \\ X_1 \\ X_2 \end{matrix} & \begin{pmatrix} 1 & -0.370 & 0.221 & \mathbf{0.445} \\ -0.370 & 1 & 0.316 & 0.168 \\ 0.221 & 0.316 & 1 & -0.176 \\ \mathbf{0.445} & 0.168 & -0.176 & 1 \end{pmatrix} \end{matrix}$$

¿Qué puede decir con respecto a la **relación lineal entre los dos conjuntos** de datos?

En este caso, **la mayoría de las correlaciones lineales son bajas**, de hecho, **la más alta (0.445)** se observa entre X_2 e Y_1 ; aunque ésta es **moderada**. Así que, aún para conjuntos de **apenas 2 variables**, queda un poco **difícil evaluar la correlación entre ellos** a partir de esta matriz. Imagine cuando los conjuntos están conformados por mas de dos variables!

En general, intentar extraer de la matriz de correlación alguna idea de la asociación entre los dos conjuntos de variables no es sencillo o casi imposible!. Esto se debe principalmente a que las correlaciones entre los dos conjuntos:

- pueden **no tener un patrón consistente**,
- deben **ajustarse** de alguna manera para las **correlaciones dentro del conjunto**.

En general, intentar extraer de la matriz de correlación alguna idea de la asociación entre los dos conjuntos de variables no es sencillo o casi imposible!. Esto se debe principalmente a que las correlaciones entre los dos conjuntos:

- pueden **no tener un patrón consistente**,
- deben **ajustarse** de alguna manera para las **correlaciones dentro del conjunto**.

Entonces,

¿Cómo **cuantificar la asociación lineal** entre los conjuntos de variables $\mathbf{X} = \{X_1, X_2, \dots, X_p\}$ e $\mathbf{Y} = \{Y_1, Y_2, \dots, Y_q\}$?

Hotelling (1935) propuso hacer una combinación lineal con las variables del primer conjunto (U), la cuál llamó variable canónica. Así mismo, hacer una combinación lineal con las variables del segundo conjunto (V), la cuál también llamó variable canónica. Entonces, la correlación entre las variables canónicas U y V ($\rho_{U,V}$) se llama correlación canónica y mide el grado de asociación lineal existente entre dos conjuntos de variables.

- El **objetivo principal** en la correlación canónica es estudiar las **relaciones lineales entre dos conjuntos de variables** (no de variable a variable).
- La **idea básica** de la correlación canónica es resumir la información de cada conjunto de variables en combinaciones lineales de las variables de cada conjunto (variables canónicas), cuyos **coeficientes son seleccionados a partir del criterio de maximización de la correlación entre los conjuntos de variables**.

Observaciones:

- El análisis de correlación canónica **generaliza al análisis de correlación entre dos variables**. Aquí la diferencia es que se tienen dos conjuntos de variables y el objetivo es entender cómo éstos conjuntos se relacionan de forma lineal.
- Así como en el ACP, el análisis de correlación canónica busca **reducir el (los) conjunto(s) de datos**.
- Los **resultados** de este tipo de análisis suelen ser **difíciles de interpretar**, en consecuencia, esta técnica se utiliza menos que otras técnicas multivariadas.

Principales objetivos de la correlación canónica:

- ✓ Comprender y cuantificar la asociación lineal entre dos conjuntos de variables.
- ✓ Resumir la información de cada conjunto de variables en las variables canónicas, para evaluar la correlación canónica entre ellas.

¿Cuándo usar análisis de correlación canónica?

- ✓ Cuando el interés principal es la correlación entre dos conjuntos de variables que, al principio, parecen estar moderadamente correlacionadas. Por lo tanto, no tiene sentido tratarlos por separado, ignorando la interdependencia entre ellos.
- ✓ Cuando se quiere predecir el resultado de un indicador basándose en un conjunto de variables a partir de otro conjunto de variables.

Sea

$$\mathbf{X}_{(p+q) \times 1} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \\ X_{p+1} \\ \vdots \\ X_{p+q} \end{bmatrix} = \begin{bmatrix} \mathbf{X}_{p \times 1} \\ \dots \\ \mathbf{Y}_{q \times 1} \end{bmatrix}$$

donde

- $\mathbf{X}_{p \times 1} = [X_1 \ X_2 \ \dots \ X_p]^\top$
- $\mathbf{Y}_{q \times 1} = [X_{p+1} \ X_{p+2} \ \dots \ X_{p+q}]^\top$

Observe que

$$\mathbf{X}_{p \times 1} \quad \text{e} \quad \mathbf{Y}_{q \times 1}$$

son **dos conjuntos de variables**.

El interés es medir la relación lineal entre éstos dos conjuntos.

donde

- $\mathbf{X}_{p \times 1} = [X_1 \ X_2 \ \dots \ X_p]^\top$
- $\mathbf{Y}_{q \times 1} = [X_{p+1} \ X_{p+2} \ \dots \ X_{p+q}]^\top$

Observe que

$$\mathbf{X}_{p \times 1} \quad \text{e} \quad \mathbf{Y}_{q \times 1}$$

son **dos conjuntos de variables**.

El interés es medir la relación lineal entre éstos dos conjuntos.

Considere

$$\Sigma = \begin{bmatrix} \Sigma_{XX} & \vdots & \Sigma_{XY} \\ \dots & \dots & \dots \\ \Sigma_{YX} & \vdots & \Sigma_{YY} \end{bmatrix}_{(p+q) \times (p+q)}$$

donde

- $\Sigma_{XX} = \text{Var}[\mathbf{X}]$ es la matriz $(p \times p)$ de varianzas y covarianzas de las variables del conjunto $\mathbf{X}$.
- $\Sigma_{YY} = \text{Var}[\mathbf{Y}]$ es la matriz $(q \times q)$ de varianzas y covarianzas de las variables del conjunto $\mathbf{Y}$.
- $\Sigma_{XY} = \text{Cov}[\mathbf{X}, \mathbf{Y}]$ es la matriz $(p \times q)$ de covarianzas de las variables de los conjuntos $\mathbf{X}$ e $\mathbf{Y}$.
- $\Sigma_{YX} = \text{Cov}[\mathbf{Y}, \mathbf{X}]$ es la matriz $(q \times p)$ de covarianzas de las variables de los conjuntos $\mathbf{Y}$ e $\mathbf{X}$.

Observación: $\Sigma_{XY} = \Sigma_{YX}^T$.

De acuerdo con la **propuesta de Hotelling**, para determinar el grado de **relación lineal entre los dos conjuntos de datos $\mathbf{X}$ e $\mathbf{Y}$** , definimos las **variables canónicas**:

- $U = \mathbf{a}^\top \mathbf{X}$, combinaciones lineales de $\mathbf{X}$
- $V = \mathbf{b}^\top \mathbf{Y}$, combinaciones lineales de $\mathbf{Y}$

Para algún par de vectores de coeficientes $\mathbf{a}$ y $\mathbf{b}$.

De acuerdo con la **propuesta de Hotelling**, para determinar el grado de **relación lineal entre los dos conjuntos de datos $\mathbf{X}$ e $\mathbf{Y}$** , definimos las **variables canónicas**:

- $U = \mathbf{a}^\top \mathbf{X}$, combinaciones lineales de $\mathbf{X}$
- $V = \mathbf{b}^\top \mathbf{Y}$, combinaciones lineales de $\mathbf{Y}$

Para algún par de vectores de coeficientes $\mathbf{a}$ y $\mathbf{b}$.

Luego, la **correlación canónica** entre U e V

$$\rho_{U,V} = \frac{\text{Cov}[U, V]}{\sqrt{\text{Var}[U]}\sqrt{\text{Var}[V]}}$$

mide el **grado de relación lineal** entre los dos conjuntos de variables **X** e **Y**.

Note que:

$$\text{Var}[U] = \text{Var} \left[\mathbf{a}^\top \mathbf{X} \right] = \mathbf{a}^\top \text{Var}[\mathbf{X}] \mathbf{a} = \mathbf{a}^\top \boldsymbol{\Sigma}_{XX} \mathbf{a}$$

$$\text{Var}[V] = \text{Var} \left[\mathbf{b}^\top \mathbf{Y} \right] = \mathbf{b}^\top \text{Var}[\mathbf{Y}] \mathbf{b} = \mathbf{b}^\top \boldsymbol{\Sigma}_{YY} \mathbf{b}$$

$$\text{Cov}[U, V] = \text{Cov} \left[\mathbf{a}^\top \mathbf{X}, \mathbf{b}^\top \mathbf{Y} \right] = \mathbf{a}^\top \text{Cov}[\mathbf{X}, \mathbf{Y}] \mathbf{b} = \mathbf{a}^\top \boldsymbol{\Sigma}_{XY} \mathbf{b}$$

Por lo tanto

$$\rho_{U,V} = \frac{\mathbf{a}^\top \Sigma_{XY} \mathbf{b}}{\sqrt{\mathbf{a}^\top \Sigma_{XX} \mathbf{a}} \sqrt{\mathbf{b}^\top \Sigma_{YY} \mathbf{b}}}$$

La idea es **determinar** los vectores de coeficientes

$$\mathbf{a} \quad \text{y} \quad \mathbf{b}$$

que hagan $\rho_{U,V}$ **sea lo más grande posible**.

Observación: $U = \mathbf{a}^\top \mathbf{X}$ y $V = \mathbf{b}^\top \mathbf{Y}$ son todas las combinaciones de $\mathbf{X}$ e $\mathbf{Y}$, respectivamente.

Tenga en cuenta que si

$$\text{Var}[U] = 1 = \text{Var}[V]$$

entonces

$$\rho_{U,V} = \frac{\text{Cov}[U, V]}{\sqrt{\text{Var}[U]}\sqrt{\text{Var}[V]}} = \text{Cov}[U, V]$$

Entonces, podemos determinar los vectores de constantes o vectores de coeficientes $\mathbf{a}^\top$ y $\mathbf{b}^\top$ talque

Maximizar $\rho_{U,V}$

Sujeto a $\text{Var}[U] = 1 = \text{Var}[V]$

equivalentemente

$$\begin{aligned} \text{Maximizar } \rho_{U,V} &= \frac{\mathbf{a}^\top \Sigma_{XY} \mathbf{b}}{\sqrt{\mathbf{a}^\top \Sigma_{XX} \mathbf{a}} \sqrt{\mathbf{b}^\top \Sigma_{YY} \mathbf{b}}} \\ \text{Sujeto a } \mathbf{a}^\top \Sigma_{XX} \mathbf{a} &= 1 = \mathbf{b}^\top \Sigma_{YY} \mathbf{b} \end{aligned}$$

Recuerde que

- $U = \mathbf{a}^\top \mathbf{X}$, combinaciones lineales de $\mathbf{X}$
- $V = \mathbf{b}^\top \mathbf{Y}$, combinaciones lineales de $\mathbf{Y}$

así que podemos tener p combinaciones de $\mathbf{X}$ y q combinaciones de $\mathbf{Y}$.
En consecuencia, tendremos

$$(U_1, V_1), (U_2, V_2), \dots, (U_k, V_k)$$

pares de variables canónicas.

Particularmente, el **primer par de variables canónicas** denotado (U_1, V_1) es:

$$U_1 = \mathbf{a}_1^\top \mathbf{X}$$

$$V_1 = \mathbf{b}_1^\top \mathbf{Y}$$

para el cual se desea

$$\text{Maximizar } \rho_{U_1, V_1} = \rho_1^*$$

$$\text{Sujeto a } \text{Var}[U_1] = 1 = \text{Var}[V_1]$$

equivalentemente

$$\text{Maximizar } \mathbf{a}_1^\top \Sigma_{XY} \mathbf{b}_1$$

$$\text{Sujeto a } \mathbf{a}_1^\top \Sigma_{XX} \mathbf{a}_1 = 1 = \mathbf{b}_1^\top \Sigma_{YY} \mathbf{b}_1$$

Análogamente, **el segundo par de variables canónicas** denotado (U_2, V_2) es:

$$U_2 = \mathbf{a}_2^\top \mathbf{X}$$

$$V_2 = \mathbf{b}_2^\top \mathbf{Y}$$

para el cual se desea

Maximizar $\rho_{U_2, V_2} = \rho_2^*$

Sujeto a $\text{Var}[U_2] = 1 = \text{Var}[V_2]$

$$\text{Cov}[U_1, U_2] = \text{Cov}[U_1, V_2] = \text{Cov}[U_2, V_1] = \text{Cov}[U_2, V_2] = 0$$

Esto significa que U_2 y V_2 sean **no correlacionados** con los anteriores pares (U_1, V_1) .

Y así en adelante, hasta el k -ésimo par de variables canónicas (U_k, V_k) :

Maximizar $\rho_{U_k, V_k} = \rho_k^*$

Sujeto a $\text{Var}[U_k] = 1 = \text{Var}[V_k]$

$$\text{Cov}[U_k, U_l] = \text{Cov}[V_k, V_l] = \text{Cov}[U_k, V_l] = \text{Cov}[U_l, V_k] = 0 \quad k \neq l$$

Observaciones:

- *La técnica de correlación canónica garantiza que las variables canónicas de un par no están correlacionadas con variables canónicas de otro par.*
- *El número de variables canónicas que puede ser obtenido es*

$$k = \min\{p, q\}$$

Claramente se tiene un **problema de optimización con restricción**, así que se pueden aplicar los **multiplicadores de Lagrange**:

$$\mathcal{L} = \mathbf{a}_k^\top \Sigma_{XY} \mathbf{b}_k - \frac{\alpha}{2} \left(\mathbf{a}_k^\top \Sigma_{XX} \mathbf{a}_k - 1 \right) - \frac{\beta}{2} \left(\mathbf{b}_k^\top \Sigma_{YY} \mathbf{b}_k - 1 \right)$$

donde α y β son los multiplicadores de Lagrange.

Para encontrar para encontrar $\mathbf{a}_k$ y $\mathbf{b}_k$ para $k = \min\{p, q\}$, debemos resolver el sistema:

$$\begin{cases} \frac{d}{d\mathbf{a}_k} \mathcal{L} = 0 \\ \frac{d}{d\mathbf{b}_k} \mathcal{L} = 0 \end{cases}$$

el cual queda dado por

$$\begin{cases} [\Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{XY}^{\top} - \lambda_k \Sigma_{XX}] \mathbf{a}_k = 0 \\ [\Sigma_{XY}^{\top} \Sigma_{XX}^{-1} \Sigma_{XY} - \lambda_k \Sigma_{YY}] \mathbf{b}_k = 0 \end{cases}$$

Donde λ_k satisface

$$\begin{cases} |\Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{XY}^{\top} - \lambda_k \Sigma_{XX}| = 0 \\ |\Sigma_{XY}^{\top} \Sigma_{XX}^{-1} \Sigma_{XY} - \lambda_k \Sigma_{YY}| = 0 \end{cases}$$

Observe que λ_k es el **autovalor** más grande de la matriz

$$\mathbf{A} = \Sigma_{XX}^{-1} \Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{XY}^{\top}$$

o equivalentemente de la matriz

$$\mathbf{B} = \Sigma_{YY}^{-1} \Sigma_{XY}^{\top} \Sigma_{XX}^{-1} \Sigma_{XY}$$

Ahora bien, apesar que λ_k es el **mismo** en **A** y **B**, tiene asociados **diferentes autovectores**:

$\mathbf{e}_k$:autovector correspondiente a λ_k obtenida en **A**

$\mathbf{f}_k$:autovector correspondiente a λ_k obtenida en **B**

Finalmente,

$$\mathbf{a}_k = \Sigma_{XX}^{-1/2} \mathbf{e}_k$$

$$\mathbf{b}_k = \Sigma_{YY}^{-1/2} \mathbf{f}_k$$

y por lo tanto, el k -ésimo par de variables canónicas queda dado por

$$U_k = \mathbf{a}_k^\top \mathbf{X} = \underbrace{\mathbf{e}_k^\top \Sigma_{XX}^{-1/2}}_{\mathbf{a}_k^\top} \mathbf{X}$$

$$V_k = \mathbf{b}_k^\top \mathbf{Y} = \underbrace{\mathbf{f}_k^\top \Sigma_{YY}^{-1/2}}_{\mathbf{b}_k^\top} \mathbf{Y}$$

La **correlación canónica** es la correlación entre U_k y V_k en valor absoluto:

$$\rho_k^{*2} = \lambda_k = [\text{Cor}(U_k, V_k)]^2 = \frac{(\mathbf{a}_k^\top \Sigma_{\mathbf{X}\mathbf{Y}} \mathbf{b}_k^\top)^2}{(\mathbf{a}_k^\top \Sigma_{\mathbf{X}\mathbf{X}} \mathbf{a}_k) (\mathbf{b}_k^\top \Sigma_{\mathbf{Y}\mathbf{Y}} \mathbf{b}_k)}$$

Observación: $\sqrt{\lambda_k} > 0$.

Las correlaciones entre las variables originales y las variables canónicas son conocidas como **cargas canónicas**.

La **correlación canónica** es la correlación entre U_k y V_k en valor absoluto:

$$\rho_k^{*2} = \lambda_k = [\text{Cor}(U_k, V_k)]^2 = \frac{\left(\mathbf{a}_k^\top \Sigma_{\mathbf{X}\mathbf{Y}} \mathbf{b}_k^\top\right)^2}{\left(\mathbf{a}_k^\top \Sigma_{\mathbf{X}\mathbf{X}} \mathbf{a}_k\right) \left(\mathbf{b}_k^\top \Sigma_{\mathbf{Y}\mathbf{Y}} \mathbf{b}_k\right)}$$

Observación: $\sqrt{\lambda_k} > 0$.

Las correlaciones entre las variables originales y las variables canónicas son conocidas como **cargas canónicas**.

Existe un criterio (parecido al gráfico de codo de componentes principales) para escoger el número de pares de correlaciones canónicas.

Notas:

1. Si **las variables originales son estandarizadas**, entonces basta substituir

$$\Sigma = \begin{bmatrix} \Sigma_{XX} & \vdots & \Sigma_{XY} \\ \cdots & \cdots & \cdots \\ \Sigma_{YX} & \vdots & \Sigma_{YY} \end{bmatrix} \quad \text{por} \quad \mathbf{P} = \begin{bmatrix} \mathbf{P}_{11} & \vdots & \mathbf{P}_{12} \\ \cdots & \cdots & \cdots \\ \mathbf{P}_{21} & \vdots & \mathbf{P}_{22} \end{bmatrix}$$

en consecuencia

$$U_k = \mathbf{e}_k^\top \mathbf{P}_{11}^{-1/2} \mathbf{Z}^{(1)} \quad \text{y} \quad V_k = \mathbf{f}_k^\top \mathbf{P}_{22}^{-1/2} \mathbf{Z}^{(2)}$$

donde **e** y **f** son los respectivos **autovectores** de

$$\mathbf{P}_{11}^{-1} \mathbf{P}_{12} \mathbf{P}_{22}^{-1} \mathbf{P}_{12}^{\top} \quad \text{y} \quad \mathbf{P}_{22}^{-1} \mathbf{P}_{12}^{\top} \mathbf{P}_{11}^{-1} \mathbf{P}_{12}$$

y

$$\text{Cov} [\mathbf{Z}^{(1)}] = \mathbf{P}_{11} \quad \text{Cov} [\mathbf{Z}^{(2)}] = \mathbf{P}_{22} \quad \text{Cov} [\mathbf{Z}^{(1)}, \mathbf{Z}^{(2)}] = \mathbf{P}_{12} = \mathbf{P}_{21}^{\top}$$

siendo

- $\mathbf{Z}^{(1)}$ la estandarización de $\mathbf{X}$,
- $\mathbf{Z}^{(2)}$ la estandarización de $\mathbf{Y}$.

2. Las **variables canónicas** pueden ser **estimadas** substituyendo las matrices poblacionales $\Sigma_{XX}, \Sigma_{YY}, \Sigma_{XY}$ y Σ_{YX} por las correspondientes matrices muestrales $\mathbf{S}_{XX}, \mathbf{S}_{YY}, \mathbf{S}_{XY}$ e $\mathbf{S}_{YX}$.
3. Las variables canónicas estandarizadas u obtenidas a partir de la matriz de correlaciones poblacionales, pueden ser obtenidas substituyendo a las matrices de correlaciones poblacionales por las matrices de correlaciones muestrales.

Ejemplo 1

Supongamos que $\mathbf{Z}^{(1)} = [Z_1^{(1)}, Z_2^{(1)}]^T$ son variables estandarizadas y que $\mathbf{Z}^{(2)} = [Z_1^{(2)}, Z_2^{(2)}]^T$ también son variables estandarizadas. Definimos el vector conjunto como:

$$\mathbf{Z} = \begin{bmatrix} \mathbf{Z}^{(1)} \\ \mathbf{Z}^{(2)} \end{bmatrix}$$

y su matriz de covarianza está dada por:

$$\text{Cov}(\mathbf{Z}) = \begin{bmatrix} \rho_{11} & \rho_{12} \\ \rho_{21} & \rho_{22} \end{bmatrix} = \begin{bmatrix} 1.0 & 0.4 & 0.5 & 0.6 \\ 0.4 & 1.0 & 0.3 & 0.4 \\ 0.5 & 0.3 & 1.0 & 0.2 \\ 0.6 & 0.4 & 0.2 & 1.0 \end{bmatrix}$$

Encuentre las variables y correlaciones canónicas.

Sobre la **interpretación**:

- En general, las **variables canónicas** son artificiales, **no tienen significado físico**, lo cual hace que esta técnica se utilice menos que otras técnicas multivariandas.
- Se da una **interpretación subjetiva a las variables canónicas** de acuerdo con la magnitud de las correlaciones de las variables originales con las variables canónicas. Así, las correlaciones son medidas para interpretar y analizar las cualidades de variables canónicas.

Sea $\mathbf{Ac} = [\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_p]^T$ y $\mathbf{Bc} = [\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_q]^T$, de modo que los vectores de variables canónicas son:

$$\mathbf{U} = \mathbf{AcX}, \quad \mathbf{V} = \mathbf{BcY}$$

La covarianza entre $\mathbf{U}$ y $\mathbf{X}$ está dada por:

$$\text{Cov}(\mathbf{U}, \mathbf{X}^{(1)}) = \text{Cov}(\mathbf{AcX}, \mathbf{X}) = \mathbf{Ac}\Sigma_{11}$$

Dado que $\text{Var}(U_i) = 1$, la correlación entre U_i y X_k se obtiene dividiendo $\text{Cov}(U_i, X_k)$ por $\sqrt{\text{Var}(X_k)} = \sigma_{kk}^{1/2}$. Equivalentemente,

$$\text{Corr}(U_i, X_k) = \text{Cov}(U_i, \sigma_{kk}^{-1/2} X_k)$$

Introduciendo la matriz diagonal $\mathbf{V}_{11}^{-1/2}$, con elementos diagonales $\sigma_{kk}^{-1/2}$, tenemos:

$$\rho_{\mathbf{U}, \mathbf{X}^{(1)}} = \mathbf{A} \mathbf{\Sigma}_{11} \mathbf{V}_{11}^{-1/2}$$

Cálculos similares para los pares $(\mathbf{U}, \mathbf{Y})$, $(\mathbf{V}, \mathbf{Y})$ y $(\mathbf{V}, \mathbf{X})$ arrojan:

$$\begin{aligned} \rho_{\mathbf{U}, \mathbf{X}} &= \mathbf{A} \mathbf{c} \mathbf{\Sigma}_{11} \mathbf{V}_{11}^{-1/2} & \rho_{\mathbf{V}, \mathbf{Y}} &= \mathbf{B} \mathbf{c} \mathbf{\Sigma}_{22} \mathbf{V}_{22}^{-1/2} \\ \rho_{\mathbf{U}, \mathbf{Y}} &= \mathbf{A} \mathbf{c} \mathbf{\Sigma}_{12} \mathbf{V}_{22}^{-1/2} & \rho_{\mathbf{V}, \mathbf{X}} &= \mathbf{B} \mathbf{c} \mathbf{\Sigma}_{21} \mathbf{V}_{11}^{-1/2} \end{aligned}$$

Donde $\mathbf{V}_{22}^{-1/2}$ es una matriz diagonal $(q \times q)$ donde el i -ésimo elemento es $Var(Y_i)$.

Las variables canónicas derivadas de variables estandarizadas pueden interpretarse a través del cálculo de las correlaciones:

$$\begin{aligned}\rho_{U,Z^{(1)}} &= \mathbf{A}_Z \rho_{11}, & \rho_{U,Z^{(2)}} &= \mathbf{A}_Z \rho_{12}, \\ \rho_{V,Z^{(2)}} &= \mathbf{B}_Z \rho_{22}, & \rho_{V,Z^{(1)}} &= \mathbf{B}_Z \rho_{21}.\end{aligned}$$

donde $\mathbf{A}_Z$ y $\mathbf{B}_Z$ son las matrices cuyas filas contienen los coeficientes canónicos para los conjuntos $\mathbf{Z}^{(1)}$ y $\mathbf{Z}^{(2)}$, respectivamente.

Nota: Las correlaciones mostradas en estas expresiones tienen los mismos valores numéricos que las obtenidas previamente:

$$\rho_{U,X} = \rho_{U,Z^{(1)}}.$$

Esto se debe a que la estandarización no afecta las correlaciones.

Ejemplo 1 (Continuación)

Encuentre las correlaciones entre las variables originales y las variables canónicas encontradas en el **Ejemplo 1**.

Ejemplo 1 (Continuación)

Encuentre las correlaciones entre las variables originales y las variables canónicas encontradas en el **Ejemplo 1**.

```
rhoUX<- ak1_trasp%*%cor11; rhoUX
           [,1]      [,2]
[1,] -0.9670595 -0.6201230
[2,]  0.2545503 -0.7845046
rhoVY<- bk1_trasp%*%cor22; rhoVY
           [,1]      [,2]
[1,]  0.6921410 0.8456079
[2,] -0.7217623 0.5338045
```

Análisis de Correlación Canónica

Una evaluación importante de la **calidad del potencial de las variables canónicas** es medir el poder de resumen de la variabilidad contenida en los conjuntos a través de la proporción de la varianza total

- **explicada por las variables canónicas** es dada por

$$PE_{U_k} = \frac{\sum_{i=1}^p [\text{Cor}(U_k, X_i)]^2}{\text{Tr}(\mathbf{S}_{XX})} \quad \text{y} \quad PE_{V_k} = \frac{\sum_{i=1}^q [\text{Cor}(V_k, Y_i)]^2}{\text{Tr}(\mathbf{S}_{YY})}$$

Si las variables originales son estandarizadas, $\mathbf{S}_Z = \mathbf{R}_X$, luego

$$PE_{U_k} = \frac{\sum_{i=1}^p [\text{Cor}(U_k, Z_i^{(1)})]^2}{p} \quad \text{y} \quad PE_{V_k} = \frac{\sum_{i=1}^q [\text{Cor}(V_k, Z_i^{(2)})]^2}{p}$$

- explicada por **los primeros r pares canónicos**

$$PVTE_{U_k} = \frac{\sum_{i=1}^r \sum_{j=1}^p [\text{Cor}(U_k, X_i)]^2}{\text{Tr}(\mathbf{S}_{XX})} \quad \text{y} \quad PVTE_{V_k} = \frac{\sum_{i=1}^r \sum_{j=1}^q [\text{Cor}(V_k, Y_i)]^2}{\text{Tr}(\mathbf{S}_{YY})}$$

Si las variables originales son estandarizadas, $\mathbf{S}_Z = \mathbf{R}_X$, luego

$$PVTE_{U_k} = \frac{\sum_{i=1}^r \sum_{j=1}^p [\text{Cor}(U_k, Z_i^{(1)})]^2}{p} \quad \text{y} \quad PVTE_{V_k} = \frac{\sum_{i=1}^r \sum_{j=1}^q [\text{Cor}(V_k, Z_i^{(2)})]^2}{p}$$

- explicada por **los primeros r pares canónicos**

$$PVTE_{U_k} = \frac{\sum_{i=1}^r \sum_{j=1}^p [\text{Cor}(U_k, X_i)]^2}{\text{Tr}(\mathbf{S}_{XX})} \quad \text{y} \quad PVTE_{V_k} = \frac{\sum_{i=1}^r \sum_{j=1}^q [\text{Cor}(V_k, Y_i)]^2}{\text{Tr}(\mathbf{S}_{YY})}$$

Si las variables originales son estandarizadas, $\mathbf{S}_Z = \mathbf{R}_X$, luego

$$PVTE_{U_k} = \frac{\sum_{i=1}^r \sum_{j=1}^p [\text{Cor}(U_k, Z_i^{(1)})]^2}{p} \quad \text{y} \quad PVTE_{V_k} = \frac{\sum_{i=1}^r \sum_{j=1}^q [\text{Cor}(V_k, Z_i^{(2)})]^2}{p}$$

¿Cuándo aplicar (o vale la pena aplicar) análisis de correlación canónica?

1. cuando se tiene interés en estudiar la relación de dos conjuntos de variables.
2. cuando en el planteamiento de hipótesis

$$H_0 : \Sigma_{\mathbf{X}\mathbf{Y}} = \mathbf{0}$$

$$H_1 : \Sigma_{\mathbf{X}\mathbf{Y}} \neq \mathbf{0}$$

o equivalentemente

$$H_0 : \mathbf{P}_{\mathbf{X}\mathbf{Y}} = \mathbf{0}$$

$$H_1 : \mathbf{P}_{\mathbf{X}\mathbf{Y}} \neq \mathbf{0}$$

se rechaza H_0 .

usamos:

- Para muestras relativamente grandes

$$Q_1 = -n \ln \prod_{i=1}^p (1 - \lambda_i) \stackrel{H_0 \text{ verd.}}{\sim} \chi_{pq}^2$$

- Para muestras pequeñas

$$Q_2 = - \left[n - 1 - \frac{1}{2}(p + q + 1) \right] \ln \prod_{i=1}^p (1 - \lambda_i) \stackrel{H_0 \text{ verd.}}{\sim} \chi_{pq}^2$$

Ejemplo 2

Los datos del archivo `Hijos.xlsx` corresponden a las **medidas de la cabeza (en milímetros)** de cada uno de los **dos primeros hijos adultos de 25 familias**. La familia es el “individuo” y x_1 (longitud de la cabeza del primer hijo), x_2 (ancho de cabeza del primer hijo), x_3 (longitud de la cabeza del segundo hijo) y x_4 (ancho de cabeza del segundo hijo). Estos datos fueron recopilados por Frets (1921)^a, y la preguntade interés era si existe una **relación entre las medidas de la cabeza de los pares de hijos**.

^aFrets, G. P. (1921), “Hepurpleity of head form in man”, *Genetica*, 3, 193(384)

Análisis de Correlación Canónica

Claramente en este caso tenemos **dos grupos de variables**:

Hijo 1 : $\{X_1, X_2\}$

Hijo 2 : $\{Y_1, Y_2\}$

Aquí podemos encontrar

$$\mathbf{R} = \begin{bmatrix} 1.00 & 0.73 & \vdots & 0.71 & 0.70 \\ 0.73 & 1.00 & \vdots & 0.69 & 0.71 \\ \dots & \dots & \dots & \dots & \dots \\ 0.71 & 0.69 & \vdots & 1.00 & 0.84 \\ 0.70 & 0.71 & \vdots & 0.84 & 1.00 \end{bmatrix} = \begin{bmatrix} \mathbf{R}_{XX} & \vdots & \mathbf{R}_{XY} \\ \dots & \dots & \dots \\ \mathbf{R}_{YX} & \vdots & \mathbf{R}_{YY} \end{bmatrix}$$

Análisis de Correlación Canónica

Note que **todas las correlaciones son altas**, lo cual nos da **sospecha que vale la pena aplicar análisis de correlación canónica**. Sin embargo, debemos hacer una **prueba formal**. **Hágala!**

Para aplicar correlación canónica, cargamos los datos

```
# --- Ejemplo 2 --- #  
require(tidyverse)  
library(readxl)  
Hijos <- read_excel("Hijos.xlsx")  
Datos<-Hijos %>% as.data.frame()  
head(Datos)  
  familia  x1  x2  x3  x4  
1      1 191 155 179 145  
2      2 195 149 201 152  
3      3 181 148 185 149  
4      4 183 153 188 149  
5      5 176 144 171 142
```

Extraemos los dos conjuntos de variables y extraemos las matrices de correlaciones muestrales

```
# --- X=(x1,x2) e Y=(x3,x4) --- #  
X<-Datos[,2:3]  
Y<-Datos[,4:5]  
  
# --- Matrices de Correlacion Muestrales --- #  
R_XX<-cor(X) # Mat. de corr. muestr. de las var. de X  
R_YY<-cor(Y) # Mat. de corr. muestr. de las var. de Y  
R_XY<-cor(X,Y) # Mat. de corr. muestr. entre X e Y  
R_YX<-cor(Y,X) # = R_YX=R^t_XY
```

Análisis de Correlación Canónica

Calculamos las matrices **A** e **B** y calculamos sus autovalores (λ_k) y autovectores ($\mathbf{e}_k$ y $\mathbf{f}_k$)

```
# Inversa de la matriz raiz cuadrada
```

```
require(expm)
```

```
raiz_XX<-sqrtm(R_XX)
```

```
inv_raiz_XX<-solve(raiz_XX)
```

```
raiz_YY<-sqrtm(R_YY)
```

```
inv_raiz_YY<-solve(raiz_YY)
```

```
# --- Matrices A e B --- #
```

```
A<-inv_raiz_XX%*%(R_XY) %*%solve(R_YY) %*%t(R_XY) %*%inv_raiz_XX
```

```
B<-inv_raiz_YY%*%t(R_XY) %*%solve(R_XX) %*%(R_XY) %*%inv_raiz_YY
```

```
# --- Lambda_k
```

```
autoA<-eigen(A)
```

```
lambdak<-autoA$values
```

```
lambdak
```

```
[1] 0.621744734 0.002887956
```

Análisis de Correlación Canónica

```
autoB<-eigen(B)
lambda_k<-autoB$values;lambda_k
[1] 0.621744734 0.002887956
```

Observe que los **autovalores** de **A** e **B** son **exactamente los mismos**.

```
# --- Correlaciones Canonicas
rho<-sqrt(lambda_k)
round(rho,4)
[1] 0.7885 0.0537
```

Tenemos que

$$\rho_{U_1,V_1} = 0.7885 \quad \text{e} \quad \rho_{U_2,V_2} = 0.0537$$

El **segundo par de correlaciones canónicas** (estandarizadas) **explican muy poco (0.0537)** de la correlación entre los dos conjuntos de variables.

Análisis de Correlación Canónica

```
# --- e_k y f_k
e_k<-autoA$variables;e_k
      [,1]      [,2]
[1,] -0.7149589  0.6991664
[2,] -0.6991664 -0.7149589
f_k<-autoB$variables;f_k
      [,1]      [,2]
[1,]  0.7002906 -0.7138579
[2,]  0.7138579  0.7002906
```

Extraemos los **coeficientes** para cada par de **variables canónicas**

```
# --- Variables Canonicas
# coeficientes de a
ak_trasp<-t(e_k)%*%inv_raiz_XX
a1_trasp<-ak_trasp[1,];round(a1_trasp,3)
[1] -0.552 -0.522
a2_trasp<-ak_trasp[2,];round(a2_trasp,3)
[1]  1.366 -1.378
```

Análisis de Correlación Canónica

```
# coeficientes de b
bk_trasp<-t(f_k) %*%inv_raiz_YY
b1_trasp<-bk_trasp[1,]; round(b1_trasp, 3)
[1] 0.504 0.538
b2_trasp<-bk_trasp[2,]; round(b2_trasp, 3)
[1] -1.769 1.759
```

Por lo tanto, **las primeras variables canónicas** (de las variables estandarizadas)

$$U_1 = -0.5552 Z_1 - 0.552 Z_2$$

$$V_1 = 0.504 Z_3 + 0.538 Z_4$$

son responsables de la **mayor correlación (0.7885)** entre los variables cefálicas de los dos primeros hijos de las familias estudiadas.

- Las **variables individuales** contribuyen con “pesos/cargas” prácticamente iguales.
- Observe que en este par de variables canónicas, cada una es una **suma/resta ponderada de las dos medidas de la cabeza** y podría ser etiquetada como la “**circunferencia de la cabeza**”.

La **segunda variable canónica** (de las variables estandarizadas)

$$U_2 = 1.366 Z_1 - 1.378 Z_2$$

$$V_2 = -1.769 Z_3 + 1.759 Z_4$$

$$\rho_{U_2, V_2} = 0.0537$$

explica muy poco (0.0537) de la correlación entre los dos primeros hijos.

Observe que para este par de variables canónicas, **cada una es una diferencia ponderada de las dos medidas de la cabeza**, así que se puede interpretar (aproximadamente) como **“la forma de la cabeza”**.

Análisis de Correlación Canónica

Podemos hacer el análisis de **correlación canónica en R** con:

```
# ----- ACC usando el paquete CCA ----- #
require(CCA)
# ----- Para trabajar con R
zX<-scale(X)
zY<-scale(Y)
# ----- Ajuste ACC
acc<-cc(zX,zY);
# --- Correlaciones canonicas
acc$cor
[1] 0.7885079 0.0537397
# Significancia de las correlaciones
library(CCP)
p.asym(acc$cor, nrow(X), ncol(X), ncol(Y))
Wilks' Lambda, using F-approximation (Rao's F):
```

	stat	approx	df1	df2	p.value
1 to 2:	0.3771629	6.59719349	4	42	0.000325
2 to 2:	0.9971120	0.06371905	1	22	0.803055

Análisis de Correlación Canónica

```
# --- Variables canonicas
acc$xcoef          # coeficientes de a
      [,1]      [,2]
x1 -0.5521896 -1.366374
x2 -0.5215372  1.378365
acc$ycoef          # coeficientes de b
      [,1]      [,2]
x3 -0.5044484 -1.768570
x4 -0.5382877  1.758566
# --- Cargas Canonicas
cargasCanon <- comput(zX, zY, acc)
# X y U
cargasCanon$corr.X.xscores
      [,1]      [,2]
x1 -0.9352877 -0.3538884
x2 -0.9271512  0.3746875
```

Análisis de Correlación Canónica

```
# Y y V
cargasCanon$corr.Y.yscores
      [,1]      [,2]
x3 -0.9562074 -0.2926900
x4 -0.9616470  0.2742901
```

```
# --- Cargas Cruzadas
```

```
# X y V
cargasCanon$corr.X.yscores
      [,1]      [,2]
x1 -0.7374817 -0.01901786
x2 -0.7310660  0.02013559
```

```
# Y y U
cargasCanon$corr.Y.xscores
      [,1]      [,2]
x3 -0.7539771 -0.01572908
x4 -0.7582663  0.01474027
```

Ejercicio

Una investigadora ha recopilado datos sobre tres variables psicológicas, cuatro variables académicas (puntajes estandarizados en pruebas) y el género de 600 estudiantes de primer año de universidad. Su interés radica en cómo el conjunto de variables psicológicas se relaciona con las variables académicas y el género (1 si femenino, 0 si masculino). Las variables psicológicas son locus de control, autoconcepto y motivación. Las variables académicas son puntajes estandarizados en pruebas de lectura (read), escritura (write), matemáticas (math) y ciencias (science).

```
# ----- Ejercicio -----#
datos <- read.csv("mmreg.csv")
colnames(datos) <- c("Control", "Concept", "Motivation",
                    "Read", "Write", "Math", "Science",
                    "Sex")

summary(datos)
```