Análisis de Correlación Canónica (ACC)

¿Cómo medir la asociación lineal entre *dos conjuntos* de variables?

Análisis Multivariado – ID 033521

Facultad de Ciencias – Departamento de Matemáticas
Pontificia Universidad Javeriana

Clase magistral (2 horas)

Plan de la sesión (120 minutos)

Bloque	Min.
Motivación e introducción	13
Variables y correlaciones canónicas	22
Actividad 1	10
Interpretación	15
Variables canónicas muestrales	8
Proporción de varianza explicada	8
Actividad 2	15
Inferencia para muestras grandes	10
Aplicación: economía y emisiones	10
Actividad 3 y cierre	9
Total	120

Pregunta guía

Si sobre los mismos individuos medimos *dos conjuntos* de variables, ¿qué combinación lineal de cada conjunto los hace **lo más correlacionados posible**?

Códigos: `ACC_codigos.R`

Contenido

1. Motivación
2. Introducción y objetivos
3. Variables y correlaciones canónicas
4. Interpretación de las variables canónicas
5. Variables canónicas muestrales
6. Proporción de varianza muestral explicada
7. Inferencia para muestras grandes
8. Aplicación: economía y emisiones
9. Síntesis

Contenido

1. Motivación
2. Introducción y objetivos
3. Variables y correlaciones canónicas
4. Interpretación de las variables canónicas
5. Variables canónicas muestrales
6. Proporción de varianza muestral explicada
7. Inferencia para muestras grandes
8. Aplicación: economía y emisiones
9. Síntesis

Dos conjuntos de variables sobre los mismos individuos

- **Agronomía**: desarrollo de las plantas $\leftrightarrow$ condiciones climáticas.
- **Educación**: pruebas de aptitud $\leftrightarrow$ rendimiento académico.
- **Salud**: factores fisiológicos $\leftrightarrow$ factores psicológicos.
- **Selección de personal**: puntajes de ingreso $\leftrightarrow$ productividad en el cargo.
- **Economía y ambiente**: indicadores macroeconómicos $\leftrightarrow$ emisiones de gases.

Lo común

Interesa la relación **entre los dos conjuntos**, no variable a variable:

$$\{X_1, \ldots, X_p\} \quad \longleftrightarrow \quad \{Y_1, \ldots, Y_q\}$$

¿Basta con mirar la matriz de correlaciones?

$$\mathbf{R} = \left(\begin{array}{cc|cc} 1 & -0.370 & 0.221 & 0.445 \\ -0.370 & 1 & 0.316 & 0.168 \\ \hline 0.221 & 0.316 & 1 & -0.176 \\ 0.445 & 0.168 & -0.176 & 1 \end{array}\right) \begin{array}{c} Y_1 \\ Y_2 \\ X_1 \\ X_2 \end{array}$$

La mayor correlación cruzada es 0.445.

Leer la asociación entre conjuntos en $\mathbf{R}$ es difícil:

- las correlaciones cruzadas no siguen un patrón claro;
- hay que descontar las correlaciones *dentro* de cada conjunto;
- con $p = 5$ y $q = 7$ serían 35 correlaciones.

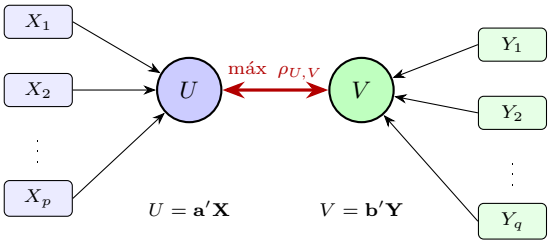
Pregunta

¿Cómo resumir la asociación en **pocos números**?

Contenido

1. Motivación
2. Introducción y objetivos
3. Variables y correlaciones canónicas
4. Interpretación de las variables canónicas
5. Variables canónicas muestrales
6. Proporción de varianza muestral explicada
7. Inferencia para muestras grandes
8. Aplicación: economía y emisiones
9. Síntesis

La idea de Hotelling (1935, 1936)



- Resumir cada conjunto en una combinación lineal: las **variables canónicas** U y V.
- Elegir los coeficientes que **maximizan** $\mathrm{Corr}(U, V)$: la **correlación canónica**.
- Repetir con nuevos pares, no correlacionados con los anteriores.

Objetivos y cuándo usar el ACC

Objetivos

1. Cuantificar la asociación lineal entre dos conjuntos de variables.
2. Resumir cada conjunto en unas pocas variables canónicas.

Úselo cuando:

- los dos conjuntos parecen moderadamente correlacionados;
- se quiere predecir un conjunto de indicadores a partir de otro;
- se rechaza $H_0 : \boldsymbol{\Sigma}_{12} = \mathbf{0}$ (independencia entre bloques, semanas 5–6).

Advertencia

Las variables canónicas son "artificiales": su interpretación puede ser difícil.

El ACC frente a lo que ya conocemos

Técnica	Qué maximiza
ACP	la *varianza* dentro de *un* conjunto
ACC	la *correlación* entre *dos* conjuntos

Casos particulares del ACC:

- $p = q = 1$: correlación simple.
- $p = 1$: correlación múltiple (regresión).

En *machine learning*

El ACC es el método clásico de *multi-view learning*: alinea dos "vistas" de los mismos individuos en un espacio latente común.

Contenido

1. Motivación
2. Introducción y objetivos
3. Variables y correlaciones canónicas
4. Interpretación de las variables canónicas
5. Variables canónicas muestrales
6. Proporción de varianza muestral explicada
7. Inferencia para muestras grandes
8. Aplicación: economía y emisiones
9. Síntesis

Planteamiento poblacional (J&W, sección 10.2)

Vector aleatorio de dimensión $p+q$, con $p \leq q$:

$$\mathbf{X} = \begin{pmatrix} \mathbf{X}^{(1)} \\ \mathbf{X}^{(2)} \end{pmatrix}, \qquad \boldsymbol{\Sigma} = \mathrm{Cov}(\mathbf{X}) = \left(\begin{array}{c|c} \underset{(p\times p)}{\boldsymbol{\Sigma}_{11}} & \underset{(p\times q)}{\boldsymbol{\Sigma}_{12}} \\ \hline \underset{(q\times p)}{\boldsymbol{\Sigma}_{21}} & \underset{(q\times q)}{\boldsymbol{\Sigma}_{22}} \end{array} \right), \qquad \boldsymbol{\Sigma}_{21} = \boldsymbol{\Sigma}_{12}'$$

- $\boldsymbol{\Sigma}_{11}$, $\boldsymbol{\Sigma}_{22}$: covarianzas *dentro* de cada conjunto.
- $\boldsymbol{\Sigma}_{12}$: las pq covarianzas *entre* conjuntos. Es lo que queremos resumir.

Notación equivalente

$\mathbf{X}^{(1)} \equiv \mathbf{X}$, $\mathbf{X}^{(2)} \equiv \mathbf{Y}$, $\boldsymbol{\Sigma}_{11} \equiv \boldsymbol{\Sigma}_{XX}$, $\boldsymbol{\Sigma}_{22} \equiv \boldsymbol{\Sigma}_{YY}$, $\boldsymbol{\Sigma}_{12} \equiv \boldsymbol{\Sigma}_{XY}$.

La correlación entre dos combinaciones lineales

Para $\mathbf{a}$ $(p \times 1)$ y $\mathbf{b}$ $(q \times 1)$, sean $U = \mathbf{a}'\mathbf{X}^{(1)}$ y $V = \mathbf{b}'\mathbf{X}^{(2)}$. Entonces

$$\mathrm{Var}(U) = \mathbf{a}'\boldsymbol{\Sigma}_{11}\mathbf{a}, \qquad \mathrm{Var}(V) = \mathbf{b}'\boldsymbol{\Sigma}_{22}\mathbf{b}, \qquad \mathrm{Cov}(U, V) = \mathbf{a}'\boldsymbol{\Sigma}_{12}\mathbf{b},$$

$$\boxed{\mathrm{Corr}(U, V) = \frac{\mathbf{a}'\boldsymbol{\Sigma}_{12}\mathbf{b}}{\sqrt{\mathbf{a}'\boldsymbol{\Sigma}_{11}\mathbf{a}}\sqrt{\mathbf{b}'\boldsymbol{\Sigma}_{22}\mathbf{b}}}}$$

- Buscamos $\mathbf{a}$ y $\mathbf{b}$ que la hagan **lo más grande posible**.
- Como $\mathrm{Corr}(cU, dV) = \mathrm{Corr}(U, V)$ para $c, d > 0$, fijamos la escala: $\mathrm{Var}(U) = \mathrm{Var}(V) = 1$.
- Con Lagrange, el problema se convierte en uno de **valores propios**.

Pares de variables canónicas

Definición secuencial

Primer par (U_1, V_1): varianza 1 y $\mathrm{Corr}(U_1, V_1)$ máxima.

Segundo par (U_2, V_2): varianza 1, correlación máxima entre las combinaciones **no correlacionadas** con el primer par.

k-ésimo par (U_k, V_k): igual, sin correlación con los $k-1$ pares anteriores.

- $\rho_k^* = \mathrm{Corr}(U_k, V_k)$ es la **k-ésima correlación canónica**.
- Hay a lo sumo $\min\{p, q\} = p$ pares.
- Se cumple $\rho_1^* \geq \rho_2^* \geq \cdots \geq \rho_p^* \geq 0$.

Resultado 10.1 (J&W) — sin demostración

Resultado 10.1

Suponga $p \leq q$ y $\boldsymbol{\Sigma}$ de rango completo. Sean $\rho_1^{*2} \geq \cdots \geq \rho_p^{*2}$ los valores propios de

$$\boldsymbol{\Sigma}_{11}^{-1/2}\,\boldsymbol{\Sigma}_{12}\,\boldsymbol{\Sigma}_{22}^{-1}\,\boldsymbol{\Sigma}_{21}\,\boldsymbol{\Sigma}_{11}^{-1/2} \qquad (p \times p)$$

con vectores propios $\mathbf{e}_1, \ldots, \mathbf{e}_p$. Entonces el k-ésimo par canónico es

$$U_k = \underbrace{\mathbf{e}_k' \boldsymbol{\Sigma}_{11}^{-1/2}}_{\mathbf{a}_k'} \mathbf{X}^{(1)}, \qquad V_k = \underbrace{\mathbf{f}_k' \boldsymbol{\Sigma}_{22}^{-1/2}}_{\mathbf{b}_k'} \mathbf{X}^{(2)}, \qquad \mathrm{Corr}(U_k, V_k) = \rho_k^*,$$

donde $\mathbf{f}_k$ es vector propio de $\boldsymbol{\Sigma}_{22}^{-1/2}\boldsymbol{\Sigma}_{21}\boldsymbol{\Sigma}_{11}^{-1}\boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1/2}$ $(q \times q)$, con $\mathbf{f}_k \propto \boldsymbol{\Sigma}_{22}^{-1/2}\boldsymbol{\Sigma}_{21}\boldsymbol{\Sigma}_{11}^{-1/2}\mathbf{e}_k$.

Propiedades

$$\mathrm{Var}(U_k) = \mathrm{Var}(V_k) = 1, \qquad \mathrm{Cov}(U_k, U_\ell) = \mathrm{Cov}(V_k, V_\ell) = \mathrm{Cov}(U_k, V_\ell) = 0 \quad (k \neq \ell).$$

Observaciones al Resultado 10.1

- Los ρ_k^{*2} también son valores propios de $\boldsymbol{\Sigma}_{11}^{-1}\boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}$, cuyos vectores propios son (salvo escala) directamente los $\mathbf{a}_k$.
- El signo de cada par $(\mathbf{a}_k, \mathbf{b}_k)$ es arbitrario: cambiar el signo de *ambos* no altera ρ_k^*.
- Si un ρ_k^* es casi cero, el par k no aporta a la asociación entre conjuntos.

Variables estandarizadas

Con $\mathbf{Z}^{(1)}$, $\mathbf{Z}^{(2)}$ estandarizadas, $\boldsymbol{\Sigma}$ se reemplaza por la matriz de correlaciones $\boldsymbol{\rho}$:

$$U_k = \mathbf{e}_k' \boldsymbol{\rho}_{11}^{-1/2} \mathbf{Z}^{(1)}, \qquad V_k = \mathbf{f}_k' \boldsymbol{\rho}_{22}^{-1/2} \mathbf{Z}^{(2)},$$

con $\mathbf{e}_k$, $\mathbf{f}_k$ vectores propios de las matrices análogas construidas con $\boldsymbol{\rho}_{11}, \boldsymbol{\rho}_{12}, \boldsymbol{\rho}_{22}$.

No cambia

Las **correlaciones canónicas** ρ_k^* (a diferencia del ACP).

Sí cambia

Los **coeficientes**: $\mathbf{a}_{k,z} = \mathbf{V}_{11}^{1/2} \mathbf{a}_k$, $\mathbf{b}_{k,z} = \mathbf{V}_{22}^{1/2} \mathbf{b}_k$.

Para comparar el peso de variables en unidades distintas se reportan los coeficientes **estandarizados**.

Ejemplo 10.1 (J&W): planteamiento

$\mathbf{Z}^{(1)} = [Z_1^{(1)}, Z_2^{(1)}]'$ y $\mathbf{Z}^{(2)} = [Z_1^{(2)}, Z_2^{(2)}]'$ estandarizadas, con

$$\mathrm{Cov}\begin{pmatrix}\mathbf{Z}^{(1)}\\ \mathbf{Z}^{(2)}\end{pmatrix} = \left(\begin{array}{cc|cc} 1.0 & 0.4 & 0.5 & 0.6 \\ 0.4 & 1.0 & 0.3 & 0.4 \\ \hline 0.5 & 0.3 & 1.0 & 0.2 \\ 0.6 & 0.4 & 0.2 & 1.0 \end{array}\right)$$

Cálculos:

$$\boldsymbol{\rho}_{11}^{-1/2} = \begin{pmatrix} 1.0681 & -0.2229 \\ -0.2229 & 1.0681 \end{pmatrix}, \qquad \boldsymbol{\rho}_{11}^{-1/2}\boldsymbol{\rho}_{12}\boldsymbol{\rho}_{22}^{-1}\boldsymbol{\rho}_{21}\boldsymbol{\rho}_{11}^{-1/2} = \begin{pmatrix} 0.4371 & 0.2178 \\ 0.2178 & 0.1096 \end{pmatrix}$$

$$\rho_1^{*2} = 0.5458, \quad \rho_2^{*2} = 0.0009, \qquad \mathbf{e}_1' = [0.8947,\ 0.4466]$$

Ejemplo 10.1 (J&W): resultado

$$\mathbf{a}_1 = \boldsymbol{\rho}_{11}^{-1/2}\mathbf{e}_1 = \begin{pmatrix} 0.8561 \\ 0.2776 \end{pmatrix}, \qquad \mathbf{b}_1 = \boldsymbol{\rho}_{22}^{-1/2}\mathbf{f}_1 = \begin{pmatrix} 0.5448 \\ 0.7366 \end{pmatrix}$$

Primer par canónico

$$U_1 = 0.86\, Z_1^{(1)} + 0.28\, Z_2^{(1)}$$
$$V_1 = 0.54\, Z_1^{(2)} + 0.74\, Z_2^{(2)}$$
$$\rho_1^* = \sqrt{0.5458} = 0.74$$

- $\rho_1^* = 0.74$ supera a todas las correlaciones cruzadas (≤ 0.6).
- $\rho_2^* = \sqrt{0.0009} = 0.03$: el segundo par prácticamente no aporta.

Actividad 1 (10 min): el Ejemplo 10.1 en R

```
rho <- matrix(c(1,.4,.5,.6, .4,1,.3,.4,
                .5,.3,1,.2, .6,.4,.2,1), 4)
r11 <- rho[1:2,1:2]; r12 <- rho[1:2,3:4]
r22 <- rho[3:4,3:4]; r21 <- t(r12)
raiz_inv <- function(M){    # M^(-1/2)
  e <- eigen(M, symmetric = TRUE); P <- e$vectors
  P %*% diag(1/sqrt(e$values)) %*% t(P)}
r11m <- raiz_inv(r11);  r22m <- raiz_inv(r22)
M1 <- r11m %*% r12 %*% solve(r22) %*% r21 %*% r11m
eA <- eigen(M1, symmetric = TRUE)
sqrt(eA$values)                  # rho*
a <- t(eA$vectors) %*% r11m      # filas = a_k'
f <- r22m %*% r21 %*% r11m %*% eA$vectors
f <- sweep(f, 2, sqrt(colSums(f^2)), "/")
b <- t(f) %*% r22m               # filas = b_k'
```

Tareas:

1. Verifique ρ_1^*, $\mathbf{a}_1$ y $\mathbf{b}_1$.
2. Calcule a `%*% r11 %*% t(a)`. ¿Qué obtiene?
3. Calcule a `%*% r12 %*% t(b)`. ¿Qué significan sus ceros?

Contenido

1. Motivación
2. Introducción y objetivos
3. Variables y correlaciones canónicas
4. Interpretación de las variables canónicas
5. Variables canónicas muestrales
6. Proporción de varianza muestral explicada
7. Inferencia para muestras grandes
8. Aplicación: economía y emisiones
9. Síntesis

Cargas canónicas

Para dar significado a las variables canónicas se usan sus correlaciones con las variables originales.

Con variables estandarizadas ($\mathbf{U} = \mathbf{A}_z\mathbf{Z}^{(1)}$, $\mathbf{V} = \mathbf{B}_z\mathbf{Z}^{(2)}$)

Cargas:	$\boldsymbol{\rho}_{\mathbf{U},\mathbf{Z}^{(1)}} = \mathbf{A}_z\boldsymbol{\rho}_{11}$,	$\boldsymbol{\rho}_{\mathbf{V},\mathbf{Z}^{(2)}} = \mathbf{B}_z\boldsymbol{\rho}_{22}$
Cargas cruzadas:	$\boldsymbol{\rho}_{\mathbf{U},\mathbf{Z}^{(2)}} = \mathbf{A}_z\boldsymbol{\rho}_{12}$,	$\boldsymbol{\rho}_{\mathbf{V},\mathbf{Z}^{(1)}} = \mathbf{B}_z\boldsymbol{\rho}_{21}$

- Las filas de $\mathbf{A}_z$ y $\mathbf{B}_z$ son los coeficientes $\mathbf{a}_k'$ y $\mathbf{b}_k'$.
- Sin estandarizar: $\boldsymbol{\rho}_{\mathbf{U},\mathbf{X}^{(1)}} = \mathbf{A}\boldsymbol{\Sigma}_{11}\mathbf{V}_{11}^{-1/2}$ (mismos valores).
- Las cargas cruzadas cumplen $\boldsymbol{\rho}_{U_k,\mathbf{Z}^{(2)}} = \rho_k^*\,\boldsymbol{\rho}_{V_k,\mathbf{Z}^{(2)}}$.

Ejemplo 10.1: cargas del primer par

	$Z_1^{(1)}$	$Z_2^{(1)}$		$Z_1^{(2)}$	$Z_2^{(2)}$
U_1 (carga)	**0.97**	0.62	V_1 (carga)	0.69	**0.85**
V_1 (cruzada)	0.71	0.46	U_1 (cruzada)	0.51	0.62

- U_1 representa sobre todo a $Z_1^{(1)}$.
- V_1 se asocia con ambas variables, algo más con $Z_2^{(2)}$.
- Cargas cruzadas $= 0.74\times$ cargas: por ejemplo, $0.51 = 0.74 \times 0.69$.

Coeficientes vs. cargas

Coeficientes $\mathbf{a}_k$, $\mathbf{b}_k$

Contribución de cada variable *en presencia* de las demás del conjunto.

Cargas

Asociación *univariada* de cada variable con la variable canónica.

Cuidado

Si hay alta colinealidad dentro de un conjunto, una variable puede tener coeficiente casi cero (o de signo contrario) y, sin embargo, carga alta. Interprete con las **cargas**.

El ACC generaliza otros coeficientes de correlación

- $p = q = 1$: ρ_1^* es la correlación simple en valor absoluto.
- $p = 1$: ρ_1^* es la correlación múltiple de $X_1^{(1)}$ con $\mathbf{X}^{(2)}$.
- En general, ρ_1^* es **mayor o igual** que cualquier correlación cruzada y que cualquier correlación múltiple de una variable con el otro conjunto.

Ejemplo 10.1 ($\rho_1^* = 0.74$)

Mayor correlación cruzada:	0.60
Correlaciones múltiples de $Z_1^{(1)}, Z_2^{(1)}$ con $\mathbf{Z}^{(2)}$:	$0.71,\ 0.46$
Correlaciones múltiples de $Z_1^{(2)}, Z_2^{(2)}$ con $\mathbf{Z}^{(1)}$:	$0.51,\ 0.62$

Combinar las variables de cada conjunto "gana" correlación.

Las primeras r variables canónicas como resumen

Si $p = q$: $\mathbf{X}^{(1)} = \mathbf{A}^{-1}\mathbf{U}$ y, como $\mathrm{Cov}(\mathbf{U}) = \mathbf{I}$,

$$\boldsymbol{\Sigma}_{11} = \sum_{k=1}^{p} \mathbf{a}^{(k)}\mathbf{a}^{(k)\prime}, \qquad \boldsymbol{\Sigma}_{12} = \sum_{k=1}^{p} \rho_k^* \, \mathbf{a}^{(k)}\mathbf{b}^{(k)\prime},$$

con $\mathbf{a}^{(k)}$ la k-ésima columna de $\mathbf{A}^{-1}$.

- Con r pares, $\boldsymbol{\Sigma}_{12}$ se aproxima bien si $\rho_{r+1}^*, \ldots, \rho_p^*$ son pequeños.
- $\boldsymbol{\Sigma}_{11}$ y $\boldsymbol{\Sigma}_{22}$ pueden quedar **mal** reproducidas.

Moraleja

Las variables canónicas maximizan *correlación*, no varianza: pueden explicar casi toda la asociación y poco de la variabilidad de cada conjunto.

Interpretación geométrica: conexión con el ACP

Con $\boldsymbol{\Sigma}_{11} = \mathbf{P}_1 \boldsymbol{\Lambda}_1 \mathbf{P}_1'$:

$$\mathbf{U} = \mathbf{E}' \boldsymbol{\Sigma}_{11}^{-1/2} \mathbf{X}^{(1)} = \mathbf{E}' \, \mathbf{P}_1 \, \boldsymbol{\Lambda}_1^{-1/2} \underbrace{\mathbf{P}_1' \mathbf{X}^{(1)}}_{\text{componentes principales}}$$

Leído de derecha a izquierda:

1. **Rotar** a las componentes principales de $\mathbf{X}^{(1)}$.
2. **Re-escalar** cada componente a varianza 1 (nube "esférica").
3. **Rotar otra vez** según la relación con el otro conjunto.

Idea clave

El ACC "blanquea" cada conjunto y luego rota ambos sistemas para **alinearlos** lo más posible.

Contenido

1. Motivación
2. Introducción y objetivos
3. Variables y correlaciones canónicas
4. Interpretación de las variables canónicas
5. Variables canónicas muestrales
6. Proporción de varianza muestral explicada
7. Inferencia para muestras grandes
8. Aplicación: economía y emisiones
9. Síntesis

Variables y correlaciones canónicas muestrales

Se reemplaza $\boldsymbol{\Sigma}$ por $\mathbf{S}$ (o $\boldsymbol{\rho}$ por $\mathbf{R}$):

$$\hat{\rho}_k^{*2} = \text{valores propios de } \mathbf{S}_{11}^{-1/2}\mathbf{S}_{12}\mathbf{S}_{22}^{-1}\mathbf{S}_{21}\mathbf{S}_{11}^{-1/2}$$

$$\hat{u}_k = \hat{\mathbf{e}}_k'\mathbf{S}_{11}^{-1/2}\mathbf{x}^{(1)}, \qquad \hat{v}_k = \hat{\mathbf{f}}_k'\mathbf{S}_{22}^{-1/2}\mathbf{x}^{(2)}$$

- Todas las propiedades poblacionales se mantienen en la muestra.
- Si las escalas son distintas, use $\mathbf{R}$ para interpretar coeficientes; las $\hat{\rho}_k^*$ no cambian.

Ejemplo 10.4 (J&W): huesos de pollo, $n = 276$

Cabeza: $z_1^{(1)}$ long. del cráneo, $z_2^{(1)}$ ancho del cráneo. Pata: $z_1^{(2)}$ fémur, $z_2^{(2)}$ tibia.

$$\mathbf{R} = \left(\begin{array}{cc|cc} 1.000 & 0.505 & 0.569 & 0.602 \\ 0.505 & 1.000 & 0.422 & 0.467 \\ \hline 0.569 & 0.422 & 1.000 & 0.926 \\ 0.602 & 0.467 & 0.926 & 1.000 \end{array}\right)$$

Resultados

$$\hat{\rho}_1^* = 0.631: \quad \hat{u}_1 = 0.781\, z_1^{(1)} + 0.345\, z_2^{(1)}, \quad \hat{v}_1 = 0.060\, z_1^{(2)} + 0.944\, z_2^{(2)}$$

$$\hat{\rho}_2^* = 0.057: \quad \hat{u}_2 = -0.856\, z_1^{(1)} + 1.106\, z_2^{(1)}, \quad \hat{v}_2 = -2.648\, z_1^{(2)} + 2.475\, z_2^{(2)}$$

Ejemplo 10.4: interpretación

Cargas	$\hat{u}_1$	$\hat{u}_2$		$\hat{v}_1$	$\hat{v}_2$
cráneo long.	0.955	-0.297	fémur	0.934	-0.356
cráneo ancho	0.739	0.674	tibia	1.000	0.023

- $\hat{u}_1$: **tamaño de la cabeza**, dominado por la longitud del cráneo.
- $\hat{v}_1$: prácticamente la **tibia**.
- El fémur tiene coeficiente 0.06 pero carga 0.93: fémur y tibia tienen $r = 0.926$.
- El segundo par ($\hat{\rho}_2^* = 0.057$) no tiene relevancia práctica.

Contenido

1. Motivación
2. Introducción y objetivos
3. Variables y correlaciones canónicas
4. Interpretación de las variables canónicas
5. Variables canónicas muestrales
6. Proporción de varianza muestral explicada
7. Inferencia para muestras grandes
8. Aplicación: economía y emisiones
9. Síntesis

¿Cuánta varianza de su conjunto resumen las variables canónicas?

Con variables estandarizadas, $\text{tr}(\mathbf{R}_{11}) = p$ y $\text{tr}(\mathbf{R}_{22}) = q$.

Proporción explicada por los primeros r pares

$$R^2_{\mathbf{z}^{(1)}|\hat{u}_1,\ldots,\hat{u}_r} = \frac{1}{p}\sum_{k=1}^{r}\sum_{i=1}^{p} r^2_{\hat{u}_k, z_i^{(1)}}, \qquad R^2_{\mathbf{z}^{(2)}|\hat{v}_1,\ldots,\hat{v}_r} = \frac{1}{q}\sum_{k=1}^{r}\sum_{i=1}^{q} r^2_{\hat{v}_k, z_i^{(2)}}$$

- Es el **promedio de las cargas al cuadrado**.
- Si $p < q$, las $\hat{v}_k$ no alcanzan a explicar el 100% del conjunto 2.
- Sin estandarizar se divide por $\text{tr}(\mathbf{S}_{11})$ o $\text{tr}(\mathbf{S}_{22})$.

Índice de redundancia

Redundancia (Stewart y Love, 1968)

Proporción de la varianza de un conjunto explicada por la variable canónica del *otro* conjunto:

$$Rd_{\mathbf{z}^{(2)}|\hat{u}_k} = \hat{\rho}_k^{*2}\ R^2_{\mathbf{z}^{(2)}|\hat{v}_k}, \qquad Rd_{\mathbf{z}^{(1)}|\hat{v}_k} = \hat{\rho}_k^{*2}\ R^2_{\mathbf{z}^{(1)}|\hat{u}_k}$$

- Se interpreta como un R^2 de regresión.
- **No es simétrico**: $Rd_{\mathbf{z}^{(2)}|\hat{u}} \neq Rd_{\mathbf{z}^{(1)}|\hat{v}}$ en general.
- $\hat{\rho}_1^*$ alto con redundancia baja: la asociación se concentra en una parte pequeña de la variabilidad.

Ejemplo 10.4: proporciones y redundancias

	Cabeza ($\mathbf{z}^{(1)}$)	Pata ($\mathbf{z}^{(2)}$)
Proporción explicada por $\hat{u}_1$ / $\hat{v}_1$	$\frac{0.955^2 + 0.739^2}{2} = 0.729$	$\frac{0.934^2 + 1.000^2}{2} = 0.936$
Redundancia ($\times 0.631^2$)	0.290	0.373

- $\hat{u}_1$ resume el 72.9% de la variabilidad de la cabeza; $\hat{v}_1$, el 93.6% de la pata.
- La cabeza explica el 37.3% de la variabilidad de la pata (a través de $\hat{u}_1$).

Actividad 2 (15 min): datos de Frets (1921)

Medidas de la cabeza (mm) de los dos primeros hijos de 25 familias (paquete `boot`).

```
library(boot)
X <- scale(frets[, c("l1","b1")])    # hijo 1
Y <- scale(frets[, c("l2","b2")])    # hijo 2
acc <- cancor(X, Y);  acc$cor
A <- t(acc$xcoef) * sqrt(nrow(X) - 1)
B <- t(acc$ycoef) * sqrt(nrow(Y) - 1)
U <- X %*% t(A);  V <- Y %*% t(B)
cargasX <- cor(X, U); cargasY <- cor(Y, V)
colMeans(cargasX^2); colMeans(cargasY^2)
```

Tareas:

1. Reporte $\hat{\rho}_1^*$, $\hat{\rho}_2^*$, $\hat{u}_1$ y $\hat{v}_1$.
2. Interprete los dos pares: ¿"tamaño" y "forma" de la cabeza?
3. Calcule proporciones explicadas y redundancias.

Contenido

1. Motivación
2. Introducción y objetivos
3. Variables y correlaciones canónicas
4. Interpretación de las variables canónicas
5. Variables canónicas muestrales
6. Proporción de varianza muestral explicada
7. Inferencia para muestras grandes
8. Aplicación: economía y emisiones
9. Síntesis

¿Hay asociación entre los conjuntos? $H_0 : \boldsymbol{\Sigma}_{12} = \mathbf{0}$

Si $\boldsymbol{\Sigma}_{12} = \mathbf{0}$, **todas** las correlaciones canónicas son cero.

Prueba de razón de verosimilitud (sin demostración)

Con una muestra de $N_{p+q}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ y n grande, se rechaza H_0 si

$$-\Big(n - 1 - \tfrac{1}{2}(p+q+1)\Big) \ln \prod_{i=1}^{p} \left(1 - \hat{\rho}_i^{*2}\right) > \chi^2_{pq}(\alpha)$$

- El factor $n - 1 - \frac{1}{2}(p+q+1)$ es la corrección de **Bartlett** (en lugar de n).
- Es la prueba de independencia entre dos bloques de las semanas 5–6.
- Requiere normalidad multivariada.

¿Cuántas correlaciones canónicas son distintas de cero?

Pruebas secuenciales, $k = 1, 2, \ldots, p-1$:

$$H_0^{(k)} : \ \rho_{k+1}^* = \cdots = \rho_p^* = 0$$

Se rechaza $H_0^{(k)}$ si

$$-\Big(n - 1 - \tfrac{1}{2}(p+q+1)\Big) \ln \prod_{i=k+1}^{p} \left(1 - \hat{\rho}_i^{*2}\right) > \chi^2_{(p-k)(q-k)}(\alpha)$$

- Se detiene en el primer k que **no** se rechaza.
- Con n muy grande, correlaciones pequeñas resultan significativas: distinga significancia **estadística** de **práctica**.

Ejemplo 10.8 (J&W): satisfacción laboral, $n = 784$

- $\mathbf{X}^{(1)}$ ($p = 5$): características del trabajo (retroalimentación, importancia, variedad, identidad de la tarea, autonomía).
- $\mathbf{X}^{(2)}$ ($q = 7$): medidas de satisfacción (supervisor, carrera, salario, carga, empresa, tipo de trabajo, general).

$$\hat{\rho}^* = (0.55,\ 0.23,\ 0.12,\ 0.08,\ 0.05), \qquad n - 1 - \tfrac{1}{2}(p + q + 1) = 776.5$$

H_0	Estadístico	g.l.	$\chi^2(0.01)$	Decisión
$\rho_1^* = \cdots = \rho_5^* = 0$	340.1	35	57.34	Rechaza
$\rho_2^* = \cdots = \rho_5^* = 0$	60.4	24	42.98	Rechaza
$\rho_3^* = \rho_4^* = \rho_5^* = 0$	18.2	15	30.58	No rechaza

Ejemplo 10.8: conclusiones

- Por ejemplo, para el segundo renglón:

$$-776.5 \ln\left[(1-0.23^2)(1-0.12^2)(1-0.08^2)(1-0.05^2)\right] = 60.4$$

- Los **dos primeros** pares canónicos son estadísticamente significativos.
- Pero $\hat{\rho}_2^{*2} = 0.05$: el segundo par comparte sólo el 5% de varianza.

Lección

Con $n = 784$ la prueba detecta asociaciones muy débiles. La decisión final debe considerar la utilidad y la interpretación de cada par.

Contenido

1. Motivación
2. Introducción y objetivos
3. Variables y correlaciones canónicas
4. Interpretación de las variables canónicas
5. Variables canónicas muestrales
6. Proporción de varianza muestral explicada
7. Inferencia para muestras grandes
8. Aplicación: economía y emisiones
9. Síntesis

Pasos para aplicar el ACC

1. **Dividir** las variables en dos conjuntos $\mathbf{X}$ e $\mathbf{Y}$.
2. **Verificar pertinencia**: correlaciones cruzadas suficientemente fuertes.
3. **Estimar** los pares canónicos (estandarizar si hay escalas distintas).
4. **Decidir cuántos pares**: prueba de Wilks/Bartlett (normalidad y n grande) o índice de redundancia.
5. **Interpretar** con las cargas y cargas cruzadas.
6. **Evaluar** la proporción de varianza explicada.

En R

`cancor` (R base), `CCA::cc`, `CCP::p.asym`, `candisc::redundancy`.

Datos: 30 países, año 2022

$\mathbf{X}$: variables económicas ($p = 5$)

PIB, Inversión Extranjera Directa (IED), Exportaciones Netas, Deuda Externa, Consumo.

$\mathbf{Y}$: gases de efecto invernadero ($q = 3$)

CO_2, CH_4, N_2O.

- Fuentes: Banco Mundial, FMI y Comisión Europea.
- Las correlaciones cruzadas son altas, salvo para **Exportaciones Netas**: al ser exportaciones − importaciones, su relación con las emisiones se diluye.
- Escalas muy distintas $\Rightarrow$ se estandarizan las variables.

Correlaciones canónicas y redundancias

	1.er par	2.º par	3.er par	Total
$\hat{\rho}_k^*$	0.99	0.85	0.30	
Redundancia de $\mathbf{X}$	0.322	0.014	0.042	0.378
Redundancia de $\mathbf{Y}$	0.778	0.023	0.017	0.817

- Las variables económicas explican el 81.7% de la variabilidad de las emisiones; el primer par, el 77.8%.
- Las emisiones explican sólo el 37.8% de la variabilidad económica.
- Según la redundancia, basta con **un par** canónico.

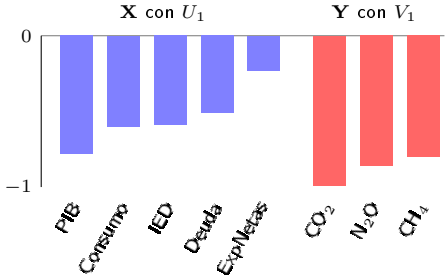
El primer par canónico

Coeficientes (variables estandarizadas)

$$U_1 = -3.641\,\text{PIB} + 0.420\,\text{IED} + 0.120\,\text{ExpNetas} - 0.224\,\text{DeudaExt} + 2.806\,\text{Consumo}$$
$$V_1 = -1.286\,\text{CO}_2 + 0.134\,\text{CH}_4 + 0.193\,\text{N}_2\text{O}$$

- En U_1 pesan sobre todo el PIB y el Consumo, con signos opuestos.
- V_1 está construida principalmente por el CO_2.

Cargas canónicas del primer par



- Todas las cargas son **negativas** en ambos conjuntos (también las cruzadas).
- Por tanto, la relación entre los conjuntos es **directa**.
- Las variables dominantes son **PIB** y **CO_2**: más producción, más uso de combustibles fósiles, más emisiones.

¿Es razonable la conclusión?

- En el largo plazo, estudios en países de la Unión Europea reportan una relación *inversa* PIB–CO_2 (tecnologías bajas en carbono).
- Aquí se mezclan países desarrollados y en desarrollo.
- Algunos países (China, Estados Unidos) concentran gran parte de las emisiones globales.

Recomendación

Repetir el análisis con más países y variables más adecuadas para obtener resultados más robustos.

Actividad 3 (discusión en grupos, 6 min)

1. **Signos.** ¿Por qué cargas negativas en ambos conjuntos implican una relación *directa*? ¿Qué pasa si se cambia el signo de $\mathbf{a}_1$ y $\mathbf{b}_1$?
2. **Coeficientes vs. cargas.** PIB tiene coeficiente -3.64 y Consumo $+2.81$, pero ambos tienen carga negativa. ¿Por qué?
3. **Asimetría.** ¿Por qué $\mathbf{Y}$ queda explicado en 81.7% y $\mathbf{X}$ sólo en 37.8%?
4. **Atípicos.** Con variables muy asimétricas y $n = 30$, ¿qué tan creíble es $\hat{\rho}_1^* = 0.99$?

Actividad 3: ¿uno o dos pares?

Prueba de Bartlett con $n = 30$, $p = 5$, $q = 3$ y $\hat{\rho}^* = (0.99,\ 0.85,\ 0.30)$:

H_0	Estadístico	g.l.	$\chi^2(0.05)$	Decisión
$\rho_1^* = \rho_2^* = \rho_3^* = 0$	129.7	15	25.00	Rechaza
$\rho_2^* = \rho_3^* = 0$	33.7	8	15.51	Rechaza
$\rho_3^* = 0$	2.3	3	7.81	No rechaza

Pregunta

La prueba sugiere **dos** pares; la redundancia, **uno**. ¿A cuál le cree? Piense en la normalidad y el tamaño de muestra.

Contenido

1. Motivación
2. Introducción y objetivos
3. Variables y correlaciones canónicas
4. Interpretación de las variables canónicas
5. Variables canónicas muestrales
6. Proporción de varianza muestral explicada
7. Inferencia para muestras grandes
8. Aplicación: economía y emisiones
9. Síntesis

Síntesis: qué es y cómo se reporta

Qué es

- Pares (U_k, V_k) de varianza 1 con correlación máxima ρ_k^*.
- ρ_k^{*2}: valores propios de $\boldsymbol{\Sigma}_{11}^{-1/2}\boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}\boldsymbol{\Sigma}_{11}^{-1/2}$.
- Hay $\min\{p, q\}$ pares.
- "Blanquear" y alinear dos conjuntos.

Cómo se reporta

- $\hat{\rho}_k^*$ y pruebas de Bartlett.
- Coeficientes estandarizados.
- Cargas y cargas cruzadas.
- Proporción de varianza explicada y redundancia.

Advertencias frecuentes

- ρ_k^* no cambia al estandarizar; los coeficientes sí.
- El signo de cada par es arbitrario: interprete el *patrón* de signos.
- Interprete con **cargas**, sobre todo si hay colinealidad.
- $\hat{\rho}_1^*$ alto no implica que las variables canónicas resuman bien su conjunto.
- Con n pequeño, $\hat{\rho}_1^*$ está **sesgada hacia arriba**; con n grande, todo es "significativo".
- Sólo capta relaciones **lineales** y es sensible a atípicos.

Referencias

- Johnson, R. A. & Wichern, D. W. (2007). *Applied Multivariate Statistical Analysis* (6.ª ed.). Pearson. Capítulo 10.
- Hotelling, H. (1936). Relations between two sets of variates. *Biometrika*, 28, 321–377.
- Frets, G. P. (1921). Heredity of head form in man. *Genetica*, 3, 193–384.
- Hair, J. F., Black, W. C., Babin, B. J. & Anderson, R. E. (2010). *Multivariate Data Analysis* (7.ª ed.). Pearson.
- Stewart, D. & Love, W. (1968). A general canonical correlation index. *Psychological Bulletin*, 70, 160–163.