Análisis Factorial (AF)

Un recorrido paso a paso: ¿se puede medir la inteligencia?

Análisis Multivariado – ID 033521

Facultad de Ciencias – Departamento de Matemáticas
Pontificia Universidad Javeriana

Clase magistral (3 horas)

Plan de la sesión (180 minutos)

Bloque	Min.
El problema: ¿se puede medir la inteligencia?	15
Paso 1. Mirar la matriz de correlación	10
Paso 2. Escribir el modelo factorial	25
Actividad 1	10
Paso 3. ¿Es viable el AF? Bartlett y KMO	10
Paso 4. ¿Cuántos factores?	10
Paso 5. Estimar: factores principales	15
Descanso	10
Paso 5. Estimar: máxima verosimilitud	15
Actividad 2	15
Paso 6. Interpretar y rotar	20
Paso 7. Puntajes factoriales y reporte	10
Segunda vuelta: dengue en Colombia	20
Actividad 3 y cierre	10
Total	180

Cómo vamos a trabajar

Un solo problema nos acompaña toda la clase. Cada concepto aparece **cuando el problema lo necesita**: primero la pregunta, después la herramienta.

Referencia: Johnson & Wichern (2007), capítulo 9.

Paquetes de R: `psych`, `GPArotation`.

Contenido

1. El problema: ¿se puede medir la inteligencia?
2. Paso 1. Mirar la matriz de correlación
3. Paso 2. Escribir el modelo factorial
4. Paso 3. ¿Es viable el AF? Bartlett y KMO
5. Paso 4. ¿Cuántos factores?
6. Paso 5. Estimar las cargas y las varianzas específicas
7. Paso 6. Interpretar los factores y rotar
8. Paso 7. Puntajes factoriales y reporte
9. Segunda vuelta: análisis factorial de la incidencia de dengue
10. Síntesis

Contenido

1. El problema: ¿se puede medir la inteligencia?
2. Paso 1. Mirar la matriz de correlación
3. Paso 2. Escribir el modelo factorial
4. Paso 3. ¿Es viable el AF? Bartlett y KMO
5. Paso 4. ¿Cuántos factores?
6. Paso 5. Estimar las cargas y las varianzas específicas
7. Paso 6. Interpretar los factores y rotar
8. Paso 7. Puntajes factoriales y reporte
9. Segunda vuelta: análisis factorial de la incidencia de dengue
10. Síntesis

Cosas que queremos medir pero no podemos observar

- **Calidad de vida en una ciudad**: tiempo de desplazamiento, acceso a parques, seguridad percibida, costo de la vivienda, calidad del aire.
- **Estrés laboral**: carga de trabajo, horas extra, relación con el jefe, claridad de las funciones, problemas de sueño.
- **Vulnerabilidad de un municipio ante una epidemia**: densidad de población, cobertura de acueducto, pobreza, temperatura, acceso a salud.
- **Inteligencia**: puntuaciones en exámenes de distintas materias.

Lo común

Ninguna de las variables *es* el concepto, pero todas lo reflejan. A estos conceptos se les llama **variables latentes**; a lo que sí medimos, **variables manifiestas**.

Hoy vamos a trabajar el último caso de principio a fin.

El caso: puntuaciones de exámenes (Lawley & Maxwell)

A $n = 220$ estudiantes varones se les aplicaron exámenes en seis materias:

X_1 Gaélico	X_2 Inglés	X_3 Historia
X_4 Aritmética	X_5 Álgebra	X_6 Geometría

Las preguntas del investigador

1. ¿Existe una "inteligencia general" que explique el desempeño en *todas* las materias?
2. ¿O hay capacidades distintas (verbal, matemática) detrás de los puntajes?
3. ¿Cómo asignarle a cada estudiante un puntaje en esas capacidades?

Es el mismo tipo de pregunta que se hizo Charles **Spearman** en 1904 y que dio origen al **Análisis Factorial**. Ejemplo 9.8 de Johnson & Wichern.

Naturaleza y escala de las variables

El AF trabaja con la matriz de covarianzas o de correlaciones, así que las variables deben ser tales que **tenga sentido calcular correlaciones de Pearson** entre ellas.

Sí

- Variables **cuantitativas continuas** (escala de intervalo o de razón): temperatura, ingresos, tiempo, tasas, puntajes.
- Escalas tipo **Likert** con 5 o más categorías ordenadas (satisfacción de 1 a 7), tratadas como cuantitativas.
- Todas medidas sobre los **mismos individuos** $(n \times p)$.

No (o con cuidado)

- Variables **nominales** (sexo, departamento, tipo de vivienda): no hay correlación de Pearson que interpretar.
- Ordinales con pocas categorías o dicotómicas: usar correlaciones *policóricas* o *tetracóricas* (`psych::polychoric`).
- Variables con relaciones claramente **no lineales**.

- Con **unidades distintas** (casos, mm, grados, porcentajes) se trabaja con $\mathbf{R}$ (variables estandarizadas).
- Tamaño de muestra: regla práctica, $n \geq 50$ y al menos 5–10 observaciones por variable.

Antes de empezar: ¿sirven mis datos para esto?

Lo que tenemos

- 6 variables **cuantitativas** (puntajes), medidas sobre los **mismos** 220 estudiantes.
- $n/p = 220/6 \approx 37$ observaciones por variable: muestra amplia.
- Puntajes en escalas distintas: trabajaremos con las variables **estandarizadas**, es decir, con la matriz de correlación $\mathbf{R}$.

Lo que vamos a suponer

- Las relaciones entre variables son **lineales**.
- No hay atípicos que distorsionen las correlaciones.
- Los puntajes tienen distribución **normal multivariada**: lo necesitaremos para las pruebas de hipótesis y para uno de los métodos de estimación (lo señalaremos en su momento).

Si esto está en orden, el primer paso es **mirar las correlaciones**.

Contenido

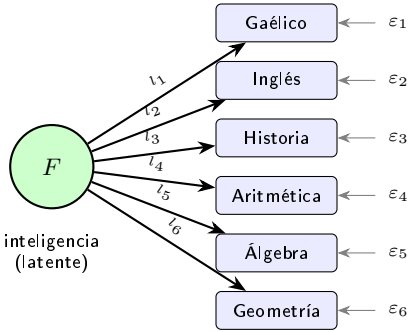
1. El problema: ¿se puede medir la inteligencia?
2. Paso 1. Mirar la matriz de correlación
3. Paso 2. Escribir el modelo factorial
4. Paso 3. ¿Es viable el AF? Bartlett y KMO
5. Paso 4. ¿Cuántos factores?
6. Paso 5. Estimar las cargas y las varianzas específicas
7. Paso 6. Interpretar los factores y rotar
8. Paso 7. Puntajes factoriales y reporte
9. Segunda vuelta: análisis factorial de la incidencia de dengue
10. Síntesis

La matriz de correlación de los seis exámenes

$$\mathbf{R} = \begin{array}{l|cccccc} & \text{Gaél.} & \text{Ing.} & \text{Hist.} & \text{Arit.} & \text{Álg.} & \text{Geom.} \\ \hline \text{Gaélico} & 1.000 & & & & & \\ \text{Inglés} & 0.439 & 1.000 & & & & \\ \text{Historia} & 0.410 & 0.351 & 1.000 & & & \\ \text{Aritmética} & 0.288 & 0.354 & 0.164 & 1.000 & & \\ \text{Álgebra} & 0.329 & 0.320 & 0.190 & 0.595 & 1.000 & \\ \text{Geometría} & 0.248 & 0.329 & 0.181 & 0.470 & 0.464 & 1.000 \end{array}$$

- **Todas** las correlaciones son positivas: el estudiante al que le va bien en una materia tiende a que le vaya bien en las demás. ¿Una inteligencia general?
- Las correlaciones son **más altas dentro de dos grupos**: Gaélico–Inglés–Historia (0.35–0.44) y Aritmética–Álgebra–Geometría (0.46–0.60).
- Entre grupos son más bajas (0.16–0.35). ¿Dos capacidades distintas?

¿De dónde salen esas correlaciones?



La idea de Spearman (1904): las materias se correlacionan porque **comparten algo** que no vemos: la inteligencia F.

- Si F es alta, todos los puntajes tienden a ser altos.
- Lo que F no explica de cada materia es propio de ella: ε_i (facilidad particular, azar del examen).
- Agrupar las variables según sus correlaciones = buscar los factores que las producen.

Siguiente paso

Escribir esta idea como un **modelo**.

Contenido

1. El problema: ¿se puede medir la inteligencia?
2. Paso 1. Mirar la matriz de correlación
3. Paso 2. Escribir el modelo factorial
4. Paso 3. ¿Es viable el AF? Bartlett y KMO
5. Paso 4. ¿Cuántos factores?
6. Paso 5. Estimar las cargas y las varianzas específicas
7. Paso 6. Interpretar los factores y rotar
8. Paso 7. Puntajes factoriales y reporte
9. Segunda vuelta: análisis factorial de la incidencia de dengue
10. Síntesis

Un factor: el modelo más simple

Cada puntaje es función de la inteligencia F y de una variación propia ε_i:

$$X_i - \mu_i = l_i F + \varepsilon_i, \qquad i = 1, \ldots, 6 \tag{1}$$

Gaélico $\rightarrow X_1 - \mu_1 = l_1 F + \varepsilon_1$

Inglés $\rightarrow X_2 - \mu_2 = l_2 F + \varepsilon_2$

Historia $\rightarrow X_3 - \mu_3 = l_3 F + \varepsilon_3$

Aritmética $\rightarrow X_4 - \mu_4 = l_4 F + \varepsilon_4$

Álgebra $\rightarrow X_5 - \mu_5 = l_5 F + \varepsilon_5$

Geometría $\rightarrow X_6 - \mu_6 = l_6 F + \varepsilon_6$

La ecuación (1) se parece a una **regresión** con respuesta X_i:

- l_i: cuánto "pesa" la inteligencia en la materia i. Se llama **carga factorial**.
- ε_i: lo específico de la materia i.

La diferencia con la regresión

El "regresor" F **no se observa**. Tampoco ε_i. Sólo vemos X_i.

¿Qué implica el modelo para la varianza de cada examen?

Como vamos a trabajar con $\mathbf{R}$, usemos los puntajes estandarizados $Z_i = (X_i - \mu_i)/\sigma_i$:

$$Z_i = l_i F + \varepsilon_i.$$

Para poder hacer cuentas necesitamos fijar dos cosas: $\mathrm{Var}(F) = 1$ (escala del factor) y $\mathrm{Cov}(F, \varepsilon_i) = 0$ (lo común y lo específico no se mezclan). Entonces

$$1 = \mathrm{Var}(Z_i) = \mathrm{Var}(l_i F + \varepsilon_i) = l_i^2 \ \mathrm{Var}(F) + \mathrm{Var}(\varepsilon_i) = \underbrace{l_i^2}_{\text{común}} + \underbrace{\psi_i}_{\text{específica}}$$

l_i^2: comunalidad

Proporción de la varianza del examen i que explica la inteligencia.

ψ_i: varianza específica

Lo que la inteligencia *no* explica del examen i.

Y para dos exámenes distintos, si además $\mathrm{Cov}(\varepsilon_i, \varepsilon_k) = 0$:

$$\mathrm{Cov}(Z_i, Z_k) = \mathrm{Cov}(l_i F + \varepsilon_i,\ l_k F + \varepsilon_k) = l_i l_k.$$

Toda la correlación entre dos materias proviene del factor común. Eso es lo que vimos en $\mathbf{R}$.

¿Y si hay más de un factor?

La matriz $\mathbf{R}$ sugería **dos** grupos. Permitamos m factores $F_1, \ldots, F_m$ (aquí $m = 2$: ¿verbal y matemático?):

$$
\begin{aligned}
Z_1 &= l_{11}F_1 + l_{12}F_2 + \cdots + l_{1m}F_m + \varepsilon_1 \\
Z_2 &= l_{21}F_1 + l_{22}F_2 + \cdots + l_{2m}F_m + \varepsilon_2 \\
&\vdots \\
Z_p &= l_{p1}F_1 + l_{p2}F_2 + \cdots + l_{pm}F_m + \varepsilon_p
\end{aligned}
$$

Matricialmente,

$$
\underbrace{\mathbf{Z}}_{p\times 1} = \underbrace{\mathbf{L}}_{p\times m}\ \underbrace{\mathbf{F}}_{m\times 1} + \underbrace{\boldsymbol{\varepsilon}}_{p\times 1} \qquad \text{(o, sin estandarizar, } \mathbf{X} - \boldsymbol{\mu} = \mathbf{LF} + \boldsymbol{\varepsilon}) \tag{2}
$$

- $\mathbf{L}$: matriz de **cargas factoriales**; l_{ij} es la carga del examen i en el factor j.
- $\mathbf{F}$: los m **factores comunes** (no observables).
- $\boldsymbol{\varepsilon}$: los p **factores específicos** (no observables).

Los supuestos que hacen manejable el modelo

Hay demasiadas cantidades no observables en (2). Para poder trabajar fijamos:

Modelo factorial ortogonal (J&W, 9-4)

$$E[\mathbf{F}] = \mathbf{0}, \quad \mathrm{Cov}(\mathbf{F}) = \mathbf{I}_m, \qquad E[\boldsymbol{\varepsilon}] = \mathbf{0}, \quad \mathrm{Cov}(\boldsymbol{\varepsilon}) = \boldsymbol{\Psi} = \mathrm{diag}(\psi_1, \ldots, \psi_p), \qquad \mathrm{Cov}(\boldsymbol{\varepsilon}, \mathbf{F}) = \mathbf{0}.$$

En palabras, para nuestro ejemplo:

- Los factores (capacidad verbal, capacidad matemática) tienen varianza 1 y **no están correlacionados**: por eso el modelo se llama *ortogonal*.
- Lo específico de Gaélico no se relaciona con lo específico de Álgebra, ni con los factores.
- Por tanto, **toda** la correlación entre materias tiene que pasar por los factores comunes.

Lo que el modelo dice sobre $\mathbf{R}$: la ecuación que vamos a resolver

Con los supuestos anteriores, $\mathbf{Z} = \mathbf{LF} + \boldsymbol{\varepsilon}$ y

$$\boldsymbol{\rho} = \mathrm{Cov}(\mathbf{Z}) = \mathbf{L}\,\underbrace{\mathrm{Cov}(\mathbf{F})}_{\mathbf{I}}\,\mathbf{L}' + \underbrace{\mathrm{Cov}(\boldsymbol{\varepsilon})}_{\boldsymbol{\Psi}}$$

Resultado

$$\boxed{\boldsymbol{\rho} = \mathbf{L}\mathbf{L}' + \boldsymbol{\Psi}} \qquad \text{y} \qquad \mathrm{Cov}(\mathbf{Z}, \mathbf{F}) = \mathbf{L} \quad \Rightarrow \quad \mathrm{Corr}(Z_i, F_j) = l_{ij}.$$

Elemento a elemento (generaliza lo que vimos con un factor):

$$1 = \underbrace{l_{i1}^2 + \cdots + l_{im}^2}_{h_i^2 \text{ (comunalidad)}} + \psi_i, \qquad \rho_{ik} = l_{i1}l_{k1} + \cdots + l_{im}l_{km} \quad (i \neq k).$$

El problema del análisis factorial, en una frase

Encontrar $\mathbf{L}$ y $\boldsymbol{\Psi}$ tales que la matriz de correlación **observada** se pueda escribir como $\mathbf{L}\mathbf{L}' + \boldsymbol{\Psi}$. Lo que no siempre es posible, y cuando lo es, no es único.

Dos advertencias antes de seguir

1. Puede no existir (J&W, Ej. 9.2)

Con $p = 3$, $m = 1$ y

$$\boldsymbol{\rho} = \begin{pmatrix} 1 & 0.9 & 0.7 \\ 0.9 & 1 & 0.4 \\ 0.7 & 0.4 & 1 \end{pmatrix},$$

de $l_1 l_2 = 0.9$, $l_1 l_3 = 0.7$, $l_2 l_3 = 0.4$ sale $l_1^2 = \dfrac{0.9 \times 0.7}{0.4} = 1.575$ y $\psi_1 = 1 - 1.575 < 0$.

Una varianza negativa: **no hay** modelo de un factor para esta $\boldsymbol{\rho}$ (caso de *Heywood*).

2. Si existe, no es única

Sea $\mathbf{T}$ ortogonal ($\mathbf{T}\mathbf{T}' = \mathbf{I}$). Entonces

$$\mathbf{L}\mathbf{F} + \boldsymbol{\varepsilon} = \underbrace{\mathbf{L}\mathbf{T}}_{\mathbf{L}^*} \underbrace{\mathbf{T}'\mathbf{F}}_{\mathbf{F}^*} + \boldsymbol{\varepsilon},$$

y $\mathbf{F}^*$ cumple los mismos supuestos. Además

$$\mathbf{L}^*\mathbf{L}^{*\prime} + \boldsymbol{\Psi} = \mathbf{L}\mathbf{T}\mathbf{T}'\mathbf{L}' + \boldsymbol{\Psi} = \mathbf{L}\mathbf{L}' + \boldsymbol{\Psi}.$$

Las cargas sólo están determinadas hasta una **rotación**; h_i^2 y ψ_i no cambian. Lo usaremos a favor en el Paso 6.

Actividad 1 (10 min): tocar el modelo con las manos

```
# Ejemplo 9.1 de J&W: una Sigma que SI se
    descompone
Sigma <- matrix(c(19,30,2,12, 30,57,5,23,
                  2,5,38,47, 12,23,47,68), 4)
L   <- matrix(c(4,7,-1,1, 1,2,6,8), ncol = 2)
Psi <- diag(c(2,4,1,3))
L %*% t(L) + Psi              # reproduce Sigma?
h2  <- rowSums(L^2); h2       # comunalidades
h2 / diag(Sigma)              # proporcion explicada
# una rotacion de 30 grados
th <- pi/6
T  <- matrix(c(cos(th), -sin(th), sin(th), cos(th)
    ), 2)
Lr <- L %*% T
Lr %*% t(Lr) + Psi            # cambia Sigma?
rowSums(Lr^2)                 # cambian las h2?
# Ejemplo 9.2: la que NO se descompone
R2 <- matrix(c(1,.9,.7, .9,1,.4, .7,.4,1), 3)
factanal(covmat = R2, factors = 1)
```

Tareas:

1. Verifique que $\mathbf{\Sigma} = \mathbf{L}\mathbf{L}' + \mathbf{\Psi}$. ¿Qué proporción de la varianza de cada variable explican los dos factores?
2. Compare $\mathbf{L}$ con $\mathbf{LT}$: ¿qué cambia y qué no?
3. ¿Qué reporta R para ψ_1 en el Ejemplo 9.2? ¿Por qué?

Con el modelo claro, volvemos a los exámenes: ¿vale la pena buscar factores en esa $\mathbf{R}$?

Contenido

1. El problema: ¿se puede medir la inteligencia?
2. Paso 1. Mirar la matriz de correlación
3. Paso 2. Escribir el modelo factorial
4. Paso 3. ¿Es viable el AF? Bartlett y KMO
5. Paso 4. ¿Cuántos factores?
6. Paso 5. Estimar las cargas y las varianzas específicas
7. Paso 6. Interpretar los factores y rotar
8. Paso 7. Puntajes factoriales y reporte
9. Segunda vuelta: análisis factorial de la incidencia de dengue
10. Síntesis

¿Hay correlaciones que explicar? Prueba de esfericidad de Bartlett

Si las materias no estuvieran correlacionadas, no habría nada que un factor común pudiera explicar. Probamos $H_0: \boldsymbol{\rho} = \mathbf{I}$ vs. $H_1: \boldsymbol{\rho} \neq \mathbf{I}$.

Estadístico (requiere normalidad multivariada)

$\chi^2_{\text{obs}} = -\left(n - 1 - \frac{2p+5}{6}\right) \ln |\mathbf{R}| \;\dot{\sim}\; \chi^2_{p(p-1)/2}$ bajo H_0. El AF es viable cuando se **rechaza** H_0.

```
R <- matrix(c(1,.439,.410,.288,.329,.248,
  .439,1,.351,.354,.320,.329,
       .410,.351,1,.164,.190,.181,
  .288,.354,.164,1,.595,.470,
       .329,.320,.190,.595,1,.464,
  .248,.329,.181,.470,.464,1), 6)
mat <- c("Gaelico","Ingles","Historia",
         "Aritmetica","Algebra","Geometria")
dimnames(R) <- list(mat, mat)
require(psych)
cortest.bartlett(R, n = 220)
## $chisq 310.84   $p.value 0   $df 15
```

valor-$p \approx 0 < 0.05$: se rechaza H_0. Hay correlación entre las materias; tiene sentido buscar factores.

Con n grande esta prueba casi siempre rechaza; por eso se complementa con el KMO.

¿Las correlaciones son "de factor común"? Criterio KMO

El KMO compara las correlaciones con las **correlaciones parciales** a_{ij} (la relación entre X_i y X_j descontando las demás variables):

$$\text{KMO} = \frac{\sum_{i \neq j} r_{ij}^2}{\sum_{i \neq j} r_{ij}^2 + \sum_{i \neq j} a_{ij}^2}.$$

KMO	Evaluación
≥ 0.9	Excelente
$[0.8, 0.9)$	Buena
$[0.7, 0.8)$	Media
$[0.6, 0.7)$	Baja
$[0.5, 0.6)$	Mala
< 0.5	Inaceptable

```
KMO(R)
## Kaiser-Meyer-Olkin factor adequacy
## Overall MSA =  0.77
## MSA for each item =
## Gaelico  Ingles  Historia Aritmetica Algebra
     Geometria
##    0.77    0.81       0.76       0.74    0.75
     0.83
```

- Si las variables comparten factores, las parciales son pequeñas y KMO ≈ 1. Regla práctica: KMO ≥ 0.7.
- Aquí KMO $= 0.77$ (media) y ninguna materia baja de 0.74: **seguimos adelante**.

Contenido

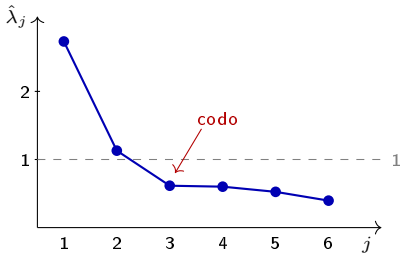
1. El problema: ¿se puede medir la inteligencia?
2. Paso 1. Mirar la matriz de correlación
3. Paso 2. Escribir el modelo factorial
4. Paso 3. ¿Es viable el AF? Bartlett y KMO
5. Paso 4. ¿Cuántos factores?
6. Paso 5. Estimar las cargas y las varianzas específicas
7. Paso 6. Interpretar los factores y rotar
8. Paso 7. Puntajes factoriales y reporte
9. Segunda vuelta: análisis factorial de la incidencia de dengue
10. Síntesis

¿Uno (inteligencia general) o dos (verbal y matemático)?

Antes de estimar $\mathbf{L}$ hay que fijar m. Los criterios usuales miran los **valores propios** de $\mathbf{R}$ (como en ACP):

```
auto   <- eigen(R)
lambda <- auto$values
round(lambda, 3)
## [1] 2.733 1.130 0.615 0.601 0.525 0.396
round(lambda / 6, 3)          # PVE
## [1] 0.455 0.188 0.103 0.100 0.087 0.066
round(cumsum(lambda / 6), 3)
## [1] 0.455 0.644 0.746 0.847 0.934 1.000
```

1. **Varianza explicada**: 2 factores, 64%; 3, 75%.
2. **Kaiser**: valores propios > 1: dos.
3. **Scree plot**: codo en $j = 3$.
4. **Análisis paralelo** (`fa.parallel`); y, con ML, la prueba de bondad de ajuste.



Decisión

$m = 2$: coincide con lo que sugería $\mathbf{R}$ y con la pregunta del investigador.

Contenido

1. El problema: ¿se puede medir la inteligencia?
2. Paso 1. Mirar la matriz de correlación
3. Paso 2. Escribir el modelo factorial
4. Paso 3. ¿Es viable el AF? Bartlett y KMO
5. Paso 4. ¿Cuántos factores?
6. Paso 5. Estimar las cargas y las varianzas específicas
7. Paso 6. Interpretar los factores y rotar
8. Paso 7. Puntajes factoriales y reporte
9. Segunda vuelta: análisis factorial de la incidencia de dengue
10. Síntesis

Tres caminos para estimar $\mathbf{L}$ y $\mathbf{\Psi}$

Tenemos $\mathbf{R}$ y queremos $\hat{\mathbf{L}}$ (6×2) y $\hat{\mathbf{\Psi}}$ tales que $\mathbf{R} \approx \hat{\mathbf{L}}\hat{\mathbf{L}}' + \hat{\mathbf{\Psi}}$.

1. **Factores principales**: usa la descomposición espectral de $\mathbf{R}$ (es el ACP leído como modelo factorial). No requiere normalidad.
2. **Factores principales iterativo** (ejes principales): refina el anterior estimando primero las comunalidades.
3. **Máxima verosimilitud**: **requiere normalidad multivariada**; a cambio permite probar si m factores bastan.

En psych

`principal(R, nfactors = m)` para (1); `fa(R, nfactors = m, fm = "pa")` para (2); `fa(R, nfactors = m, fm = "ml")` para (3).

Empezamos por el más directo.

1. Factores principales: la idea

Descomposición espectral de $\mathbf{R}$ con $\lambda_1 \geq \cdots \geq \lambda_p$ y vectores propios $\mathbf{e}_1, \ldots, \mathbf{e}_p$:

$$\mathbf{R} = \sum_{i=1}^{p} \lambda_i \mathbf{e}_i \mathbf{e}_i' = \underbrace{\left[\sqrt{\lambda_1}\mathbf{e}_1 \ \cdots \ \sqrt{\lambda_p}\mathbf{e}_p\right]}_{\mathbf{L}_{p\times p}} \begin{bmatrix} \sqrt{\lambda_1}\mathbf{e}_1' \\ \vdots \\ \sqrt{\lambda_p}\mathbf{e}_p' \end{bmatrix} = \mathbf{L}\mathbf{L}'.$$

Con $m = p$ la igualdad es exacta y $\mathbf{\Psi} = \mathbf{0}$, pero no hemos reducido nada. Nos quedamos con los m primeros términos y mandamos el resto a $\mathbf{\Psi}$:

Estimadores (J&W, 9-15)

$$\hat{\mathbf{L}} = \left[\sqrt{\hat{\lambda}_1}\hat{\mathbf{e}}_1 \ \cdots \ \sqrt{\hat{\lambda}_m}\hat{\mathbf{e}}_m\right], \qquad \hat{\psi}_i = 1 - \sum_{j=1}^{m} \hat{l}_{ij}^2 \quad \left(\hat{\mathbf{\Psi}} = \operatorname{diag}(\mathbf{R} - \hat{\mathbf{L}}\hat{\mathbf{L}}')\right).$$

- Las cargas del factor j son las del componente principal j multiplicadas por $\sqrt{\hat{\lambda}_j}$.
- Varianza explicada por el factor j: $\sum_i \hat{l}_{ij}^2 = \hat{\lambda}_j$, es decir, $\text{PVE}_{F_j} = \hat{\lambda}_j / p$.
- Al agregar un factor, los anteriores no cambian.

Factores principales en los exámenes

```
e    <- auto$vectors
L    <- e %*% diag(sqrt(lambda))    # cargas, m
     = p
L_m <- L[, 1:2]                     # m = 2
L_m[, 1] <- -L_m[, 1]               # signo
     arbitrario
rownames(L_m) <- mat
round(L_m, 3)
##              [,1]   [,2]
## Gaelico     0.658  0.449
## Ingles      0.688  0.290
## Historia    0.517  0.637
## Aritmetica  0.738 -0.413
## Algebra     0.744 -0.375
## Geometria   0.678 -0.355
h2   <- rowSums(L_m^2)              #
     comunalidades
Psi <- 1 - h2                       # var.
     especificas
round(cbind(h2, Psi), 3)
```

Materia	F_1	F_2	h_i^2	$\hat{\psi}_i$
Gaélico	0.658	0.449	0.63	0.37
Inglés	0.688	0.290	0.56	0.44
Historia	0.517	0.637	0.67	0.33
Aritmética	0.738	-0.413	0.72	0.28
Álgebra	0.744	-0.375	0.69	0.31
Geometría	0.678	-0.355	0.59	0.41
Var. expl.	0.455	0.188		

- Los dos factores explican entre el 56% (Inglés) y el 72% (Aritmética) de cada materia.
- F_1: todas las cargas positivas. F_2: verbales $+$, matemáticas $-$.

¿Qué tan bien reproduce el modelo a $\mathbf{R}$? La matriz residual

El ajuste se mira comparando $\mathbf{R}$ con lo que el modelo predice:

$$\text{Residuos} = \mathbf{R} - \left(\hat{\mathbf{L}}\hat{\mathbf{L}}' + \hat{\boldsymbol{\Psi}}\right).$$

La diagonal es cero por construcción; interesan los elementos fuera de ella.

```
MRES <- R - (L_m %*% t(L_m) + diag(Psi))
round(MRES, 2)
##          Gael   Ingl   Hist   Arit   Alge   Geom
## Gael     0.00 -0.14 -0.22 -0.01  0.01 -0.04
## Ingl    -0.14  0.00 -0.19 -0.03 -0.08 -0.04
## Hist    -0.22 -0.19  0.00  0.05  0.04  0.06
## Arit    -0.01 -0.03  0.05  0.00 -0.11 -0.18
## Alge     0.01 -0.08  0.04 -0.11  0.00 -0.17
## Geom    -0.04 -0.04  0.06 -0.18 -0.17  0.00
sum(MRES^2); sum(lambda[3:6]^2)    # cota
     (9-16)
```

- Los residuos más grandes (-0.22, -0.19, -0.18) están **dentro** de cada grupo: el método sobreestima las correlaciones intra-grupo.
- J&W (9-16): la suma de cuadrados de los residuos es $\leq \hat{\lambda}_{m+1}^2 + \cdots + \hat{\lambda}_p^2$. Aquí es 0.39; un ajuste aceptable, no excelente.

Con psych

`principal(R, nfactors = 2, rotate = "none")` entrega cargas (`PC1`, `PC2`), comunalidades (`h2`), varianzas específicas (`u2`) y `SS loadings` $= \hat{\lambda}_j$.

¿Podemos ajustar mejor? Sí, si estamos dispuestos a suponer normalidad.

2. Factores principales iterativo (ejes principales), en breve

El método anterior pone unos en la diagonal de $\mathbf{R}$, como si toda la varianza fuera común. Pero el modelo dice $\mathbf{L}\mathbf{L}' = \boldsymbol{\rho} - \boldsymbol{\Psi}$: la diagonal de $\mathbf{L}\mathbf{L}'$ son las **comunalidades**, no unos.

$$\mathbf{R}_r = \mathbf{R} - \boldsymbol{\Psi}^* = \begin{pmatrix} h_1^{*2} & r_{12} & \cdots & r_{1p} \\ r_{21} & h_2^{*2} & \cdots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \cdots & h_p^{*2} \end{pmatrix}$$

1. Estimación inicial: $\psi_i^* = 1/r^{ii}$ (r^{ii}: diagonal de $\mathbf{R}^{-1}$), de modo que h_i^{*2} es el R^2 de X_i sobre las demás.
2. Descomposición espectral de $\mathbf{R}_r$; $\hat{\mathbf{L}}^*$ con los m primeros términos.
3. Nuevas comunalidades $h_i^{*2} = \sum_j \hat{l}_{ij}^{*2}$; volver a (2) hasta que no cambien.

Observación

A veces no converge o da comunalidades > 1 (Heywood). En `psych`: `fa(R, nfactors = 2, fm = "pa")`.

3. Máxima verosimilitud: aquí entra la normalidad

Suponga que

$$\mathbf{Z} \sim N_p(\mathbf{0}, \boldsymbol{\rho}), \qquad \mathbf{F} \sim N_m(\mathbf{0}, \mathbf{I}), \qquad \boldsymbol{\varepsilon} \sim N_p(\mathbf{0}, \boldsymbol{\Psi}).$$

Con una muestra $\mathbf{z}_1, \ldots, \mathbf{z}_n$, la verosimilitud de $\boldsymbol{\rho}$ es

$$L(\boldsymbol{\rho} \mid \mathbf{z}) = \frac{1}{(2\pi)^{np/2}|\boldsymbol{\rho}|^{n/2}} \exp\Big\{ -\tfrac{1}{2} \sum_{j=1}^{n} \mathbf{z}_j' \boldsymbol{\rho}^{-1} \mathbf{z}_j \Big\},$$

y, reemplazando $\boldsymbol{\rho} = \mathbf{L}\mathbf{L}' + \boldsymbol{\Psi}$,

$$L(\mathbf{L}, \boldsymbol{\Psi} \mid \mathbf{z}) = \frac{1}{(2\pi)^{np/2}|\mathbf{L}\mathbf{L}' + \boldsymbol{\Psi}|^{n/2}} \exp\Big\{ -\tfrac{1}{2} \sum_{j=1}^{n} \mathbf{z}_j' [\mathbf{L}\mathbf{L}' + \boldsymbol{\Psi}]^{-1} \mathbf{z}_j \Big\}.$$

- $\hat{\mathbf{L}}$ y $\hat{\boldsymbol{\Psi}}$ son las matrices que maximizan $L(\mathbf{L}, \boldsymbol{\Psi} \mid \mathbf{z})$, para un m fijado de antemano.
- Como $\mathbf{L}$ sólo está determinada hasta rotación, se impone $\mathbf{L}'\boldsymbol{\Psi}^{-1}\mathbf{L}$ diagonal y se maximiza **numéricamente**. Puede no converger.
- Invariante ante cambios de escala: con $\mathbf{S}$ o con $\mathbf{R}$ se obtienen soluciones equivalentes.

Máxima verosimilitud en los exámenes

```
AF.ml <- fa(R, nfactors = 2, rotate = "
    none",
            fm = "ml", n.obs = 220)
L.m <- AF.ml$loadings       # cargas
h2  <- AF.ml$communality    # comunalidades
psi <- AF.ml$uniquenesses   # var.
    especificas
round(R - (L.m %*% t(L.m) + diag(psi)), 2)
```

- Las cargas cambian respecto a factores principales (distinto criterio), pero el **patrón** es el mismo: F_1 general, F_2 bipolar.
- Las comunalidades son **menores**: ML no obliga a la diagonal a ser 1.
- Los residuos ahora son todos ≤ 0.03 en valor absoluto: ajuste mucho mejor.

Materia	F_1	F_2	h_i^2	$\hat{\psi}_i$
Gaélico	0.553	0.429	0.490	0.510
Inglés	0.568	0.288	0.406	0.594
Historia	0.392	0.450	0.356	0.644
Aritmética	0.740	-0.273	0.623	0.377
Álgebra	0.724	-0.211	0.569	0.431
Geometría	0.595	-0.132	0.372	0.628

Comparación de residuos

	Fact. princ.	Máx. veros.
Mayor residuo	0.22	0.03
Raíz del ECM	0.11	0.01

El premio por suponer normalidad: ¿bastan dos factores?

Prueba de adecuación del modelo (J&W, 9-39)

H_0: $\boldsymbol{\rho} = \mathbf{L}\mathbf{L}' + \boldsymbol{\Psi}$ con m factores vs. H_1: $\boldsymbol{\rho}$ cualquiera. Se rechaza H_0 si

$$\left(n - 1 - \tfrac{2p+4m+5}{6}\right) \ln \frac{|\hat{\mathbf{L}}\hat{\mathbf{L}}' + \hat{\boldsymbol{\Psi}}|}{|\mathbf{R}|} > \chi^2_\nu(\alpha), \qquad \nu = \tfrac{1}{2}\left[(p-m)^2 - p - m\right].$$

```
AF.ml$STATISTIC; AF.ml$dof; AF.ml$PVAL
## m = 2: chi2 = 2.34, gl = 4, p = 0.67
fa(R, 1, fm = "ml", n.obs = 220)$PVAL
## m = 1: chi2 = 52.0, gl = 9, p < 0.001
```

- Con $m = 1$ se rechaza: **una sola inteligencia general no basta**.
- Con $m = 2$ no se rechaza ($p = 0.67$): dos factores reproducen bien las correlaciones.

Cuidados

Sólo tiene sentido si $\nu > 0$. Con n grande rechaza con facilidad y, sin normalidad, el valor-p no es confiable.

¿Cuál método usar?

- Bajo **normalidad**, máxima verosimilitud: estimaciones más precisas, mejor ajuste y prueba de bondad de ajuste.
- Sin normalidad o con n pequeño, **factores principales** (o ejes principales).
- Estrategia usual: fijar m con los valores propios (factores principales) y luego estimar por ML.
- Si varios métodos coinciden en lo esencial (como aquí), hay más confianza en la estructura encontrada.

Dónde estamos

Ya tenemos $\hat{\mathbf{L}}$ y $\hat{\mathbf{\Psi}}$. Falta responder la pregunta del investigador: **¿qué son F_1 y F_2?**

Ejemplo 2 para la Actividad 2: satisfacción con un nuevo producto

Se encuestó a $n = 200$ personas sobre un nuevo producto: **sabor**, **aroma**, **color**, **textura**, **utilidad**, **facilidad de encontrar** (local) y **empaque**, en una escala de 1 a 7.

$\mathbf{R} =$

	Sabor	Aroma	Color	Textura	Utilidad	Local	Empaque
Sabor	1						
Aroma	0.969	1					
Color	0.801	0.711	1				
Textura	0.960	0.991	0.696	1			
Utilidad	0.050	0.037	0.138	0.029	1		
Local	0.056	0.046	0.096	0.045	0.833	1	
Empaque	0.103	0.090	0.163	0.087	0.693	0.530	1

- Escala Likert de 7 puntos tratada como cuantitativa; mismas unidades, pero igual se usa $\mathbf{R}$.
- A simple vista: un bloque sensorial (sabor, aroma, color, textura) y un bloque práctico (utilidad, local, empaque).

Actividad 2 (15 min): recorrer los pasos 1–5 con el Ejemplo 2

```
R2 <- matrix(c
     (1,0.969,0.801,0.96,0.05,0.056,0.103,
   0.969,1,0.711,0.991,0.037,0.046,0.09,
   0.801,0.711,1,0.696,0.138,0.096,0.163,
   0.96,0.991,0.696,1,0.029,0.045,0.087,
   0.05,0.037,0.138,0.029,1,0.833,0.693,
   0.056,0.046,0.096,0.045,0.833,1,0.53,
   0.103,0.09,0.163,0.087,0.693,0.53,1), 7)
nom <- c("Sabor","Aroma","Color","Textura",
         "Utilidad","Local","Empaque")
dimnames(R2) <- list(nom, nom)
cortest.bartlett(R2, n = 200); KMO(R2)
round(eigen(R2)$values / 7, 3)
AF.fp <- principal(R2, nfactors = 2, rotate = "
    none")
AF.ml <- fa(R2, nfactors = 2, fm = "ml", rotate =
     "none",
            n.obs = 200)
```

Tareas:

1. **Paso 1**: describa los bloques de $\mathbf{R}$.
2. **Paso 3**: ¿es viable el AF? (Bartlett $\chi^2 = 1955$, KMO $= 0.72$.)
3. **Paso 4**: ¿cuántos factores? (PVE: $0.52, 0.33, 0.07, \ldots$)
4. **Paso 5**: con factores principales, lea cargas, comunalidades y $\hat{\psi}_i$. ¿Qué variable queda peor explicada?
5. Compare con ML: ¿cambia el patrón? ¿Aparece un caso de Heywood? ¿Qué dice la prueba de bondad de ajuste?
6. Proponga un nombre para cada factor.

Contenido

1. El problema: ¿se puede medir la inteligencia?
2. Paso 1. Mirar la matriz de correlación
3. Paso 2. Escribir el modelo factorial
4. Paso 3. ¿Es viable el AF? Bartlett y KMO
5. Paso 4. ¿Cuántos factores?
6. Paso 5. Estimar las cargas y las varianzas específicas
7. Paso 6. Interpretar los factores y rotar
8. Paso 7. Puntajes factoriales y reporte
9. Segunda vuelta: análisis factorial de la incidencia de dengue
10. Síntesis

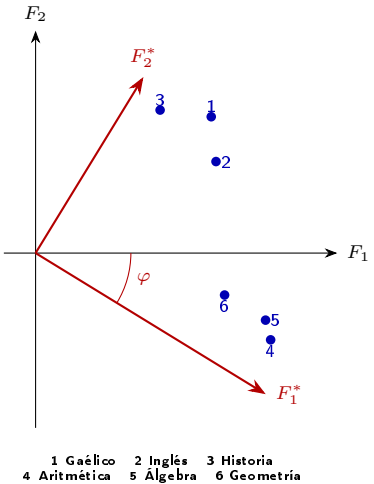
Intentemos interpretar la solución de máxima verosimilitud

Materia	F_1	F_2	h_i^2
Gaélico	0.553	0.429	0.490
Inglés	0.568	0.288	0.406
Historia	0.392	0.450	0.356
Aritmética	0.740	-0.273	0.623
Álgebra	0.724	-0.211	0.569
Geometría	0.595	-0.132	0.372

- En F_1 todas las cargas son **positivas**: quien obtiene puntuaciones altas en todas las pruebas obtiene puntaje alto. Podría llamarse **inteligencia general**.
- En F_2 las tres primeras cargas son positivas y las tres últimas negativas: un **factor bipolar** verbal vs. matemático. (Los signos de una columna son arbitrarios: se pueden invertir sin afectar nada.)
- Pero Gaélico, Inglés e Historia tienen cargas **similares en ambos factores**. La interpretación no es del todo clara.

¿Qué hacemos?

Mirar las cargas como puntos en el plano (Figura 9.1 de J&W)



Cada materia es el punto $(\hat{l}_{i1}, \hat{l}_{i2})$. Se ven **dos grupos**, pero ninguno queda sobre un eje: por eso las cargas se reparten.

Recordemos la advertencia 2 del Paso 2: **las cargas sólo están definidas hasta una rotación**. Si giramos los ejes un ángulo $\varphi \approx 31.5°$:

- Aritmética, Álgebra y Geometría quedan sobre F_1^*: **capacidad matemática**.
- Gaélico, Inglés e Historia quedan cerca de F_2^*: **capacidad verbal**.
- La inteligencia general queda "repartida" entre F_1^* y F_2^*.

¿Cómo escoger el ángulo?

Rotar es multiplicar por una matriz ortogonal

Para $m = 2$, girar los ejes un ángulo φ en sentido horario es

$$\hat{\mathbf{L}}^* = \hat{\mathbf{L}}\mathbf{T}, \qquad \mathbf{T} = \begin{pmatrix} \cos\varphi & \sin\varphi \\ -\sin\varphi & \cos\varphi \end{pmatrix}, \qquad \mathbf{T}\mathbf{T}' = \mathbf{I}.$$

En el ejemplo, con $\varphi = 31.5°$:

$$\hat{\mathbf{L}}^* = \begin{pmatrix} 0.553 & 0.429 \\ 0.568 & 0.288 \\ 0.392 & 0.450 \\ 0.740 & -0.273 \\ 0.724 & -0.211 \\ 0.595 & -0.132 \end{pmatrix} \begin{pmatrix} 0.852 & 0.523 \\ -0.523 & 0.852 \end{pmatrix} = \begin{pmatrix} 0.247 & 0.655 \\ 0.333 & 0.543 \\ 0.099 & 0.589 \\ 0.774 & 0.155 \\ 0.727 & 0.199 \\ 0.576 & 0.199 \end{pmatrix}.$$

Lo que no cambia

$\hat{\mathbf{L}}^*\hat{\mathbf{L}}^{*\prime} + \hat{\mathbf{\Psi}} = \hat{\mathbf{L}}\hat{\mathbf{L}}' + \hat{\mathbf{\Psi}}$: la matriz residual, las comunalidades y las varianzas específicas son las mismas. Rotar **nunca mejora el ajuste**; sólo cambia la interpretación.

Con $m > 2$ hay muchos ángulos posibles: hace falta un **criterio** que escoja $\mathbf{T}$ automáticamente.

Criterio varimax (Kaiser, 1958)

Sea $\tilde{l}^*_{ij} = \hat{l}^*_{ij}/\hat{h}_i$ la carga rotada **escalada** por la raíz de la comunalidad (así las variables bien explicadas no dominan).

Varimax

Elegir $\mathbf{T}$ que maximice

$$V = \frac{1}{p}\sum_{j=1}^{m}\left[\sum_{i=1}^{p}\tilde{l}^{*4}_{ij} - \frac{1}{p}\Big(\sum_{i=1}^{p}\tilde{l}^{*2}_{ij}\Big)^2\right] \;\propto\; \sum_{j=1}^{m}\mathrm{Var}\,(\tilde{l}^{*2}_{1j},\ldots,\tilde{l}^{*2}_{pj}),$$

es decir, la suma sobre los factores de la varianza de los cuadrados de las cargas escaladas. Después se multiplican las cargas por $\hat{h}_i$ para recuperar la escala original.

- Maximizar la varianza de $\tilde{l}^{*2}_{ij}$ *dentro de cada columna* empuja las cargas hacia 0 o hacia ± 1: cada factor queda definido por **pocas variables con carga alta**.
- Es el criterio más usado; tiende a distribuir la varianza explicada entre los factores (desaparece el "factor general").

Varimax en los exámenes

```
AF.ml.r <- fa(R, nfactors = 2, rotate = "
    varimax",
              fm = "ml", n.obs = 220)
print(AF.ml.r$loadings, cutoff = 0.3)
AF.ml.r$communality          # las mismas
AF.ml.r$rot.mat              # la matriz T
# equivalente, a partir de la solucion sin
    rotar:
varimax(AF.ml$loadings)
```

Varimax entrega

$$\mathbf{T} = \begin{pmatrix} 0.852 & 0.523 \\ -0.523 & 0.852 \end{pmatrix}, \qquad \varphi = 31.5°,$$

el mismo giro que hicimos "a ojo" en la figura.

Materia	F_1^*	F_2^*	h_i^2
Gaélico	0.247	**0.655**	0.490
Inglés	0.333	**0.543**	0.406
Historia	0.099	**0.589**	0.356
Aritmética	**0.774**	0.155	0.623
Álgebra	**0.727**	0.199	0.569
Geometría	**0.576**	0.199	0.372
Var. expl.	0.274	0.196	

Respuesta a la pregunta 2 del investigador

F_1^* = **capacidad matemática**; F_2^* = **capacidad verbal**. Las comunalidades no cambiaron.

Otros criterios de rotación

Rotaciones ortogonales ($\mathbf{T}'\mathbf{T} = \mathbf{I}$):

- **Varimax**: simplifica las *columnas* de $\mathbf{L}$ (cada factor con pocas cargas altas).
- **Cuartimax**: simplifica las *filas* (cada variable en un solo factor); tiende a producir un factor general.
- **Equimax**: compromiso entre las dos.

Los factores rotados siguen **no correlacionados**.

Rotaciones oblicuas ($\mathbf{T}$ no ortogonal):

- **Oblimin**, **Promax**.
- Los factores quedan **correlacionados**. ¿Es realista que capacidad verbal y matemática se relacionen? Probablemente sí.
- Se pierde la estructura del modelo ortogonal; hay que distinguir matriz de *patrón* y de *estructura*.

Cuándo no rotar

Si la solución sin rotar ya es interpretable, la rotación es innecesaria. Cuando se rota sin necesidad, la interpretación suele empeorar.

Contenido

1. El problema: ¿se puede medir la inteligencia?
2. Paso 1. Mirar la matriz de correlación
3. Paso 2. Escribir el modelo factorial
4. Paso 3. ¿Es viable el AF? Bartlett y KMO
5. Paso 4. ¿Cuántos factores?
6. Paso 5. Estimar las cargas y las varianzas específicas
7. Paso 6. Interpretar los factores y rotar
8. Paso 7. Puntajes factoriales y reporte
9. Segunda vuelta: análisis factorial de la incidencia de dengue
10. Síntesis

La pregunta 3: ¿qué puntaje tiene cada estudiante en cada capacidad?

Los factores no se observan, pero podemos **estimar** el valor $\mathbf{f}_j$ que toman para el estudiante j a partir de sus seis puntajes $\mathbf{z}_j$. Dos enfoques (J&W, sección 9.5):

Mínimos cuadrados ponderados (Bartlett)

Trata $\mathbf{z}_j = \mathbf{L}\mathbf{f}_j + \boldsymbol{\varepsilon}_j$ como una regresión con pesos $1/\psi_i$:

$$\hat{\mathbf{f}}_j = \left(\hat{\mathbf{L}}'\hat{\boldsymbol{\Psi}}^{-1}\hat{\mathbf{L}}\right)^{-1}\hat{\mathbf{L}}'\hat{\boldsymbol{\Psi}}^{-1}\mathbf{z}_j.$$

No necesita normalidad.

Regresión (Thomson)

Bajo **normalidad**, $(\mathbf{Z}, \mathbf{F})$ es normal conjunta y

$$\hat{\mathbf{f}}_j = E[\mathbf{F} \mid \mathbf{z}_j] = \hat{\mathbf{L}}'\mathbf{R}^{-1}\mathbf{z}_j.$$

Los puntajes quedan "encogidos" hacia 0.

- Se usan las cargas **rotadas** y se tratan $\hat{\mathbf{L}}$, $\hat{\boldsymbol{\Psi}}$ como si fueran los verdaderos valores.
- Con factores principales se usan mínimos cuadrados ordinarios, $(\hat{\mathbf{L}}'\hat{\mathbf{L}})^{-1}\hat{\mathbf{L}}'\mathbf{z}_j$, que equivalen a los componentes principales escalados por $1/\sqrt{\hat{\lambda}_k}$.
- En `psych`: `scores = "regression"` o `"Bartlett"`; se necesitan los **datos crudos**.

Dos estudiantes hipotéticos

Puntajes estandarizados (Gaélico, Inglés, Historia, Aritmética, Álgebra, Geometría):
$\mathbf{z}_A = (1.2,\ 0.8,\ 0.5,\ -0.9,\ -1.1,\ -0.4)$ y $\mathbf{z}_B = (-0.5,\ 0.1,\ -0.3,\ 1.4,\ 1.0,\ 1.2)$.

```
L   <- unclass(AF.ml.r$loadings)    # cargas
    rotadas
Psi <- diag(AF.ml.r$uniquenesses)
zA  <- c(1.2, 0.8, 0.5, -0.9, -1.1, -0.4)
zB  <- c(-0.5, 0.1, -0.3, 1.4, 1.0, 1.2)
W   <- solve(t(L) %*% solve(Psi) %*% L) %*%
       t(L) %*% solve(Psi)          # MC ponderados
Rg  <- t(L) %*% solve(R)            # regresion
round(rbind(WLS_A = W %*% zA, Reg_A = Rg %*% zA,
            WLS_B = W %*% zB, Reg_B = Rg %*% zB),
                  2)
##         ML1   ML2   (ML1 = matem., ML2 = verbal)
## WLS_A -1.68  2.07
## Reg_A -0.98  1.05
## WLS_B  1.98 -1.18
## Reg_B  1.32 -0.47
```

- A está por encima del promedio en capacidad **verbal** y por debajo en **matemática**; B, al revés.
- Ambos métodos ordenan igual; regresión da valores más cercanos a 0.
- Estos puntajes sirven como insumo de una regresión, una clasificación o un agrupamiento.

Pregunta 3: respondida

Cada estudiante recibe un puntaje en cada capacidad.

Cómo se reporta un análisis factorial

El camino que recorrimos

1. Datos: naturaleza, escala, n/p, supuestos.
2. Matriz de correlación y su lectura.
3. Modelo: $\boldsymbol{\rho} = \mathbf{L}\mathbf{L}' + \boldsymbol{\Psi}$.
4. Viabilidad: Bartlett y KMO.
5. Número de factores m.
6. Estimación de $\mathbf{L}$ y $\boldsymbol{\Psi}$ (método, ajuste).
7. Rotación e interpretación.
8. Puntajes factoriales.

Lo que va en el informe

- Bartlett y KMO.
- Criterio para m y varianza explicada.
- Tabla de cargas rotadas, h_i^2 y $\hat{\psi}_i$.
- Método de estimación y de rotación.
- Residuos o prueba de bondad de ajuste.
- Nombre e interpretación de cada factor.
- Puntajes, si se usan después.

Para conjuntos grandes

Divida los datos en dos mitades y ajuste en cada una: si las cargas son similares, la estructura factorial es **estable**.

Comparación entre AF y ACP

Ambas son técnicas de reducción de dimensionalidad, pero los criterios de optimización son diferentes:

	ACP	**AF**
Objetivo	Explicar la *variabilidad total* de los datos	Explicar las *covarianzas (correlaciones)* entre variables mediante factores comunes
Modelo	Transformación de los datos; sin supuestos	Modelo $\mathbf{X} = \boldsymbol{\mu} + \mathbf{L}\mathbf{F} + \boldsymbol{\varepsilon}$ con supuestos sobre $\mathbf{F}$ y $\boldsymbol{\varepsilon}$
Dirección	$Y_j = \mathbf{e}_j'\mathbf{X}$: las componentes son función de las variables (se "agregan")	$X_i = \sum_j l_{ij}F_j + \varepsilon_i$: las variables son función de los factores (se "desagregan")
Nuevas variables	Índices observables	Atributos no observables (latentes)
Varianza	Toda la varianza (diagonal de $\boldsymbol{\Sigma}$)	Sólo la varianza *compartida*; la específica queda en $\boldsymbol{\Psi}$
Unicidad	Solución única	Infinitas soluciones equivalentes (rotación)

El método de los factores principales es el puente: con $\boldsymbol{\Psi} = \mathbf{0}$ y $m = p$ el AF **es** el ACP.

Contenido

1. El problema: ¿se puede medir la inteligencia?
2. Paso 1. Mirar la matriz de correlación
3. Paso 2. Escribir el modelo factorial
4. Paso 3. ¿Es viable el AF? Bartlett y KMO
5. Paso 4. ¿Cuántos factores?
6. Paso 5. Estimar las cargas y las varianzas específicas
7. Paso 6. Interpretar los factores y rotar
8. Paso 7. Puntajes factoriales y reporte
9. Segunda vuelta: análisis factorial de la incidencia de dengue
10. Síntesis

El mismo camino en un problema real

Vamos a recorrer los mismos pasos con un artículo reciente sobre dengue en Colombia. Esta vez el problema es más "sucio": pocas observaciones, variables de naturaleza distinta y una variable (la incidencia) que es la que realmente nos interesa explicar.

Paso	En el artículo
0	¿Sirven los datos? Variables, unidades, $n = 32$
1	Matriz de correlación (Figura 2)
3	KMO (los autores) y Bartlett (nosotros)
4	Número de ejes: 2 (76.7% / 80.7%)
5–6	Cargas rotadas e interpretación (Figura 3)
7	Puntajes de los departamentos (sólo mencionado)

El artículo

Portilla, Tovar-Cuevas & Manotas (2025). *Biomédica*, 45(Supl. 2), 83–99

Characterization of Colombian departments based on climatic factors, infrastructure, basic service access, and dengue incidence rate.

Pregunta: ¿qué factores climáticos, socioeconómicos y de acceso a servicios básicos se relacionan con la incidencia de dengue en los departamentos de Colombia en 2023?

Unidades de análisis: los 32 departamentos ($n = 32$).

Fuentes: INS (casos de dengue), Encuesta Nacional de Calidad de Vida del DANE (servicios y vivienda), ERA5, CHIRPS y NDVI satelitales (clima).

Método: análisis factorial y, después, agrupamiento de departamentos (no lo veremos hoy).

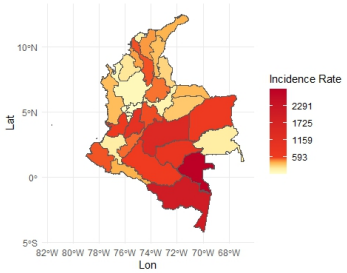


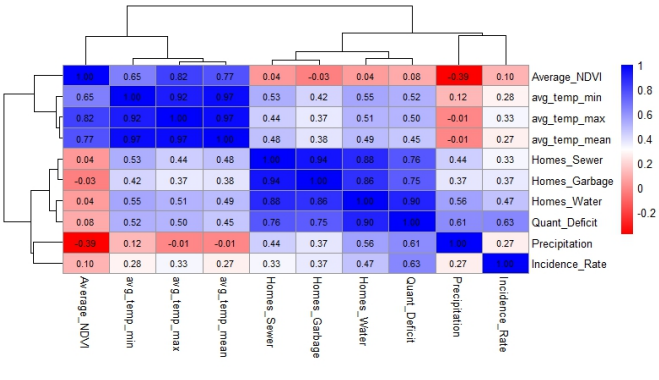
Figura 1 del artículo: incidencia de dengue por 100 000 hab., 2023.

Las variables: ¿cumplen con lo que pide el AF?

Grupo	Variable	Unidad	Fuente
Clima	Temperatura mínima, máxima y media	°C	ERA5
Clima	Precipitación acumulada	mm	CHIRPS
Clima	NDVI promedio (vegetación)	índice $[-1, 1]$	NCEI
Servicios	Hogares sin acueducto / alcantarillado / basuras	% de hogares	ENCV–DANE
Déficit	Déficit habitacional cuantitativo	% de hogares	ENCV–DANE
Dengue	Tasa de incidencia	casos por 100 000 hab.	INS

- Las $p = 10$ variables son **cuantitativas continuas**, medidas sobre los **mismos** 32 departamentos.
- Las unidades son muy distintas (°C, mm, %, tasas): se trabaja con la matriz de **correlación** $\mathbf{R}$.
- $n/p = 3.2$: muestra pequeña. Es una limitación que hay que tener en cuenta al interpretar (y que hace poco confiables las pruebas que requieren normalidad).

Paso 1: mirar la matriz de correlación (Figura 2 del artículo)



- Acueducto, alcantarillado, basuras y déficit habitacional: correlaciones > 0.75 entre sí. Un hogar sin un servicio suele carecer de los otros.
- Las tres temperaturas y el NDVI forman otro bloque (0.65–0.97).
- La tasa de dengue se correlaciona moderadamente con el déficit habitacional (0.63) y los servicios (0.33–0.47), y poco con el clima.
- La precipitación se asocia negativamente con el NDVI (-0.39).

Dos bloques claros: **¿dos factores?**

Paso 2: ¿es viable el AF? Lo que reportan los autores

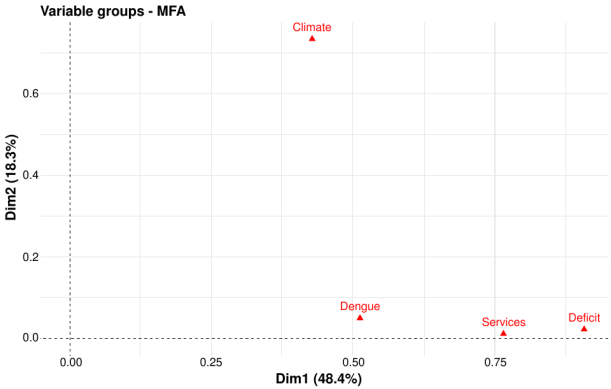
- **KMO global** $= 0.78$: la muestra es adecuada para el análisis factorial.
- KMO por variable entre 0.70 y 0.85. Los más altos: hogares sin acueducto (0.85), sin alcantarillado (0.80), sin basuras (0.80) y déficit habitacional (0.80).
- Los más bajos: precipitación y NDVI (≈ 0.70); se conservan porque superan el umbral de 0.7.

Una variante: análisis factorial múltiple (AFM)

Los autores agrupan las variables en **cuatro grupos** (clima, dengue, servicios, déficit) y aplican AFM, que pondera cada grupo para que ninguno domine por tener más variables. Es una extensión del ACP/AF a grupos de variables; la lógica (correlaciones $\rightarrow$ pocos ejes $\rightarrow$ interpretación) es la misma que vimos.

Nosotros vamos a **replicar el análisis con el AF clásico** a partir de la matriz de correlación de la Figura 2.

Paso 3: lo que encontraron los autores (Figura 3 del artículo)



- Dos ejes explican el **76.7%** de la variabilidad total ($48.4\% + 18.3\%$).
- El grupo **clima** se separa en el eje 2: un patrón distinto al de los demás.
- **Servicios**, **déficit** y **dengue** se ubican sobre el eje 1: la incidencia de dengue se asocia más con las condiciones socioeconómicas y de vivienda que con el clima.

Lectura

Eje 1 $\approx$ "carencias estructurales"; eje 2 $\approx$ "clima cálido".

Paso 4: replicamos con el AF clásico en R

```
v <- c("NDVI","Tmin","Tmax","Tmed","Alcant","Basuras",
       "Agua","Deficit","Precip","Tasa")
R <- matrix(c(
 1.00,0.65,0.82,0.77,0.04,-0.03,0.04,0.08,-0.39,0.10,
 0.65,1.00,0.92,0.97,0.53,0.42,0.55,0.52,0.12,0.28,
 0.82,0.92,1.00,0.97,0.44,0.37,0.51,0.50,-0.01,0.33,
 0.77,0.97,0.97,1.00,0.48,0.38,0.49,0.45,-0.01,0.27,
 0.04,0.53,0.44,0.48,1.00,0.94,0.88,0.76,0.44,0.33,
-0.03,0.42,0.37,0.38,0.94,1.00,0.86,0.75,0.37,0.37,
 0.04,0.55,0.51,0.49,0.88,0.86,1.00,0.90,0.56,0.47,
 0.08,0.52,0.50,0.45,0.76,0.75,0.90,1.00,0.61,0.63,
-0.39,0.12,-0.01,-0.01,0.44,0.37,0.56,0.61,1.00,0.27,
 0.10,0.28,0.33,0.27,0.33,0.37,0.47,0.63,0.27,1.00), 10)
dimnames(R) <- list(v, v)
require(psych)
cortest.bartlett(R, n = 32)    # chi2 = 445.9, gl = 45
KMO(R)                         # MSA global = 0.73
round(eigen(R)$values, 2)
## 5.45 2.62 0.84 0.63 0.20 0.13 0.06 0.05 0.02 0.01
```

- **Bartlett**: $\chi^2_{\text{obs}} = 445.9$, 45 g.l., valor-$p \approx 0$: se rechaza $\boldsymbol{\rho} = \mathbf{I}$ (ojo: con $n = 32$ y sin verificar normalidad, es sólo orientativo).
- **KMO** $= 0.73$ con la matriz redondeada (los autores: 0.78). Viable.
- **Kaiser**: dos valores propios > 1.
- Varianza explicada: $54.5\% + 26.2\% = \mathbf{80.7}\%$ (los autores, con AFM: 76.7%).

Escogemos $m = 2$.

Paso 5: cargas rotadas e interpretación

```
AF <- principal(R, nfactors = 2,
                rotate = "varimax")
print(AF$loadings, cutoff = 0.3)
AF$communality
```

F_1^*: carencias estructurales

Hogares sin acueducto, alcantarillado y basuras, déficit habitacional y precipitación.

F_2^*: clima cálido

Temperaturas mínima, máxima y media, y NDVI.

Variable	F_1^*	F_2^*	h_i^2	$\hat{\psi}_i$
NDVI	-0.21	**0.92**	0.90	0.10
Temp. mínima	0.37	**0.87**	0.89	0.11
Temp. máxima	0.28	**0.95**	0.97	0.03
Temp. media	0.27	**0.94**	0.96	0.04
Sin alcantarillado	**0.87**	0.25	0.82	0.18
Sin basuras	**0.87**	0.17	0.78	0.22
Sin acueducto	**0.93**	0.26	0.93	0.07
Déficit habitacional	**0.91**	0.25	0.88	0.12
Precipitación	**0.72**	-0.28	0.60	0.40
Tasa de dengue	**0.54**	0.19	0.33	0.67
Prop. varianza	0.43	0.37		

Factores principales, $m = 2$, rotación varimax ($\varphi \approx 38.7°$).

Paso 6: ¿qué nos dice el AF sobre el dengue?

- La tasa de dengue carga en el factor de **carencias estructurales** (0.54) y casi nada en el de **clima** (0.19): coincide con la lectura de los autores (Figura 3).
- Pero su comunalidad es baja ($h^2 = 0.33$): los dos factores explican sólo un tercio de la variabilidad de la incidencia. **Dos tercios quedan en la varianza específica**.
- Es coherente con el artículo: la incidencia se relaciona con los servicios y la vivienda, pero la fuerza de esas asociaciones no es suficiente para que el dengue "pertenezca" del todo a un bloque.
- Las temperaturas y el NDVI están casi perfectamente explicadas ($h^2 > 0.89$): forman un factor muy nítido.

Lo que el AF no hace

No dice *cuáles* departamentos son más vulnerables: para eso los autores usan los puntajes de los departamentos en los ejes y los agrupan (parte del artículo que no cubrimos). Tampoco establece causalidad: describe correlaciones de un año, con $n = 32$.

Actividad 3 (10 min): el caso del dengue

```
# con la matriz R del articulo ya construida
AF3 <- principal(R, nfactors = 3, rotate = "
    varimax")
print(AF3$loadings, cutoff = 0.3)
round(AF3$communality, 2)
# sin la tasa de dengue
AF2 <- principal(R[-10, -10], nfactors = 2,
                 rotate = "varimax")
# por maxima verosimilitud
AFml <- fa(R, nfactors = 2, fm = "ml",
           rotate = "varimax", n.obs = 32)
AFml$PVAL
```

Tareas:

1. Con $m = 3$, ¿qué variables definen el tercer factor? ¿Cómo lo llamaría? ¿Mejora la comunalidad de la tasa de dengue?
2. ¿Es razonable incluir la tasa de dengue *dentro* del AF, o debería dejarse afuera y relacionarse después con los puntajes? Argumente.
3. Con $n = 32$ y 10 variables, ¿qué tan confiables son Bartlett y la prueba de bondad de ajuste de ML? ¿Qué supuesto necesitarían?
4. **ACP vs. AF.** Un colega dice: "hice ACP, me quedé con dos componentes y los llamé factores". ¿Qué le diría?

Contenido

1. El problema: ¿se puede medir la inteligencia?
2. Paso 1. Mirar la matriz de correlación
3. Paso 2. Escribir el modelo factorial
4. Paso 3. ¿Es viable el AF? Bartlett y KMO
5. Paso 4. ¿Cuántos factores?
6. Paso 5. Estimar las cargas y las varianzas específicas
7. Paso 6. Interpretar los factores y rotar
8. Paso 7. Puntajes factoriales y reporte
9. Segunda vuelta: análisis factorial de la incidencia de dengue
10. Síntesis

Síntesis: qué es y cómo se reporta

Qué es

- Modelo $\mathbf{Z} = \mathbf{LF} + \boldsymbol{\varepsilon}$ con $\mathrm{Cov}(\mathbf{F}) = \mathbf{I}$, $\mathrm{Cov}(\boldsymbol{\varepsilon}) = \boldsymbol{\Psi}$ diagonal.
- Implica $\boldsymbol{\rho} = \mathbf{LL}' + \boldsymbol{\Psi}$ y $\mathrm{Corr}(Z_i, F_j) = l_{ij}$.
- $1 = h_i^2 + \psi_i$: comunalidad + varianza específica.
- $\mathbf{L}$ única sólo hasta rotaciones $\mathbf{LT}$.

Estimación

- Factores principales: $\hat{\mathbf{L}} = [\sqrt{\hat{\lambda}_j}\hat{\mathbf{e}}_j]$.
- Ejes principales: iterar sobre la matriz reducida.
- Máxima verosimilitud: normalidad, prueba de m.

Lo que respondimos hoy

- ¿Una inteligencia general? No basta ($m = 1$ se rechaza).
- ¿Capacidades verbal y matemática? Sí: dos factores rotados, claramente interpretables.
- ¿Puntaje de cada estudiante? Sí: puntajes factoriales.
- ¿Y el dengue? La incidencia se asocia con las carencias estructurales, no con el clima, pero queda mal explicada ($h^2 = 0.33$).

Advertencias frecuentes

- Variables cuantitativas (o Likert amplias) sobre los mismos individuos; sin correlaciones no hay factores: revise Bartlett y KMO antes de empezar.
- Bartlett, máxima verosimilitud, su prueba de bondad de ajuste y los puntajes por regresión **requieren normalidad multivariada**; si no se cumple, use factores principales y mínimos cuadrados ponderados.
- Las cargas con $\mathbf{S}$ y con $\mathbf{R}$ son distintas (salvo con ML, que es invariante). Con escalas diferentes use $\mathbf{R}$.
- Los **signos** de una columna de $\mathbf{L}$ son arbitrarios: interprete el patrón.
- La rotación **no mejora el ajuste**; sólo la interpretación. Las comunalidades no cambian.
- Comunalidades ≥ 1 o $\hat{\psi}_i \leq 0$ (Heywood): señal de que m es demasiado grande, n pequeño o el modelo inadecuado.
- Los puntajes factoriales son *estimaciones*, no observaciones: úselos con cautela en otros análisis.
- El AF sólo capta relaciones **lineales** y es sensible a atípicos.

Referencias

- Johnson, R. A. & Wichern, D. W. (2007). *Applied Multivariate Statistical Analysis* (6.ª ed.). Pearson. Capítulo 9.
- Portilla, J., Tovar-Cuevas, J. & Manotas, D. (2025). Characterization of Colombian departments based on climatic factors, infrastructure, basic service access, and dengue incidence rate. *Biomédica*, 45(Supl. 2), 83–99. doi:10.7705/biomedica.7865
- Spearman, C. (1904). General intelligence, objectively determined and measured. *American Journal of Psychology*, 15, 201–293.
- Kaiser, H. F. (1958). The varimax criterion for analytic rotation in factor analysis. *Psychometrika*, 23, 187–200.
- Lawley, D. N. & Maxwell, A. E. (1971). *Factor Analysis as a Statistical Method* (2.ª ed.). Butterworths.
- Revelle, W. (2024). *psych: Procedures for Psychological, Psychometric, and Personality Research*. R package.
- Hair, J. F., Black, W. C., Babin, B. J. & Anderson, R. E. (2010). *Multivariate Data Analysis* (7.ª ed.). Pearson.